



UNIVERSIDAD TECNICA
FEDERICO SANTA MARIA

Memoria para optar al título de Ingeniero Comercial
**“Pronóstico Jerárquico de Demanda Intermitente en
el Retail de Moda Femenina”**

Un Ensamble Híbrido de Machine Learning con Desacoplamiento Jerárquico

Profesor Guía

Marcelo Julián Villena Chamorro

Autor

Joaquín Ignacio Mondaca Parada

Profesora Correferente

Jocelyn Andrea Tapia Stefanoni



Problemática

La Industria moda Retail es altamente dinamica, con intermitencia en la demanda de productos generado por cambios de temporada y efecto de fast fashion.

Lo anterior genera dificultades en el manejo de predicción de demanda lo que lleva directamente a afrontar costos oportunidad asociados a inventario y/o falta de stock segun sea el caso de sku.

Características específicas:

1. **Intermitencia:** 30,3% de los valores son ceros a nivel SKU — meses sin venta del mismo producto
2. **Ciclos de vida cortos:** el interés por un modelo específico cae al finalizar la temporada (2-3 meses)
3. **Sensibilidad al precio:** el IPC Vestuario Mujer fluctúa $\pm 5\%$ mensual $\rightarrow$ la demanda responde a descuentos y promociones
4. **Desfase abastecimiento:** las órdenes se comprometen 3-6 meses antes $\rightarrow$ si la proyección falla, hay quiebre o sobrestock



Fuente: Elaboración propia con datos de la empresa.


Hipótesis

"La arquitectura jerárquica de ensamble híbrido ES-GBM, al integrar señales comerciales ex-ante, reduce significativamente el error de pronóstico (WAPE) frente a modelos clásicos univariados en series intermitentes"

Objetivo y Solución

Lo siguiente lleva a la necesidad de generar modelos de predicción con el objetivo de abordar la planificación comercial de mejor forma.

Diagrama 1: Evolucion de los modelos usados.



Fuente: Elaboración propia con datos de la empresa.

¿Como se definira el mejor modelo?

Por el contexto comercial se decidio que el modelo que logre alcanzar un menor WAPE sera el mas optimo para utilizarse, la justificacion radica en que el esta metrica en este contexto busca tener presicion en la demanda general , es decir aquellos SKU con mayor demanda tendran mayor peso en el calculo de este.

$$WAPE = \frac{\sum_{t=1}^n |y_t - \hat{y}_t|}{\sum_{t=1}^n y_t} \times 100 \%$$

Símbolo	Significado
y_t	Demanda real en el mes t (unidades vendidas)
$\hat{y}_t$	Demanda pronosticada en el mes t
$ y_t - \hat{y}_t $	Error absoluto en el mes t (ignora si sobre o subestima)
$\sum_{t=1}^n y_t - \hat{y}_t $	Suma de todos los errores absolutos del período
$\sum_{t=1}^n y_t$	Volumen total vendido en unidades (el denominador)
n	Número de meses del horizonte de evaluación (7 meses)
$\times 100\%$	Expresa el resultado como porcentaje

1.Durante el desarrollo si se calcularón otras metricas pero la que mide finalmente el modelo ganador es WAPE.

Presentacion de los resultados

Tabla 5.1: Comparativa Consolidada de Desempeño en el Período de Evaluación Fuera de Muestra (Feb–Ago 2025)

Modelo / Arquitectura	Nivel	WAPE	sMAPE	RMSE	MAE	Bias (%)	R ²	Ranking
<i>Panel A: Modelos Desagregados a Nivel SKU (Top 100 Productos)</i>								
ES-GBM (Static Top-Down)	SKU	16,10 %	20,47 %	26,7	11,4	-4,8 %	0,95	1°
ES-GBM (Learned Dynamic Share)	SKU	24,35 %	28,90 %	41,2	17,2	-5,2 %	0,79	2°
LSTM Recurrente (con precio ex-ante)	SKU	45,75 %	52,10 %	64,1	32,3	+8,4 %	0,55	3°
Chronos-Bolt Desagregado (Static Share)	SKU	48,44 %	70,69 %	65,1	34,2	+5,6 %	0,72	4°
LSTM Recurrente (sin precio ex-ante)	SKU	53,76 %	61,40 %	68,1	38,1	+11,2 %	0,38	5°
Seasonal Naïve (Benchmark y_{t-12})	SKU	69,89 %	88,17 %	107,2	49,4	+6,3 %	0,23	6°
SARIMAX (con precio y descuento)	SKU	73,24 %	170,87 %	122,9	51,7	+11,6 %	-0,01	7°
SARIMA Univariado (Línea Base)	SKU	76,74 %	309,88 %	139,6	54,2	+14,3 %	-0,31	8°
SBA (Syntetos-Boylan Approx.)	SKU	83,42 %	95,19 %	108,1	58,9	-4,2 %	0,22	9°
Croston Clásico	SKU	84,87 %	95,35 %	108,6	59,9	+0,9 %	0,21	10°
<i>Panel B: Modelos Agregados a Nivel Familia (58 Familias del Catálogo Top 100)</i>								
ES-GBM Ensamble Agregado	Familia	12,89 %	14,67 %	35,9	15,7	-4,8 %	0,96	1°
Chronos-Bolt Agregado (Zero-Shot)	Familia	36,35 %	61,38 %	81,9	44,3	+5,6 %	0,79	2°
LSTM Recurrente Agregado (Familia)	Familia	40,51 %	69,36 %	88,1	49,3	+7,9 %	0,76	3°
SARIMAX Agregado	Familia	59,64 %	268,31 %	165,3	72,6	+11,6 %	0,16	4°
Seasonal Naïve Agregado (Y_{t-12})	Familia	59,78 %	84,80 %	148,9	72,8	+6,3 %	0,32	5°
SARIMA Agregado	Familia	64,84 %	450,19 %	183,3	79,0	+14,3 %	-0,03	6°

1. Todos los modelos con excepcion de ES-GBM usaron una separacion de la serie de tiempo 90% entrenamiento y 10% prueba.

Supuestos y consideraciones relevantes

1. Si la base de datos tenía un producto con cantidad y venta cero se asume que la empresa no comercializó el producto ese periodo. En consecuencia la demanda es 0.
2. El precio se conoce ex-ante, esto producto a planificación comercial.
3. Solo se hizo uso de 100 sku de la muestra total con mayor venta.
4. El entrenamiento del modelo se divide en 80% entrenamiento, 10% validación y 10% prueba.

División 80-10-10

1.El 80% fue usada para que los modelos

Variables usadas

Modelos especificos usados breve explicacion

Ensamble de Cat boost , LST, Suavizacion exponencial winter ¿XgBoost?

Esquema del modelo a modo general

Explicación Capa 1

Explicación Capa 2

Explicación Capa 3 final

Gráficos simples

Ejericio comercial simple para cuatizar resultados

Resultado Test Hipotesis

Conclusiones relevantes + potenciales futuros trabajos

Anexos

Anexo 1: Mapa de Calor Intermitencia de Demanda

