



UNIVERSIDAD TECNICA
FEDERICO SANTA MARIA

Memoria para optar al título de Ingeniero Comercial

“Pronóstico Jerárquico de Demanda Intermitente en el Retail de Moda Femenina”

Un Ensamble Híbrido de Machine Learning con Desacoplamiento Jerárquico

Profesor Guía

Marcelo Julián Villena Chamorro

Autor

Joaquín Ignacio Mondaca Parada

Profesora Correferente

Jocelyn Andrea Tapia Stefanoni

Hoja de ruta



Seis bloques: del problema comercial a la evidencia y su impacto financiero.

01

Contexto y problema

Moda femenina, ciclos ultracortos e intermitencia estructural

02

Pregunta, hipótesis y objetivo

Qué se pone a prueba y con qué métrica se decide

03

Datos, variables y supuestos

Núcleo comercial: Top 100 SKUs y 58 familias, 2020–2025

04

Metodología y arquitectura

Protocolo anti-leakage y las tres capas del ES-GBM

05

Resultados y evidencia

Benchmark de diez arquitecturas y estudio de ablación

06

Impacto y conclusiones

Capital de trabajo liberado, límites y trabajo futuro

La moda femenina decide hoy lo que venderá en seis meses



Ciclos de vida ultracortos


Colecciones de 2 a 3 meses: la serie histórica de un SKU casi nunca alcanza a madurar antes de que el producto salga del catálogo.

La demanda la dirige el plan comercial

Precio, descuento y campañas mueven el volumen mensual con más fuerza que la inercia histórica de la serie.

Compromisos con 3 a 6 meses de anticipación

Las órdenes a fábrica se cierran antes de observar la demanda: equivocarse tarde se paga en inventario o en venta perdida.



Demanda agregada mensual del núcleo comercial (Top 100 SKUs), 2020–2025.

31 %

Primavera

25 %

Verano

23 %

Invierno

21 %

Otoño

Participación de cada estación en la demanda anual (waffle, anexo A15).

Series que prenden y se apagan: demanda intermitente

34,8 %

de los meses SKU no registran ninguna venta


Ceros estructurales, no ruido aleatorio

Por qué rompe a los modelos clásicos

Croston y SBA asumen intermitencia sin estacionalidad; SARIMA asume continuidad. En moda conviven las tres cosas: ceros, estacionalidad fuerte y shocks promocionales.

El dilema que hay detrás

- Sobre-stock: inmoviliza capital de trabajo y fuerza liquidaciones que erosionan el margen.
- Quiebre: destruye ingreso directo y deteriora la fidelidad del cliente.



Cada punto de error se paga dos veces: en capital inmovilizado y en venta perdida.

Qué se pone a prueba



Pregunta de investigación

¿Cuál enfoque de modelado —clásicos univariados, causales, redes recurrentes, modelos fundacionales pre-entrenados o arquitecturas híbridas de ensamble jerárquico— alcanza la mayor capacidad predictiva y robustez metodológica para pronosticar la demanda de retail de moda en Chile, evaluado mediante WAPE en un horizonte mensual $h = 1$?

H_0 · hipótesis nula

El WAPE esperado de la arquitectura ES-GBM no es inferior al de los benchmarks primarios (SARIMA, SARIMAX y LSTM).

H_1 · hipótesis de trabajo

El WAPE esperado de la arquitectura ES-GBM es inferior al de los benchmarks primarios de referencia.

Objetivo general

Desarrollar y evaluar una arquitectura de pronóstico jerárquica de ensamble (ES-GBM con desacoplamiento jerárquico a nivel SKU) para el retail de moda femenina en Chile, que minimice el error de predicción integrando variables comerciales ex-ante y suavizamiento exponencial, con el fin de optimizar la eficiencia del capital de trabajo.

Benchmarks primarios: SARIMA · SARIMAX · LSTM | Referencias de frontera: Croston · SBA · Seasonal Naïve · Chronos-Bolt

El núcleo comercial: dónde se juega el margen



Origen y ventana de los datos

- Registros POS reales de una cadena líder de moda femenina en Chile (“Empresa X”), segmento premium-mass market.
- 66 meses de historia mensual, 2020–2025; catálogo activo de 1.457 SKUs en 3 superfamilias y 58 familias.
- El Top 100 se define únicamente con datos previos al corte de calibración: la selección no mira el período de prueba.
- Regla ex-ante para familias descontinuadas y regularización de la grilla temporal (zero-filling) antes de agregar.
- Granularidad mensual: la unidad de decisión de compra y reposición de la cadena.
- Variable objetivo: unidades vendidas; el monto neto se usa para ponderar el impacto financiero de cada familia.

Variables del modelo

Target e identificación

- Venta cantidad — variable objetivo
- Venta monto neto — ponderación financiera
- Jerarquía: departamento, familia, sub-familia y SKU
- Mes calendario

Plan comercial ex-ante

- Precio promedio proyectado del mes t
- Descuento comercial promedio planificado
- Son decisiones de la empresa: se conocen antes de que ocurra la demanda
- Constituyen la señal predictiva más potente del ensamble

Temporales y de rezago

- Demanda rezagada y estadísticas móviles de 12 meses
- Estacionalidad armónica (seno y coseno del mes)
- Días de venta efectiva del período
- Variación porcentual de la demanda en $t-1$

Regla de oro anti-leakage: toda variable usa información disponible en $t-1$, salvo el plan comercial que la propia empresa fija ex-ante. Pruebas automatizadas sobre rezagos verifican que ninguna variable filtre información del futuro.

Supuestos y consideraciones relevantes

Supuestos base

- Venta cero con inventario disponible se interpreta como demanda cero.
- Precio y descuento son conocidos ex-ante por la planificación comercial.
- El target son ventas observadas en POS, no demanda latente no censurada.

Foco estratégico

- Se modela el núcleo comercial: Top 100 SKUs y 58 familias activas.
- Concentra 72 % del volumen y 78 % del margen: máximo impacto financiero por unidad de esfuerzo.
- La cola larga (1.357 SKUs de baja rotación) se plantea como trabajo futuro.

Qué implica al leer los resultados

- Ante quiebres de stock la venta observada se trunca: se pronostica demanda orgánica bajo las condiciones de disponibilidad históricas.
- No se capturan liquidaciones reactivas intramensuales (mark-downs de emergencia de última semana).

Asimetría metodológica declarada

- Las líneas base econométricas usan una parametrización global parsimoniosa estándar $(1,1,1) \times (1,1,1)$ con período estacional 12, sin selección de órdenes por SKU.
- La arquitectura propuesta sí contó con ingeniería de variables y calibración por fases: esto debe considerarse al interpretar la magnitud del diferencial.

Declarar los supuestos por adelantado es lo que permite interpretar correctamente la magnitud de los resultados.

WAPE: la métrica que resiste la demanda cero



$$WAPE = \frac{\sum_{t=1}^n |y_t - \hat{y}_t|}{\sum_{t=1}^n y_t} \times 100 \%$$

Por qué WAPE y no MAPE


- El MAPE divide por la demanda de cada mes: con ceros o valores unitarios pequeños se indetermina o explota.
- El WAPE agrega errores y volumen antes de dividir: pondera por unidades físicas y refleja el impacto operacional real.
- Ejemplo del propio benchmark: SARIMA obtiene sMAPE 309,88 % frente a un WAPE de 76,74 %; SARIMAX, 170,87 % frente a 73,24 %.

Símbolo	Significado
y_t	Demanda real en el mes t (unidades vendidas)
$\hat{y}_t$	Demanda pronosticada en el mes t
$ y_t - \hat{y}_t $	Error absoluto en el mes t (ignora si sobre o subestima)
$\sum_{t=1}^n y_t - \hat{y}_t $	Suma de todos los errores absolutos del período
$\sum_{t=1}^n y_t$	Volumen total vendido en unidades (el denominador)
n	Número de meses del horizonte de evaluación (7 meses)
$\times 100\%$	Expresa el resultado como porcentaje

Métricas complementarias

RMSE, MAE, sesgo y R^2 acompañan la evaluación; el WRMSSE (0,2017) da comparabilidad con el marco de la competencia M5.

Protocolo de validación: 80 / 10 / 10 cronológico




Entrenamiento Aprende los patrones históricos de nivel, estacionalidad y respuesta comercial.	Validación Calibra pesos NNLS del ensamble y el umbral de ruteo τ^* sin observar el futuro.	Prueba ciega Horizonte $h = 1$: cada mes se pronostica a un mes vista, encadenando siete orígenes con los pesos congelados.
---	--	--

En series de tiempo el orden temporal es innegociable: partición estrictamente cronológica, rezagos seguros en $t-1$ y pesos congelados desde el corte. Cualquier aleatorización filtraría el futuro hacia el pasado.

Fase 0 • La frontera de información


La etapa que consumió más tiempo del proyecto: garantizar que ninguna variable conozca el futuro.



Diez arquitecturas, un mismo protocolo



Desde la heurística estacional de 1970 hasta los modelos fundacionales pre-entrenados de 2024.




Todas las referencias se evalúan sobre la misma ventana, la misma jerarquía y la misma métrica: la comparación es una decisión de diseño, no un accidente.

Arquitectura ES-GBM: dos tracks en paralelo, un ensamble ponderado



Capas 1 y 2 • Por qué entrenar dos veces lo mismo



Comportamiento esperado de cada track frente a la demanda real.

Capa 1 • sin suavizamiento

- Los modelos ven la serie tal cual, en escala arcsinh .
- Reacciona rápido a shocks comerciales, pero hereda el ruido: mayor varianza.

Capa 2 • con suavizamiento

- Holt amortiguado extrae el nivel base y los modelos trabajan en escala relativa a ese nivel.
- Filtra ruido y conserva estacionalidad: menor varianza, pero reacciona más tarde.

La clave es la diversificación de errores: cuando el mercado gira, la Capa 1 llega antes; cuando hay ruido, la Capa 2 no se deja arrastrar. Sus errores no están correlacionados, y por eso la combinación pondera mejor que cualquiera de los dos por separado.

Cómo se combinan: pesos calibrados en validación

Ponderación NNLS

- Mínimos cuadrados no negativos: pesos mayores o iguales a cero que suman exactamente 1.
- Ningún modelo puede entrar con signo invertido ni dominar por construcción.

Búsqueda en grilla

- Se evalúa una grilla de umbrales de momentum entre 1,05 y 1,50.
- Para cada valor se reoptimizan los pesos de ruteo y se elige la combinación que minimiza el WAPE en validación.

Ruteo por régimen


- Indicador de momentum: media móvil de 3 meses sobre media móvil de 12.
- Si la familia acelera, pesa más el componente de nivel dinámico; si está madura, la señal conservadora.

GRILLA DE UMBRALES EVALUADA EN VALIDACIÓN



Esto es lo que da sostenibilidad en el tiempo: los pesos no son una constante del modelo, son un parámetro recalibrable. Si cambia la estructura del mercado, la recalibración reasigna peso hacia los modelos que mejor capturan el nuevo régimen, sin rediseñar la arquitectura.

Capa 3 • De la familia al SKU: desagregación top-down



Qué predice esta capa

- No la demanda del SKU, sino su participación dentro de la familia; la demanda familiar se multiplica por esa cuota.
- Restringido al catálogo estratégico: las cuotas se normalizan sobre el Top 100 de cada familia.

Vía A • proporciones históricas

- La cuota se calcula con las ventas del período de entrenamiento y se mantiene fija durante el test.
- Es el esquema que usan todos los modelos comparados: garantiza una comparación justa.
- **Resultado principal: WAPE 16,10 %.**

Vía B • cuotas supervisadas


- LightGBM, XGBoost y CatBoost predicen la cuota mes a mes con la historia que va surgiendo.
- Variables: cuota rezagada en t-1 y t-12, medias móviles de 3 y 12 meses, meses desde la última venta y precio relativo del SKU.
- **Evaluada en la misma ventana: WAPE 24,35 %.**

Regla de selección en validación

- El pipeline compara el WAPE de ambos esquemas sobre la ventana de validación.
- Adopta el de menor error para la prueba ciega, sin intervención manual.
- En esta ventana seleccionó el reparto estático; si el catálogo cambia, la misma regla puede adoptar las cuotas aprendidas.


En catálogos con alta intermitencia, la estabilidad de las proporciones históricas le ganó a la sofisticación de las cuotas aprendidas.

Benchmark fuera de muestra: febrero – agosto 2025




Lectura de resultados

- El ES-GBM reduce el error a menos de un cuarto de la mejor referencia clásica.
- Supera también a la red LSTM y al modelo fundacional Chronos-Bolt.
- Croston y SBA fallan por diseño: ignoran la estacionalidad.



WAPE fuera de muestra sobre 7 meses de prueba ciega. Métricas completas en el anexo A3; significancia estadística de la diferencia en el anexo A10.

Calidad del ajuste: el pronóstico sigue a la demanda real



Suma mensual del Top 100 SKUs: demanda observada vs. pronóstico ES-GBM.

16,10 %

WAPE a nivel SKU

12,89 %

WAPE a nivel familia

0,95 / 0,96

R^2 SKU y familia


-4,8 %

sesgo medio del pronóstico

Qué dice esto

- R^2 de 0,95 a nivel SKU: la arquitectura explica casi toda la varianza de la demanda.
- Sesgo levemente negativo (-4,8 %): el modelo sub-predice de forma sistemática y corregible.
- WRMSSE de 0,2017, comparable con el marco de la competencia M5.

Ablación del vector de precios: tres configuraciones, un mismo ensamble



WAPE a nivel SKU según la información de precios disponible al pronosticar.


Cómo se corrió el experimento

- Se reentrena el ensamble completo excluyendo o rezagando el vector de precios; el resto del protocolo se mantiene idéntico.
- Ejecuciones separadas del pipeline: 8 semillas × 3 modelos GBDT × NNLS × ruteo.

ESTUDIO DE ABLACIÓN · NIVEL SKU (TABLA 5.5)

Configuración de precios	WAPE	MAPE	RMSE	R²
1 · Sin información de precios	38,25 %	44,10 %	58,3	0,69
2 · Con precio rezagado t-1	26,42 %	31,50 %	41,2	0,78
3 · Con plan comercial ex-ante t	16,10 %	20,47 %	26,7	0,95

La configuración 3 es el modelo propuesto; las otras dos son reentrenamientos controlados.



Importancia por ganancia total del módulo GBDT: el precio ex-ante concentra el 67,0 %.

Del error de pronóstico al capital de trabajo



\$105,6M


CLP de capital de trabajo liberado
efecto nivel, en balance

\$23,2M

CLP de ahorro anual recurrente
holding costs, i = 22 % anual

7.041

unidades de stock de seguridad liberadas
CSL 95 %, lead time de 1 mes



Sensibilidad del escenario

- Rango conservador-exigente: \$84,5M a \$126,8M CLP de capital liberado.
- Ahorro anual entre \$15,2M y \$33,0M CLP según costo de reposición y tasa de mantención.

Escala y honestidad metodológica

- Con aprovisionamiento marítimo (L = 4 meses) el buffer liberado escala a 14.082 unidades.
- Ejercicio ilustrativo de orden de magnitud: usa el MAE como proxy de dispersión (sigma aprox. 1,25 × MAE).

Conclusiones

01

La evidencia respalda H_1

16,10 % de WAPE a nivel SKU y 12,89 % a nivel familia (R^2 0,95 y 0,96), frente a errores superiores al 69 % en todas las referencias clásicas y al 45 % en las redes recurrentes.

02

La demanda del fast fashion es dirigida

El plan comercial ex-ante reduce el error 22,2 puntos porcentuales. Sin señales de precio el error casi se duplica: 38,25 % frente a 16,10 %.

03

El desacoplamiento jerárquico vence a la intermitencia

Pronosticar donde la señal es continua y repartir hacia abajo resultó superior a modelar el SKU directamente, incluso con cuotas aprendidas.

04

El ensamble híbrido supera a los enfoques puros

Estadística para el nivel, aprendizaje automático para el residuo comercial y ruteo adaptativo según el estado de la categoría: cada componente hace lo que mejor sabe.

La contribución no es un algoritmo nuevo, sino una arquitectura que asigna cada problema —inercia, comercialidad e intermitencia— al método que mejor lo resuelve, bajo un protocolo que impide que el resultado se explique por fuga de información.

Limitaciones y trabajo futuro

Limitaciones reconocidas

- Horizonte $h = 1$ mensual: la industria con abastecimiento marítimo requiere extender la evaluación a 3 y 6 meses.
- Validez externa: un solo retailer del segmento premium-mass market en Chile.
- La ventana de prueba incluye el peak de mayo, pero excluye noviembre–diciembre, el período de mayor presión promocional.
- El target son ventas observadas: los quiebres truncan la demanda latente.
- Pesos y umbrales congelados desde el corte: la frecuencia óptima de reentrenamiento queda abierta.
- El ejercicio financiero es ilustrativo, con MAE como proxy de dispersión.

Líneas de trabajo futuro

- Fine-tuning de modelos fundacionales (Chronos, TimesFM) incorporando exógenas comerciales; el zero-shot ya alcanzó 36,35 % a nivel familia.
- Arquitecturas híbridas de deep learning y modelos tabulares en la etapa de desagregación de cuotas.
- Desempeño diferencial por perfil de SKU: asignar el método según rotación, intermitencia y sensibilidad al precio, en lugar de una arquitectura única.
- Extensión a la cola larga del catálogo (1.357 SKUs de baja rotación).
- Integración del pronóstico al proceso de S&OP y a la política de compra internacional.

Declarar los límites con precisión es parte del resultado: define hasta dónde puede extrapolarse la evidencia y qué preguntas quedan abiertas para la siguiente iteración.



UNIVERSIDAD TECNICA
FEDERICO SANTA MARIA

Gracias



Preguntas y comentarios

Joaquín Ignacio Mondaca Parada

Memoria para optar al título de Ingeniero Comercial · Universidad Técnica Federico Santa María

Profesor guía: Marcelo Julián Villena Chamorro · Profesora correferente: Jocelyn Andrea Tapia Stefanoni

Los anexos que siguen respaldan las preguntas del jurado.

Los modelos de referencia, en simple



Modelo	Qué hace	Punto fuerte	Punto débil	WAPE
Seasonal Naïve	Repite lo que se vendió el mismo mes del año anterior.	Referencia honesta y sin costo: captura la estacionalidad pura.	Ciega a precios, campañas y cambios de tendencia.	69,89 %
SARIMA	Proyecta la serie usando su propia historia y su ciclo anual.	Estándar de la literatura: interpretable y reproducible.	Es lineal y no admite información externa; los ceros la desestabilizan.	76,74 %
SARIMAX	SARIMA más variables externas: precio y descuento.	Incorpora la palanca comercial dentro de un marco econométrico.	La relación precio-demanda no es lineal: la estructura se le queda corta.	73,24 %
Croston	Separa dos preguntas: cada cuánto se vende y cuánto se vende.	Diseñado específicamente para demanda con muchos ceros.	No modela estacionalidad ni precio, que es justo lo que manda en moda.	84,87 %
SBA	Croston con una corrección de sesgo (Syntetos-Boylan).	Corrige la sobreestimación sistemática del Croston clásico.	Hereda la misma ceguera estacional y comercial.	83,42 %
LSTM	Red neuronal con memoria que aprende patrones de secuencias.	Captura relaciones no lineales y dependencias temporales largas.	Exige mucha historia; con series cortas e intermitentes se vuelve inestable.	45,75 %
Chronos-Bolt	Modelo fundacional pre-entrenado sobre miles de millones de series.	Predice sin entrenamiento previo; muy sólido en agregado (36,35 % en familia).	No admite las variables comerciales propias de la empresa.	48,44 %

Ninguna referencia clásica combina las tres cosas que exige la moda: ceros, estacionalidad fuerte y sensibilidad al plan comercial.

Los componentes de la arquitectura propuesta



Componente	Dónde actúa	Qué hace	Punto fuerte	Punto débil
Holt amortiguado	Capa 2	Suaviza la serie y estima su nivel y tendencia, frenando la extrapolación.	Muy estable y con pocos parámetros: entrega una base limpia.	Por sí solo ignora precios y cualquier relación no lineal.
XGBoost	Capas 1 y 2	Árboles que corrigen, uno tras otro, el error del anterior.	Captura interacciones como precio por temporada; muy preciso en datos tabulares.	No extrapola tendencias fuera del rango que vio en entrenamiento.
LightGBM	Capas 1 y 2	Mismo principio que XGBoost, pero por histogramas: mucho más rápido.	Escala bien y maneja con soltura las variables categóricas.	Puede sobreajustar en series cortas si no se regula.
CatBoost	Capas 1 y 2	Boosting ordenado, pensado para variables categóricas.	Robusto con familias y canales; menos propenso al sobreajuste.	Es el más lento de entrenar de los tres.
TabPFN	En paralelo	Modelo fundacional para tablas: infiere sin entrenar.	Buen desempeño inmediato y aporta diversidad al ensamble.	Pensado para conjuntos pequeños; no es un modelo de series nativo.
NNLS y ruteo	Validación	Decide cuánto pesa cada predicción y en qué régimen aplicarla.	Adapta el ensamble al momento comercial de cada familia.	Los pesos deben recalibrarse cuando cambia la estructura del mercado.

La arquitectura no elige un ganador: pone a cada método a hacer aquello en lo que es bueno y deja que la validación decida el peso.

Comparativa consolidada de desempeño (Tabla 5.1)



Modelo / arquitectura	WAPE	sMAPE	RMSE	MAE	Bias	R ²	Ranking
PANEL A · MODELOS DESAGREGADOS A NIVEL SKU (TOP 100 PRODUCTOS)							
ES-GBM (Static Top-Down)	16,10 %	20,47 %	26,7	11,4	−4,8 %	0,95	1°
ES-GBM (Learned Dynamic Share)	24,35 %	28,90 %	41,2	17,2	−5,2 %	0,79	2°
LSTM Recurrente (con precio ex-ante)	45,75 %	52,10 %	64,1	32,3	+8,4 %	0,55	3°
Chronos-Bolt Desagregado (Static Share)	48,44 %	70,69 %	65,1	34,2	+5,6 %	0,72	4°
LSTM Recurrente (sin precio ex-ante)	53,76 %	61,40 %	68,1	38,1	+11,2 %	0,38	5°
Seasonal Naïve (benchmark del año anterior)	69,89 %	88,17 %	107,2	49,4	+6,3 %	0,23	6°
SARIMAX (con precio y descuento)	73,24 %	170,87 %	122,9	51,7	+11,6 %	−0,01	7°
SARIMA Univariado (línea base)	76,74 %	309,88 %	139,6	54,2	+14,3 %	−0,31	8°
SBA (Syntetos-Boylan Approximation)	83,42 %	95,19 %	108,1	58,9	−4,2 %	0,22	9°
Croston Clásico	84,87 %	95,35 %	108,6	59,9	+0,9 %	0,21	10°
PANEL B · MODELOS AGREGADOS A NIVEL FAMILIA (58 FAMILIAS)							
ES-GBM Ensamble Agregado	12,89 %	14,67 %	35,9	15,7	−4,8 %	0,96	1°
Chronos-Bolt Agregado (Zero-Shot)	36,35 %	61,38 %	81,9	44,3	+5,6 %	0,79	2°
LSTM Recurrente Agregado	40,51 %	69,36 %	88,1	49,3	+7,9 %	0,76	3°
SARIMAX Agregado	59,64 %	268,31 %	165,3	72,6	+11,6 %	0,16	4°
Seasonal Naïve Agregado	59,78 %	84,80 %	148,9	72,8	+6,3 %	0,32	5°
SARIMA Agregado	64,84 %	450,19 %	183,3	79,0	+14,3 %	−0,03	6°

Evaluación fuera de muestra, febrero a agosto de 2025. Las fórmulas de cada métrica están en los anexos A4 a A6.

Métricas de error relativo

WAPE

Weighted Absolute Percentage Error · métrica rectora del estudio

$$WAPE = \frac{\sum_{t=1}^n |y_t - \hat{y}_t|}{\sum_{t=1}^n y_t} \times 100 \%$$

QUÉ SIGNIFICA CADA SÍMBOLO

y	demanda real observada en el mes t, en unidades vendidas
ŷ	pronóstico del modelo para ese mismo mes
Σ	suma sobre los n meses del horizonte de evaluación
n	número de meses evaluados: 7 en la prueba ciega
100 %	expresa el resultado como porcentaje del volumen vendido

Cómo se lee

Suma todos los errores y los divide por el volumen total vendido: es inmune a la división por cero. Un WAPE de 16,10 % significa que el error acumulado equivale al 16,10 % de las unidades vendidas.

MAPE

Mean Absolute Percentage Error · reportado en su variante simétrica

$$MAPE = \frac{1}{|T^+|} \sum_{t \in T^+} \left| \frac{y_t - \hat{y}_t}{y_t} \right| \times 100 \%$$

QUÉ SIGNIFICA CADA SÍMBOLO

y	demanda real observada en el mes t
ŷ	pronóstico del modelo para ese mismo mes
T +	conjunto de meses con demanda estrictamente positiva
T +	cantidad de esos meses: el promedio se calcula solo sobre ellos

Cómo se lee

Promedia el error relativo mes a mes. Con demanda cero se indetermina y con demanda baja se dispara: SARIMA llega a un sMAPE de 309,88 % pese a un WAPE de 76,74 %.

Métricas de escala absoluta

MAE

Mean Absolute Error · error promedio en unidades físicas

$$MAE = \frac{1}{n} \sum_{t=1}^n |y_t - \hat{y}_t|$$

QUÉ SIGNIFICA CADA SÍMBOLO

y	demanda real observada en el mes t
ŷ	pronóstico del modelo para ese mismo mes
	valor absoluto: ignora si el modelo sobrestimó o subestimó
n	número total de observaciones evaluadas

Cómo se lee

Error promedio expresado en prendas. Alimenta el cálculo del stock de seguridad: 11,4 unidades por SKU frente a 54,2 de SARIMA, y esa diferencia es la que libera capital.

RMSE

Root Mean Squared Error · penaliza los errores grandes

$$RMSE = \sqrt{\frac{1}{n} \sum_{t=1}^n (y_t - \hat{y}_t)^2}$$

QUÉ SIGNIFICA CADA SÍMBOLO

y	demanda real observada en el mes t
ŷ	pronóstico del modelo para ese mismo mes
()²	eleva al cuadrado: castiga con más fuerza las desviaciones grandes
raíz	devuelve el resultado a las unidades originales

Cómo se lee

Al castigar los errores grandes, delata a los modelos que aciertan casi siempre pero fallan feo en los peaks de campaña. El ES-GBM obtiene 26,7 unidades frente a 139,6 de SARIMA.

Métricas de calibración y bondad de ajuste

Bias

Sesgo porcentual · hacia qué lado se equivoca el modelo

$$\text{Bias} = \frac{\sum_{t=1}^n (\hat{y}_t - y_t)}{\sum_{t=1}^n y_t} \times 100 \%$$

QUÉ SIGNIFICA CADA SÍMBOLO

$\hat{y} - y$	diferencia con signo entre pronóstico y demanda real
$+$	sobreestimación sistemática: riesgo de sobre-stock
$-$	subestimación sistemática: riesgo de quiebre
Σy	volumen total vendido, para expresarlo como porcentaje

Cómo se lee

Un buen modelo combina WAPE bajo con sesgo cercano a cero. El ES-GBM tiene -4,8 %: subestima levemente, que en gestión de inventario es el error más barato de los dos.

R²

Coeficiente de determinación · cuánta varianza explica el modelo

$$R^2 = 1 - \frac{\sum_{t=1}^n (y_t - \hat{y}_t)^2}{\sum_{t=1}^n (y_t - \bar{y})^2}$$

QUÉ SIGNIFICA CADA SÍMBOLO

y	demanda real observada en el mes t
$\hat{y}$	pronóstico del modelo para ese mismo mes
media	demanda promedio del período: la y con barra en la fórmula
1 -	resta la varianza no explicada sobre la varianza total

Cómo se lee

Proporción de la variabilidad de la demanda que el modelo explica. El ES-GBM alcanza 0,95 a nivel SKU y 0,96 a nivel familia; SARIMA queda en terreno negativo, es decir, predice peor que usar el promedio.

Ficha técnica del pipeline



Horizonte de pronóstico

h = 1 mes

Cada predicción es a un mes vista, no a seis.

7 orígenes encadenados

La prueba ciega recorre febrero a agosto de 2025 avanzando mes a mes.

Extensión pendiente

Evaluar h = 3 y h = 6 para el ciclo de compra marítimo.

Validación rolling-origin

Walk-forward

El origen se desplaza en el tiempo; nunca se usa información posterior al punto de corte.

C1 = marzo 2024

Inicio de la ventana que calibra el ensamble, los pesos NNLS y el ruteo.

CUT = enero 2025

Corte que separa definitivamente entrenamiento de prueba.

Qué se actualiza y qué se congela

Se actualiza

El nivel base de Holt se recalcula mes a mes con la historia hasta t-1.

Se congela

Modelos GBDT, pesos NNLS, umbral de ruteo y cuotas quedan fijos desde el corte.

Por qué

Reentrenar cada mes tiene fricción real y riesgo de sobrereaccionar a anomalías.

Reproducibilidad

Cada modelo se entrena con 8 semillas —42, 1, 7, 2025, 99, 3, 11 y 21— y se promedian las inferencias; se fijan versiones de librerías y parámetros de ejecución.

Qué prueba realmente este diseño

Evaluar siete meses con los pesos congelados somete la arquitectura a una prueba de estrés frente al cambio de régimen, en lugar de premiarla por reajustarse.

El 16,10 % no se obtuvo reentrenando cada mes: se obtuvo con una calibración única anterior a enero de 2025 sostenida durante siete meses.

Cómo se trató la intermitencia



34,8 %

de los meses a nivel SKU tienen demanda nula
A nivel familia las series son densas y continuas

Zero-filling: lo que sí se hizo

El ERP no guarda una fila cuando no hay venta: simplemente la omite. Se generó el producto cartesiano de todos los meses por cada SKU y familia, asignando explícitamente demanda cero en los períodos sin movimiento, para poder calcular rezagos y medias móviles consistentes.

No se imputó la media

Sustituir los ceros por un promedio inventaría demanda que nunca existió y aplanaría la estacionalidad real.

No se interpoló

Interpolar entre meses con venta suavizaría artificialmente el patrón intermitente que justamente se quiere modelar.

No se eliminaron los ceros

Un cero no es un dato faltante: es la observación de que ese mes no hubo venta, y esa información es predictiva.

Entonces, ¿cómo se resuelve la intermitencia?

Por arquitectura, no por imputación. Se pronostica en el nivel donde la serie es continua y tiene estacionalidad clara —la familia comercial— y desde ahí se reparte a cada SKU mediante cuotas. El problema del cero deja de ser un problema de modelado y pasa a ser uno de reparto.

Supuesto declarado: si hay inventario disponible y la venta es cero, se interpreta como demanda cero. Los quiebres de stock son la limitación conocida de ese supuesto.

Hiperparámetros calibrados



Modelo	Módulo	Hiperparámetros	Función objetivo
XGBoost	Ensamble combo	learning_rate 0,05 · max_depth 6 · subsample 0,90 · colsample_bytree 0,90 · n_estimators 500	reg:squarederror
LightGBM	Residual y ensamble global	learning_rate 0,05 · num_leaves 31 · subsample 0,90 · colsample_bytree 0,90 · n_estimators 600	regression
CatBoost	Módulo categórico	learning_rate 0,05 · depth 6 · iterations 600	RMSE
TabPFN	Fundacional tabular	TabPFNRegressor v2 · n_estimators 2 · inferencia in-context zero-shot · escalado robusto	Sin ajuste: zero-shot
Motor de cuotas	Capa 3 · vía dinámica	LightGBM y XGBoost: n_estimators 500, learning_rate 0,05 · CatBoost por grilla: depth entre 4 y 8, learning_rate 0,03 o 0,05, iterations 600	Huber ($\alpha = 0,9$) y normalización al simplex

Cómo se eligieron

Búsqueda en grilla sobre la ventana de validación intermedia (marzo 2024 a enero 2025).
Ningún hiperparámetro se ajustó mirando el período de prueba.

Por qué ocho semillas

Cada configuración se entrena con las semillas 42, 1, 7, 2025, 99, 3, 11 y 21, promediando las inferencias: reduce la varianza de inicialización y evita resultados afortunados.

¿Es estadísticamente significativa la diferencia?

TEST DE DIEBOLD-MARIANO · ES-GBM FRENTE A LOS BENCHMARKS PRIMARIOS

vs. SARIMA

t = 7,84

p = 0,0002

vs. SARIMAX

t = 13,19

p < 0,0001

vs. LSTM

t = 10,14

p = 0,0001

Qué contrasta el test

- Compara la precisión predictiva de dos modelos sobre exactamente los mismos datos.
- Se aplicó sobre errores transversales agrupados, con función de pérdida cuadrática y corrección HAC.

Alcance declarado en la tesis

- Evalúa diferencias bajo pérdida cuadrática: no es un contraste directo sobre el WAPE, sino un respaldo inferencial consistente.
- Para Chronos-Bolt, Croston, SBA y Seasonal Naïve la comparación se mantiene descriptiva: el protocolo inferencial se delimitó a priori.

Advertencia metodológica reconocida

La literatura econométrica advierte sobre aplicar Diebold-Mariano a paneles agrupados en horizontes cortos: por eso el test se presenta como evidencia complementaria y no como el argumento central.


La ventaja del ES-GBM sobre los tres benchmarks primarios no se explica por azar muestral.

Pronóstico vs. demanda real por modelo



Seis arquitecturas representativas contra la demanda observada del Top 100 SKUs en la ventana de prueba.

Diagnóstico de residuos del modelo propuesto





Qué muestra el diagnóstico

- Residuos aproximadamente simétricos y centrados en cero.
- Ljung-Box (lag 12): $Q = 8,42$ con $p = 0,751$; no se rechaza la ausencia de autocorrelación.

Alcance de la conclusión

- Shapiro-Wilk $p = 0,184$: compatible con normalidad, sin constituir prueba definitiva.
- No se afirma homocedasticidad estricta; la evidencia es consistente con un comportamiento residual adecuado.

Intermitencia: del catálogo completo a un SKU



Ejemplo individual: 62 % de meses en cero.

Lectura

- La intermitencia no es homogénea: convive con familias de rotación continua.
- Modelar el SKU aislado obliga a predecir la ocurrencia y la magnitud a la vez.
- La agregación a familia recupera una señal continua y estacional.

Matriz de sensibilidad del impacto financiero (Tabla 6.1)

PANEL A · GESTIÓN DESCENTRALIZADA POR SKU (K = 100 · 7.041 UNIDADES LIBERADAS)

Escenario de costo y tasa	Costo reposición (c)	Tasa holding (i)	Capital liberado	Ahorro anual
Conservador	\$12.000	18 %	\$84,5M CLP	\$15,2M CLP/año
Caso base	\$15.000	22 %	\$105,6M CLP	\$23,2M CLP/año
Exigente (alta merma)	\$18.000	26 %	\$126,8M CLP	\$33,0M CLP/año


PANEL B · AGRUPACIÓN CENTRALIZADA CON RISK POOLING (K = 10 · 704 UNIDADES)

Bajo pooling independiente el capital liberado se reduce a un rango de \$8,5M a \$12,7M CLP, con ahorros anuales de \$1,5M a \$3,3M CLP.

Con aprovisionamiento marítimo internacional (L = 4 meses) el buffer liberado escala por $\sqrt{4}$: 14.082 unidades, equivalentes a \$211,2M CLP.


Supuestos: Z = 1,645 (CSL 95 %); SS = Z × MAE × K × raíz(L). Ejercicio ilustrativo de orden de magnitud.

Entorno macro y estacionalidad de la demanda



IPC de vestuario y calzado, serie mensual auditada INE (base 2023 = 100).

Los precios del vestuario caen de forma sostenida en el período: el margen se defiende con volumen bien planificado, no con precio. La estacionalidad se reparte entre las cuatro estaciones, sin un peak único dominante.



Trazabilidad, verificación y uso de herramientas de IA

Mecanismos de verificación

- Separación cronológica estricta entre entrenamiento, validación y prueba.
- Pruebas automatizadas sobre rezagos y disponibilidad temporal de cada variable.
- Revisión manual de transformaciones y agregaciones jerárquicas.
- Recálculo directo de las métricas a partir de las predicciones almacenadas.
- Fijación de semillas, versiones de librerías y parámetros de ejecución.
- Verificación de consistencia entre las formulaciones matemáticas y el código.

Uso de herramientas de IA generativa

- Apoyo instrumental en programación, depuración, refactorización y revisión de redacción.
- No sustituyó la formulación del problema, la selección de datos, las decisiones metodológicas ni la interpretación de resultados.
- Distintos modelos fundacionales se usaron como panel de contraste técnico para debatir decisiones de diseño.
- Ningún fragmento de código se incorporó sin inspección, adaptación y validación previa.
- Por confidencialidad del retailer, los registros transaccionales no son distribuibles; se conservan scripts, entornos y resultados intermedios para auditoría.

El autor definió la arquitectura experimental, las reglas de disponibilidad temporal de las variables, los criterios de comparación, las métricas y los supuestos del impacto financiero. La responsabilidad por la exactitud de resultados y conclusiones recae en el autor.