



UNIVERSIDAD TECNICA
FEDERICO SANTA MARIA

Memoria para optar al título de Ingeniero Comercial

“Pronóstico Jerárquico de Demanda Intermitente en el Retail de Moda Femenina”

Un Ensamble Híbrido de Machine Learning con Desacoplamiento Jerárquico

Profesor Guía

Marcelo Julián Villena Chamorro

Autor

Joaquín Ignacio Mondaca Parada

Profesora Correferente

Jocelyn Andrea Tapia Stefanoni

Hoja de ruta



Seis bloques: del problema comercial a la evidencia y su impacto financiero.

01

Contexto y problema

Moda femenina, ciclos ultracortos e intermitencia estructural

02

Pregunta, hipótesis y objetivo

Qué se pone a prueba y con qué métrica se decide

03

Datos, variables y supuestos

Núcleo comercial: Top 100 SKUs y 58 familias, 2020–2025

04

Metodología y arquitectura

Protocolo anti-leakage y las tres capas del ES-GBM

05

Resultados y evidencia

Benchmark de diez arquitecturas y estudio de ablación

06

Impacto y conclusiones

Capital de trabajo liberado, límites y trabajo futuro

La moda femenina decide hoy lo que venderá en seis meses

Ciclos de vida ultracortos


Colecciones de 2 a 3 meses: la serie histórica de un SKU casi nunca alcanza a madurar antes de que el producto salga del catálogo.

La demanda la dirige el plan comercial

Precio, descuento y campañas mueven el volumen mensual con más fuerza que la inercia histórica de la serie.

Compromisos con 3 a 6 meses de anticipación

Las órdenes a fábrica se cierran antes de observar la demanda: equivocarse tarde se paga en inventario o en venta perdida.



Demanda agregada mensual del núcleo comercial (Top 100 SKUs), 2020-2025.

31 %

Primavera

25 %

Verano

23 %

Invierno

21 %

Otoño

Participación de cada estación en la demanda anual (waffle, anexo A6).

Series que prenden y se apagan: demanda intermitente

30,3 %

de los pares SKU-mes no registran ninguna venta


Ceros estructurales, no ruido aleatorio

Por qué rompe a los modelos clásicos

Croston y SBA asumen intermitencia sin estacionalidad; SARIMA asume continuidad. En moda conviven las tres cosas: ceros, estacionalidad fuerte y shocks promocionales.

El dilema que hay detrás

- Sobre-stock: inmoviliza capital de trabajo y fuerza liquidaciones que erosionan el margen.
- Quiebre: destruye ingreso directo y deteriora la fidelidad del cliente.



Cada punto de error se paga dos veces: en capital inmovilizado y en venta perdida.

Qué se pone a prueba



Pregunta de investigación

¿Cuál enfoque de modelado —clásicos univariados, causales, redes recurrentes, modelos fundacionales pre-entrenados o arquitecturas híbridas de ensamble jerárquico— alcanza la mayor capacidad predictiva y robustez metodológica para pronosticar la demanda de retail de moda en Chile, evaluado mediante WAPE en un horizonte mensual $h = 1$?

H_0 · hipótesis nula

El WAPE esperado de la arquitectura ES-GBM no es inferior al de los benchmarks primarios (SARIMA, SARIMAX y LSTM).

H_1 · hipótesis de trabajo

El WAPE esperado de la arquitectura ES-GBM es inferior al de los benchmarks primarios de referencia.

Objetivo general

Desarrollar y evaluar una arquitectura de pronóstico jerárquica de ensamble (ES-GBM con desacoplamiento jerárquico a nivel SKU) para el retail de moda femenina en Chile, que minimice el error de predicción integrando variables comerciales ex-ante y suavizamiento exponencial, con el fin de optimizar la eficiencia del capital de trabajo.

Benchmarks primarios: SARIMA · SARIMAX · LSTM | Referencias de frontera: Croston · SBA · Seasonal Naïve · Chronos-Bolt

El núcleo comercial: dónde se juega el margen



- Origen y ventana de los datos**
- Registros POS reales de una cadena líder de moda femenina en Chile (“Empresa X”), segmento premium-mass market.
 - 66 meses de historia mensual, 2020–2025; catálogo activo de 1.457 SKUs en 3 superfamilias y 58 familias.
 - El Top 100 se define únicamente con datos previos al corte de calibración: la selección no mira el período de prueba.
 - Regla ex-ante para familias descontinuadas y regularización de la grilla temporal (zero-filling) antes de agregar.
 - Granularidad mensual: la unidad de decisión de compra y reposición de la cadena.
 - Variable objetivo: unidades vendidas; el monto neto se usa para ponderar el impacto financiero de cada familia.

Variables del modelo

Target e identificación

- Venta cantidad — variable objetivo
- Venta monto neto — ponderación financiera
- Jerarquía: departamento, familia, sub-familia y SKU
- Mes calendario

Plan comercial ex-ante

- Precio promedio proyectado del mes t
- Descuento comercial promedio planificado
- Son decisiones de la empresa: se conocen antes de que ocurra la demanda
- Constituyen la señal predictiva más potente del ensamble

Temporales y de rezago

- Demanda rezagada y estadísticas móviles de 12 meses
- Estacionalidad armónica (seno y coseno del mes)
- Días de venta efectiva del período
- Variación porcentual de la demanda en $t-1$

Regla de oro anti-leakage: toda variable usa información disponible en $t-1$, salvo el plan comercial que la propia empresa fija ex-ante. Pruebas automatizadas sobre rezagos verifican que ninguna variable filtre información del futuro.

Supuestos y consideraciones relevantes

Supuestos base

- Venta cero con inventario disponible se interpreta como demanda cero.
- Precio y descuento son conocidos ex-ante por la planificación comercial.
- El target son ventas observadas en POS, no demanda latente no censurada.

Foco estratégico

- Se modela el núcleo comercial: Top 100 SKUs y 58 familias activas.
- Concentra 72 % del volumen y 78 % del margen: máximo impacto financiero por unidad de esfuerzo.
- La cola larga (1.357 SKUs de baja rotación) se plantea como trabajo futuro.

Qué implica al leer los resultados

- Ante quiebres de stock la venta observada se trunca: se pronostica demanda orgánica bajo las condiciones de disponibilidad históricas.
- No se capturan liquidaciones reactivas intramensuales (mark-downs de emergencia de última semana).

Asimetría metodológica declarada

- Las líneas base econométricas usan una parametrización global parsimoniosa estándar $(1,1,1) \times (1,1,1)$ con período estacional 12, sin selección de órdenes por SKU.
- La arquitectura propuesta sí contó con ingeniería de variables y calibración por fases: esto debe considerarse al interpretar la magnitud del diferencial.

Declarar los supuestos por adelantado es lo que permite interpretar correctamente la magnitud de los resultados.

WAPE: la métrica que resiste la demanda cero



$$WAPE = \frac{\sum_{t=1}^n |y_t - \hat{y}_t|}{\sum_{t=1}^n y_t} \times 100 \%$$

Por qué WAPE y no MAPE

- El MAPE divide por la demanda de cada mes: con ceros o valores unitarios pequeños se indetermina o explota.
- El WAPE agrega errores y volumen antes de dividir: pondera por unidades físicas y refleja el impacto operacional real.
- Ejemplo del propio benchmark: SARIMA obtiene sMAPE 309,88 % frente a un WAPE de 76,74 %; SARIMAX, 170,87 % frente a 73,24 %.

Símbolo	Significado
y_t	Demanda real en el mes t (unidades vendidas)
$\hat{y}_t$	Demanda pronosticada en el mes t
$ y_t - \hat{y}_t $	Error absoluto en el mes t (ignora si sobre o subestima)
$\sum_{t=1}^n y_t - \hat{y}_t $	Suma de todos los errores absolutos del período
$\sum_{t=1}^n y_t$	Volumen total vendido en unidades (el denominador)
n	Número de meses del horizonte de evaluación (7 meses)
$\times 100\%$	Expresa el resultado como porcentaje

Métricas complementarias

RMSE, MAE, sesgo y R^2 acompañan la evaluación; el WRMSSE (0,2017) da comparabilidad con el marco de la competencia M5.

Protocolo de validación: 80 / 10 / 10 cronológico




Entrenamiento Aprende los patrones históricos de nivel, estacionalidad y respuesta comercial.	Validación Calibra pesos NNLS del ensamble y el umbral de ruteo τ^* sin observar el futuro.	Prueba ciega Siete meses evaluados con pesos congelados: simula un despliegue real.
---	--	---

En series de tiempo el orden temporal es innegociable: partición estrictamente cronológica, rezagos seguros en $t-1$ y pesos congelados desde el corte. Cualquier aleatorización filtraría el futuro hacia el pasado.

Diez arquitecturas, un mismo protocolo




Desde la heurística estacional de 1970 hasta los modelos fundacionales pre-entrenados de 2024.



Todas las referencias se evalúan sobre la misma ventana, la misma jerarquía y la misma métrica: la comparación es una decisión de diseño, no un accidente.

Arquitectura ES-GBM: tres capas, tres problemas distintos



Capa 1 • Desacoplamiento estructural

Objetivo

Capturar la inercia, el nivel base y la estacionalidad estructural de cada una de las 58 familias comerciales, donde la serie es continua y tiene señal.

Método

Suavizamiento exponencial Holt amortiguado. El amortiguamiento frena la extrapolación de la tendencia y evita proyecciones explosivas en horizontes largos.

Qué delega

Todo evento disruptivo —promociones, liquidaciones, campañas— queda deliberadamente en el residuo, para que lo explique la Capa 2 con información comercial.

Por qué empezar por aquí

Pedirle a un árbol de decisión que aprenda el nivel de una serie es gastar capacidad de modelo en algo que una ecuación de suavizamiento hace mejor y con menos varianza. Al retirar el nivel, el problema que queda —el residuo— es justamente donde la información comercial es decisiva.

Resultado de la capa: una señal base estable sobre la que el aprendizaje automático solo tiene que explicar desviaciones.

Capa 2 · Proyección de residuos comerciales



El objetivo

Modelar el residuo de la Capa 1: la parte de la demanda que la inercia no explica. Ahí es donde vive el efecto de las palancas comerciales sobre la venta.

Las palancas que entran al modelo

- Precio promedio proyectado ex-ante del mes t
- Descuento comercial planificado
- Rezagos, ventanas móviles y estacionalidad armónica

BANCO DE MODELOS DEL ENSAMBLE

XGBoost

boosting por gradiente

LightGBM

boosting histogramado

CatBoost

boosting ordenado

TabPFN

modelo fundacional tabular

Tratamiento numérico

Los residuos se modelan en escala arcsinh —que absorbe magnitudes extremas sin descartar el signo— con ponderación temporal decreciente (decay de 24 meses) para privilegiar el comportamiento comercial reciente. Modelos distintos fallan distinto: el ensamble promedia errores no correlacionados.

Capa 3 · Integración y desagregación jerárquica

Ruteo dinámico por momentum

Los pesos del ensamble se optimizan por NNLS en validación. Si el momentum trimestral de la familia supera el umbral τ^* (calibrado entre 1,05 y 1,50), el sistema conmuta hacia el componente de aprendizaje automático; si la categoría está estable, pesa más la señal inercial.

Desagregación top-down

La predicción de familia se reparte a cada SKU con proporciones históricas del período de entrenamiento, garantizando coherencia jerárquica exacta: las partes suman el total.

Por qué resuelve la intermitencia


Arriba, la serie agregada es continua y tiene estacionalidad clara; abajo, el reparto proporcional distribuye ese pronóstico limpio. El 30,3 % de ceros deja de ser un problema de modelado.

Decisión experimental documentada

Se probó también una desagregación supervisada con cuotas dinámicas aprendidas (learned shares): obtuvo 24,35 % de WAPE frente al 16,10 % del reparto estático. En catálogos muy intermitentes, la estabilidad de las proporciones históricas vence a la sofisticación.


Pronosticar bien la familia y repartir bien el SKU venció a todos los modelos que pronostican el SKU directamente.

Benchmark fuera de muestra: febrero – agosto 2025




Lectura de resultados

- El ES-GBM reduce el error a menos de un cuarto de la mejor referencia clásica.
- Supera también a la red LSTM y al modelo fundacional Chronos-Bolt.
- Croston y SBA fallan por diseño: ignoran la estacionalidad.



WAPE fuera de muestra sobre 7 meses de prueba ciega. Detalle completo de métricas en el anexo A1.

Calidad del ajuste: el pronóstico sigue a la demanda real



Suma mensual del Top 100 SKUs: demanda observada vs. pronóstico ES-GBM.

16,10 %

WAPE a nivel SKU

12,89 %

WAPE a nivel familia

0,95 / 0,96

R^2 SKU y familia


-4,8 %

sesgo medio del pronóstico


Qué dice esto

- R^2 de 0,95 a nivel SKU: la arquitectura explica casi toda la varianza de la demanda.
- Sesgo levemente negativo (-4,8 %): el modelo sub-predice de forma sistemática y corregible.
- WRMSSE de 0,2017, comparable con el marco de la competencia M5.

Ablación: la demanda no es estocástica, la dirige el plan comercial



WAPE a nivel SKU según la información de precios disponible.



Importancia por ganancia total del módulo GBDT.

Dos lecturas, una advertencia

- El precio ex-ante concentra el 67,0 % de la ganancia total del submodelo GBDT.
- Aun sin precios (38,25 %), la arquitectura supera a SARIMA (76,74 %) y SBA (83,42 %): la base estructural aporta por sí sola.
- La importancia por ganancia no es una estimación causal de la elasticidad precio.

Del error de pronóstico al capital de trabajo



\$105,6M


CLP de capital de trabajo liberado
efecto nivel, en balance

\$23,2M

CLP de ahorro anual recurrente
holding costs, $i = 22\%$ anual

7.041

unidades de stock de seguridad liberadas
CSL 95 %, lead time de 1 mes



Sensibilidad del escenario

- Rango conservador-exigente: \$84,5M a \$126,8M CLP de capital liberado.
- Ahorro anual entre \$15,2M y \$33,0M CLP según costo de reposición y tasa de mantención.

Escala y honestidad metodológica

- Con aprovisionamiento marítimo (L = 4 meses) el buffer liberado escala a 14.082 unidades.
- Ejercicio ilustrativo de orden de magnitud: usa el MAE como proxy de dispersión (sigma aprox. $1,25 \times \text{MAE}$).

Conclusiones

01

La evidencia respalda H_1

16,10 % de WAPE a nivel SKU y 12,89 % a nivel familia (R^2 0,95 y 0,96), frente a errores superiores al 69 % en todas las referencias clásicas y al 45 % en las redes recurrentes.

02

La demanda del fast fashion es dirigida

El plan comercial ex-ante reduce el error 22,2 puntos porcentuales. Sin señales de precio el error casi se duplica: 38,25 % frente a 16,10 %.

03

El desacoplamiento jerárquico vence a la intermitencia

Pronosticar donde la señal es continua y repartir hacia abajo resultó superior a modelar el SKU directamente, incluso con cuotas aprendidas.

04

El ensamble híbrido supera a los enfoques puros

Estadística para el nivel, aprendizaje automático para el residuo comercial y ruteo adaptativo según el estado de la categoría: cada componente hace lo que mejor sabe.

La contribución no es un algoritmo nuevo, sino una arquitectura que asigna cada problema —inercia, comercialidad e intermitencia— al método que mejor lo resuelve, bajo un protocolo que impide que el resultado se explique por fuga de información.

Limitaciones y trabajo futuro

Limitaciones reconocidas

- Horizonte $h = 1$ mensual: la industria con abastecimiento marítimo requiere extender la evaluación a 3 y 6 meses.
- Validez externa: un solo retailer del segmento premium-mass market en Chile.
- La ventana de prueba incluye el peak de mayo, pero excluye noviembre–diciembre, el período de mayor presión promocional.
- El target son ventas observadas: los quiebres truncan la demanda latente.
- Pesos y umbrales congelados desde el corte: la frecuencia óptima de reentrenamiento queda abierta.
- El ejercicio financiero es ilustrativo, con MAE como proxy de dispersión.

Líneas de trabajo futuro

- Fine-tuning de modelos fundacionales (Chronos, TimesFM) incorporando exógenas comerciales; el zero-shot ya alcanzó 36,35 % a nivel familia.
- Arquitecturas híbridas de deep learning y modelos tabulares en la etapa de desagregación de cuotas.
- Desempeño diferencial por perfil de SKU: asignar el método según rotación, intermitencia y sensibilidad al precio, en lugar de una arquitectura única.
- Extensión a la cola larga del catálogo (1.357 SKUs de baja rotación).
- Integración del pronóstico al proceso de S&OP y a la política de compra internacional.

Declarar los límites con precisión es parte del resultado: define hasta dónde puede extrapolarse la evidencia y qué preguntas quedan abiertas para la siguiente iteración.



UNIVERSIDAD TECNICA
FEDERICO SANTA MARIA

Gracias



Preguntas y comentarios

Joaquín Ignacio Mondaca Parada

Memoria para optar al título de Ingeniero Comercial · Universidad Técnica Federico Santa María

Profesor guía: Marcelo Julián Villena Chamorro · Profesora correferente: Jocelyn Andrea Tapia Stefanoni

Los anexos que siguen respaldan las preguntas del jurado.

Comparativa consolidada de desempeño (Tabla 5.1)



Tabla 5.1: Comparativa Consolidada de Desempeño en el Período de Evaluación Fuera de Muestra (Feb–Ago 2025)

Modelo / Arquitectura	Nivel	WAPE	sMAPE	RMSE	MAE	Bias (%)	R ²	Ranking
Panel A: Modelos Desagregados a Nivel SKU (Top 100 Productos)								
ES-GBM (Static Top-Down)	SKU	16,10 %	20,47 %	26,7	11,4	-4,8 %	0,95	1°
ES-GBM (Learned Dynamic Share)	SKU	24,35 %	28,90 %	41,2	17,2	-5,2 %	0,79	2°
LSTM Recurrente (con precio ex-ante)	SKU	45,75 %	52,10 %	64,1	32,3	+8,4 %	0,55	3°
Chronos-Bolt Desagregado (Static Share)	SKU	48,44 %	70,69 %	65,1	34,2	+5,6 %	0,72	4°
LSTM Recurrente (sin precio ex-ante)	SKU	53,76 %	61,40 %	68,1	38,1	+11,2 %	0,38	5°
Seasonal Naïve (Benchmark y_{t-12})	SKU	69,89 %	88,17 %	107,2	49,4	+6,3 %	0,23	6°
SARIMAX (con precio y descuento)	SKU	73,24 %	170,87 %	122,9	51,7	+11,6 %	-0,01	7°
SARIMA Univariado (Línea Base)	SKU	76,74 %	309,88 %	139,6	54,2	+14,3 %	-0,31	8°
SBA (Syntetos-Boylan Approx.)	SKU	83,42 %	95,19 %	108,1	58,9	-4,2 %	0,22	9°
Croston Clásico	SKU	84,87 %	95,35 %	108,6	59,9	+0,9 %	0,21	10°
Panel B: Modelos Agregados a Nivel Familia (58 Familias del Catálogo Top 100)								
ES-GBM Ensamble Agregado	Familia	12,89 %	14,67 %	35,9	15,7	-4,8 %	0,96	1°
Chronos-Bolt Agregado (Zero-Shot)	Familia	36,35 %	61,38 %	81,9	44,3	+5,6 %	0,79	2°
LSTM Recurrente Agregado (Familia)	Familia	40,51 %	69,36 %	88,1	49,3	+7,9 %	0,76	3°
SARIMAX Agregado	Familia	59,64 %	268,31 %	165,3	72,6	+11,6 %	0,16	4°
Seasonal Naïve Agregado (Y_{t-12})	Familia	59,78 %	84,80 %	148,9	72,8	+6,3 %	0,32	5°
SARIMA Agregado	Familia	64,84 %	450,19 %	183,3	79,0	+14,3 %	-0,03	6°


Métricas completas fuera de muestra (feb–ago 2025) para los diez modelos evaluados, en los niveles SKU y familia.

Pronóstico vs. demanda real por modelo



Seis arquitecturas representativas contra la demanda observada del Top 100 SKUs en la ventana de prueba.

Diagnóstico de residuos del modelo propuesto





Qué muestra el diagnóstico

- Residuos aproximadamente simétricos y centrados en cero.
- Ljung-Box (lag 12): $Q = 8,42$ con $p = 0,751$; no se rechaza la ausencia de autocorrelación.

Alcance de la conclusión

- Shapiro-Wilk $p = 0,184$: compatible con normalidad, sin constituir prueba definitiva.
- No se afirma homocedasticidad estricta; la evidencia es consistente con un comportamiento residual adecuado.

Intermitencia: del catálogo completo a un SKU



Ejemplo individual: 62 % de meses en cero.

Lectura

- La intermitencia no es homogénea: convive con familias de rotación continua.
- Modelar el SKU aislado obliga a predecir la ocurrencia y la magnitud a la vez.
- La agregación a familia recupera una señal continua y estacional.

Matriz de sensibilidad del impacto financiero (Tabla 6.1)

PANEL A · GESTIÓN DESCENTRALIZADA POR SKU (K = 100 · 7.041 UNIDADES LIBERADAS)

Escenario de costo y tasa	Costo reposición (c)	Tasa holding (i)	Capital liberado	Ahorro anual
Conservador	\$12.000	18 %	\$84,5M CLP	\$15,2M CLP/año
Caso base	\$15.000	22 %	\$105,6M CLP	\$23,2M CLP/año
Exigente (alta merma)	\$18.000	26 %	\$126,8M CLP	\$33,0M CLP/año


PANEL B · AGRUPACIÓN CENTRALIZADA CON RISK POOLING (K = 10 · 704 UNIDADES)

Bajo pooling independiente el capital liberado se reduce a un rango de \$8,5M a \$12,7M CLP, con ahorros anuales de \$1,5M a \$3,3M CLP.

Con aprovisionamiento marítimo internacional (L = 4 meses) el buffer liberado escala por $\sqrt{4}$: 14.082 unidades, equivalentes a \$211,2M CLP.


Supuestos: Z = 1,645 (CSL 95 %); SS = Z × MAE × K × raíz(L). Ejercicio ilustrativo de orden de magnitud.

Entorno macro y estacionalidad de la demanda



IPC de vestuario y calzado, serie mensual auditada INE (base 2023 = 100).

Los precios del vestuario caen de forma sostenida en el período: el margen se defiende con volumen bien planificado, no con precio. La estacionalidad se reparte entre las cuatro estaciones, sin un peak único dominante.



Trazabilidad, verificación y uso de herramientas de IA

Mecanismos de verificación

- Separación cronológica estricta entre entrenamiento, validación y prueba.
- Pruebas automatizadas sobre rezagos y disponibilidad temporal de cada variable.
- Revisión manual de transformaciones y agregaciones jerárquicas.
- Recálculo directo de las métricas a partir de las predicciones almacenadas.
- Fijación de semillas, versiones de librerías y parámetros de ejecución.
- Verificación de consistencia entre las formulaciones matemáticas y el código.

Uso de herramientas de IA generativa

- Apoyo instrumental en programación, depuración, refactorización y revisión de redacción.
- No sustituyó la formulación del problema, la selección de datos, las decisiones metodológicas ni la interpretación de resultados.
- Distintos modelos fundacionales se usaron como panel de contraste técnico para debatir decisiones de diseño.
- Ningún fragmento de código se incorporó sin inspección, adaptación y validación previa.
- Por confidencialidad del retailer, los registros transaccionales no son distribuibles; se conservan scripts, entornos y resultados intermedios para auditoría.

El autor definió la arquitectura experimental, las reglas de disponibilidad temporal de las variables, los criterios de comparación, las métricas y los supuestos del impacto financiero. La responsabilidad por la exactitud de resultados y conclusiones recae en el autor.