

UNIVERSIDAD TÉCNICA FEDERICO SANTA MARÍA
DEPARTAMENTO DE INGENIERÍA COMERCIAL
CAMPUS VITACURA – SANTIAGO, CHILE

“Pronóstico Jerárquico de Demanda Intermitente en el Retail de Moda Femenina”

Un Ensamble Híbrido de Machine Learning con Desacoplamiento Jerárquico

Autor:

Joaquín Ignacio Mondaca Parada

Profesor Guía:

Marcelo Julián Villena Chamorro

Memoria de Título presentada en conformidad a los requisitos
para optar al título profesional de Ingeniero Comercial

Santiago, Chile – 2026

Resumen

La industria del retail de moda opera bajo un dilema operacional estructural: por un lado, el sobre-stock inmoviliza capital de trabajo y erosiona márgenes mediante liquidaciones forzadas; por otro, el quiebre de stock destruye ingresos directos y deteriora la fidelidad del cliente. Esta memoria de título diseña, implementa y evalúa una arquitectura jerárquica de ensamble híbrido (**ES-GBM**) para predecir la demanda mensual en una cadena líder de moda femenina en Chile, focalizando la inferencia desagregada sobre el núcleo comercial estratégico (Top 100 SKUs que concentran el 72 % del volumen y 78 % del margen¹) y 58 Familias agregadas (2020–2025).

A nivel agregado (Familia), la arquitectura desacopla el nivel estructural de la serie mediante suavizamiento exponencial Holt amortiguado y proyecta los residuos comerciales mediante ensambles no lineales de árboles potenciados por gradiente (*XGBoost*, *LightGBM*, *CatBoost*) y modelos fundacionales tabulares (*TabPFN*), integrados vía ruteo dinámico adaptativo por momentum ($\tau^* \in [1,05; 1,50]$). A nivel desagregado (SKU), la demanda familiar se descompone hacia SKUs individuales mediante proporciones históricas Top-Down. En el período de evaluación fuera de muestra (febrero a agosto de 2025), la arquitectura propuesta alcanza un WAPE de **16,10 %** a nivel SKU y **12,89 %** a nivel Familia ($R^2 = 0,95$ y $0,96$), superando a implementaciones estándar y parsimoniosas de las referencias clásicas: Croston (84,87 %), SBA (83,42 %), SARIMA (76,74 %), SARIMAX (73,24 %), Seasonal Naïve (69,89 %), redes neuronales LSTM (45,75 %) y al modelo fundacional Amazon Chronos-Bolt a nivel agregado (36,35 %). Este resultado es condicional a la disponibilidad del plan comercial ex-ante: un experimento de ablación sin señales de precio arroja un WAPE de **38,25 %**, mostrando que la incorporación del plan comercial ex-ante aporta una reducción del WAPE de 22,2 puntos porcentuales (desde 38,25 % sin precios hasta 16,10 % con precio ex-ante), mientras que el conjunto de componentes estructurales de la arquitectura (nivel base inercial, ensamble no lineal y ruteo por momentum) forma parte de la diferencia de desempeño restante frente a las líneas base clásicas. Una evaluación ilustrativa de capital de trabajo estima que la contracción del error de pronóstico permitiría liberar un inventario amortiguador permanente de **\$105,6 millones CLP** (7.041 unidades) y generar un ahorro operativo recurrente en costos de mantención (*holding costs*) de **\$23,2 millones CLP anuales**.

Palabras Clave: Pronóstico de Demanda, Retail de Moda, Machine Learning, Ensamble Híbrido, Desagregación Jerárquica, Protocolo Anti-Leakage, Capital de Trabajo.

¹Concentración calculada a partir del total de unidades vendidas y margen bruto reportado en el período de entrenamiento y validación (enero 2020 – enero 2025), sobre la población de 100 SKUs de mayor rotación seleccionados por volumen.

Abstract

Fashion retail operates under a persistent operational dilemma: overstocking ties up working capital and erodes margins through heavy discounting, while stockouts lead to lost revenue and customer defection. This thesis designs, implements, and evaluates a hierarchical hybrid ensemble architecture (**ES-GBM**) for monthly demand forecasting in a leading Chilean women’s fashion retailer, focusing disaggregate inference on the core commercial catalog (Top 100 SKUs accounting for 72 % of sales volume and 78 % of gross margin²) across 58 aggregated Families (2020–2025).

At the aggregate Family level, the architecture decouples structural trend-cycle inertia via damped Holt exponential smoothing and models commercial residuals through gradient boosted decision trees (*XGBoost*, *LightGBM*, *CatBoost*) and tabular foundation models (*TabPFN*), dynamically routed by a calibrated momentum indicator ($\tau^* \in [1,05, 1,50]$). At the disaggregate SKU level, family-level predictions are decomposed into individual SKUs via top-down historical proportions. Over a 7-month out-of-sample evaluation horizon (February–August 2025), the proposed ES-GBM architecture achieves a **16.10 %** SKU WAPE and **12.89 %** Family WAPE ($R^2 = 0,95$ and $0,96$), outperforming standard benchmark implementations: intermittent Croston (84.87 %), SBA (83.42 %), classical SARIMA (76.74 %), SARIMAX (73.24 %), Seasonal Naïve (69.89 %), PyTorch LSTMs (45.75 %), and zero-shot Amazon Chronos-Bolt at the family level (36.35 %). This result is conditional on the availability of ex-ante commercial planning signals: an ablation experiment without pricing signals attains a **38.25 %** WAPE, revealing that the incorporation of ex-ante pricing signals contributes a 22.2 percentage point WAPE reduction (from 38.25 % without prices to 16.10 % with ex-ante pricing), while the architecture’s structural components (inertial baseline, nonlinear ensemble, and momentum routing) form the remaining performance differential against classical benchmarks. An illustrative working capital assessment indicates that forecast accuracy improvements could enable a permanent buffer stock release of 7,041 units (**\$105.6 million CLP**) and generate recurring operational holding cost savings of **\$23.2 million CLP annually**.

Keywords: Demand Forecasting, Fashion Retail, Machine Learning, Hybrid Ensemble, Hierarchical Disaggregation, Anti-Leakage Protocol, Working Capital.

²Concentration calculated from total units sold and reported gross margin during the training and validation period (January 2020 – January 2025), over the population of 100 top-rotation SKUs selected by sales volume.

Índice general

Resumen	I
Abstract	II
1. Introducción	1
1.1. Importancia del trabajo	1
1.2. Vacío en la Literatura (Gap Analysis)	2
1.3. Pregunta de investigación e hipótesis	2
1.4. Objetivos	2
1.4.1. Objetivo general	2
1.4.2. Objetivos específicos.	3
2. Caracterización del Caso de Estudio	4
2.1. Descripción de la problemática	4
2.2. Estructura de Mercado y Competencia	4
2.3. Consumidores y Segmento Objetivo	5
2.3.1. Elasticidad, Ciclo de Vida del Producto y Perfil del Cliente	5
2.3.2. Patrones de venta de la empresa	5
2.4. Elasticidad y análisis del IPC en la industria	7
3. Revisión de Literatura y Marco Teórico	8
3.1. Fundamentos de la Demanda en Moda	8
3.2. Series de Tiempo y Propiedades en Retail	8
3.3. Modelos de Pronóstico y Métodos de Referencia	9
3.3.1. Modelos ARIMA y SARIMA	9
3.3.2. Pronóstico de demanda intermitente	9
3.3.3. Modelos de Series de Tiempo con Regresores Exógenos (SARIMAX)	11
3.3.4. Machine Learning	12
3.3.5. Deep Learning en Series Temporales: Redes LSTM	12
3.4. Métricas de Evaluación de Desempeño y Criterios de Selección	13
3.4.1. Métricas de Escala Absoluta: MAE y RMSE	13
3.4.2. Métricas Porcentuales: Limitaciones del MAPE y Ventaja Estructural del WAPE	14
3.4.3. Métricas de Calibración y Bondad de Ajuste: Bias y R^2	15

3.4.4. Métricas Jerárquicas Escaladas: Weighted Root Mean Squared Scaled Error (WRMSSE)	15
3.5. Rolling-Origin como metodología de validación en pronósticos de demanda	16
3.5.1. Definición de metodología	16
3.5.2. Beneficios, desafíos y limitaciones	16
3.5.3. Aplicaciones del Rolling-Origin en el contexto de retail	17
3.6. Otros estudios	17
3.6.1. Short-term salmon price forecasting	17
3.6.2. Modelo de previsión de demanda de productos en retail fast fashion (2024)	18
4. Metodología y Formulación de Modelos	20
4.1. Microestructura de los Datos y Análisis Exploratorio	20
4.1.1. Protocolo de Regularización Temporal e Inserción de Ceros (<i>Zero-Filling</i>)	21
4.1.2. Dinámica Temporal, Estacionalidad y Concentración de Demanda	21
4.2. Diseño de la Batería Experimental y Criterios de Selección	22
4.3. Configuración y Arquitectura del Modelo SARIMA (Univariado)	25
4.3.1. Preprocesamiento y Estabilización de Varianza	25
4.3.2. Formulación Matemática del Modelo SARIMA	25
4.3.3. Configuración de parámetros (Arquitectura Global)	25
4.3.4. Estrategia de Validación	26
4.4. Configuración y Arquitectura del Modelo SARIMAX (Regresores Exógenos)	26
4.4.1. Selección de Variables Exógenas y Anti-Leakage	26
4.4.2. Formulación Matemática del Modelo SARIMAX	27
4.4.3. Estrategia de Validación y Top-Down	27
4.5. Configuración y Formulación de la Arquitectura Jerárquica Híbrida ES-GBM	27
4.5.1. Arquitectura de Ensamble con Nivel Suavizado	32
4.5.2. Formulación del Blend y Ruteo por Régimen	32
4.5.3. Segmentación por Volumen de Demanda (Adaptación ABC)	33
4.5.4. Ingeniería de Características y Anti-Leakage	34
4.5.5. Creación de features	34
4.5.6. Selección de Pesos y Umbrales en Validación	35
4.5.7. Curación de Variables mediante Auditoría Anti-Leakage	35
4.6. Arquitectura de Deep Learning: Redes LSTM (Enfoque Top-Down)	36
4.6.1. Estrategia Jerárquica de Modelado (Top-Down Approach)	36
4.6.2. Preprocesamiento de Tensores y Escalado	36
4.6.3. Arquitectura de la Red (Celdas de Memoria)	36
4.6.4. Modelo Fundacional de Series de Tiempo (Amazon Chronos-Bolt)	37
4.6.5. Desagregación Dinámica a Nivel SKU: Cuotas Supervisadas (<i>Learned Shares</i>)	37
4.7. Descripción de variables	39

4.7.1. Variables de Identificación de Catálogo y Target	39
4.7.2. Variables Exógenas y de Planificación Comercial Ex-Ante	39
5. Resultados y Análisis Comparativo	40
5.1. Comparativa Consolidada de Desempeño Global	40
5.2. Evaluación de Líneas Base Econométricas (SARIMA y SARIMAX)	43
5.3. Modelos para Demanda Intermitente y Ceros (Croston y SBA)	44
5.4. Deep Learning Recurrente y Modelos Fundacionales (LSTM y Chronos-Bolt)	45
5.5. Desempeño de la Arquitectura Propuesta (ES-GBM con Desagregación Top-Down)	47
5.5.1. Estudio de Ablación del Vector de Precios y Señales Ex-Ante	48
5.6. Interpretabilidad y Diagnóstico de Residuos	49
5.6.1. Diagnóstico y Evaluación de Residuos	50
6. Conclusiones e Impacto Financiero	51
6.1. Limitaciones Estructurales de los Modelos Clásicos Univariados	51
6.2. Eficacia de la arquitectura de ensamble y principales aportes metodológicos	51
6.3. Evaluación de Deep Learning en Contextos de Alta Intermitencia	53
6.4. Evaluación de Hipótesis y Evidencia Inferencial	53
6.5. Implicancias Conceptuales para el Pronóstico en Retail de Moda	54
6.5.1. La demanda como resultado de la planificación comercial	54
6.5.2. El rol de las variables de planificación comercial en la predicción de unidades	54
6.6. Impacto Económico, Financiero y Operacional	55
6.6.1. Evaluación Financiera del Impacto en Capital de Trabajo: Distinción entre Stock y Flujo	55
6.7. Limitaciones del Estudio	57
6.8. Futuras investigaciones	58
6.9. Uso de Herramientas de Inteligencia Artificial y Protocolo de Verificación	59
A. Anexos	64
A.1. Anexo 1: Serie Mensual del IPC de Vestuario (INE 2024–2025)	64
A.2. Anexo 2: Evolución Histórica de Ventas Mensuales en Unidades y Monto Neto (2020–2022)	65
A.3. Anexo 3: Hiperparámetros de los Modelos de Ensamble ES-GBM a Nivel Familia	66
A.4. Anexo 4: Especificaciones y Parámetros de Calibración de los Modelos Benchmark	68
A.5. Anexo 5: Configuración y Features del Motor de Desagregación Dinámica (Learned Shares)	69
A.6. Anexo 6: Ficha Técnica y Diccionario de Variables del Conjunto de Datos Consolidado	71
A.7. Anexo 7: Formulación Matemática del Modelo SARIMA	74
A.8. Anexo 8: Formulación Matemática del Modelo SARIMAX y Corrección de Sesgo	75
A.9. Anexo 9: Arquitectura Detallada de la Red LSTM	76

Índice de tablas

4.1. Taxonomía, Rol Experimental e Hipótesis de la Batería de Modelos	23
4.2. Protocolo de Calibración y Evaluación Fuera de Muestra de la Arquitectura ES-GBM.	30
5.1. Comparativa Consolidada de Desempeño en el Período de Evaluación Fuera de Mues- tra (Feb–Ago 2025)	41
5.2. Desempeño Comparativo de Modelos para Demanda Intermitente a Nivel SKU . . .	44
5.3. Evaluación de Deep Learning Recurrente y Modelos Fundacionales	45
5.4. Métricas de Desempeño del Ensamble Jerárquico ES-GBM	47
5.5. Estudio de Ablación del Vector de Precios en el Ensamble ES-GBM (Nivel SKU) . .	48
6.1. Matriz de Sensibilidad del Impacto Financiero en Inventarios.	57

Índice de figuras

2.1. Distribución Estacional de las Ventas Anuales en la Empresa X (Waffle Chart) . . .	6
2.2. Evolución del IPC de la Subclase Vestuario Mujeres en Chile (Base 2023 = 100) . .	7
4.1. Evolución del Monto Neto de Ventas Mensuales en Catálogo Estratégico (Año 2024)	21
4.2. Evolución Metodológica de la Batería de Referencia y Rol en el Diseño Experimental	23
4.3. Diagrama de Flujo de la Arquitectura Jerárquica Híbrida ES-GBM (Descomposición Inercial, Ensamble GBDT + TabPFN y Desagregación Top-Down).	29
4.4. Diagrama del Módulo de Ensamble Híbrido, Blending Global y Ruteo por Régimen.	31
4.5. Pipeline de Entrenamiento Secuencial y Protocolo de Validación Anti-Leakage en Tres Fases.	33
5.1. Comparativa Consolidada de Pronóstico Fuera de Muestra vs Demanda Real para Modelos Representativos	42
5.2. Desempeño Predictivo de la Línea Base SARIMA vs. Demanda Real Fuera de Muestra (Suma Top 100 SKUs)	43
5.3. Evolución Temporal del Pronóstico ES-GBM vs. Demanda Real Fuera de Muestra (Suma Top 100 SKUs)	47
5.4. Importancia Relativa de Variables por Ganancia Total del Módulo GBDT (<i>Total Gain Importance</i>)	49
5.5. Análisis de Residuos y Heterocedasticidad del Modelo Propuesto	50

Capítulo 1

Introducción

1.1. Importancia del trabajo

En el retail de moda, estimar con precisión la demanda mensual define la rentabilidad y la liquidez operativa del negocio. Cuando las compras se basan en proyecciones descalzadas de la realidad, surgen dos problemas inmediatos: el quiebre de inventario en los meses de mayor venta (como mayo o diciembre), que genera pérdidas directas de facturación, o la acumulación de sobrestock en bodega, que inmoviliza capital de trabajo y fuerza rebajas de precio no planificadas al cierre de temporada.

Las características del catálogo de vestuario femenino —alta estacionalidad, ciclos de vida de pocos meses y ventas intermitentes con meses en cero a nivel de producto individual— hacen que las reglas empíricas y los promedios móviles tradicionales resulten insuficientes. Por esta razón, mejorar la precisión del pronóstico (operacionalizada mediante el WAPE) se traduce directamente en una mejor planificación de compras y gestión del capital de trabajo.

Una proyección confiable puede permitir coordinar el abastecimiento con el plan comercial de la empresa, asegurando que las campañas de descuento cuenten con el volumen necesario sin saturar las tiendas con productos de baja rotación. Asimismo, disminuye las mermas por obsolescencia textil y optimiza la capacidad de almacenamiento físico en los centros de distribución.

Durante este trabajo se implementa una cronología metodológica de modelos predictivos con el objetivo de abordar los desafíos característicos del retail de moda femenina: alta estacionalidad, ciclos de vida cortos y un entorno de demanda altamente intermitente a nivel de producto individual bajo un protocolo de evaluación común y riguroso.

La propuesta central consiste en una arquitectura jerárquica Top-Down, donde la demanda agregada por familia se modela mediante un ensamble híbrido ES-GBM (Exponential Smoothing – Gradient Boosting Machine, que integra modelos de Gradient Boosting —XGBoost, LightGBM, CatBoost— con suavizamiento exponencial Holt amortiguado y ruteo dinámico por régimen de momentum), cuya predicción es posteriormente desagregada a nivel SKU mediante proporciones históricas.

1.2. Vacío en la Literatura (Gap Analysis)

La revisión bibliográfica realizada para esta investigación encontró escasa evidencia de trabajos que integren la señal comercial ex-ante (precios y promociones presupuestadas) dentro de esquemas híbridos de ensamble jerárquico bajo un protocolo estricto que evite la fuga de datos hacia el futuro en el contexto específico de vestuario femenino, brecha que esta memoria aborda directamente sobre datos reales.

1.3. Pregunta de investigación e hipótesis

Para establecer correctamente la hipótesis de trabajo, se define en primer lugar la siguiente pregunta de investigación:

¿Cuál enfoque de modelado (clásicos univariados como SARIMA, causales como SARIMAX, redes recurrentes LSTM, modelos fundacionales pre-entrenados como Chronos-Bolt o arquitecturas híbridas de ensamble como ES-GBM con desacoplamiento jerárquico) alcanza la mayor capacidad predictiva y robustez metodológica para pronosticar la demanda de retail moda en Chile, evaluado mediante el WAPE como métrica principal en un horizonte mensual $h=1$?

A partir de esta pregunta se plantean las siguientes hipótesis de trabajo, donde la pérdida predictiva se operacionaliza mediante el WAPE como métrica principal:

- H0: El WAPE esperado de la arquitectura propuesta ES-GBM no es inferior al de los benchmarks primarios de referencia (SARIMA, SARIMAX y LSTM).
- H1: El WAPE esperado de la arquitectura propuesta ES-GBM es inferior al de los benchmarks primarios de referencia.

Los modelos Chronos-Bolt, Croston, SBA y Seasonal Naïve se incorporan como referencias descriptivas y complementarias de frontera metodológica.

1.4. Objetivos

A continuación se formulan los objetivos que guían el desarrollo conceptual, metodológico y experimental de esta memoria de título:

1.4.1. Objetivo general

Desarrollar y evaluar una arquitectura de pronóstico jerárquica de ensamble (ES-GBM con desacoplamiento jerárquico a nivel SKU) para el mercado de retail de moda femenina en Chile, que minimice el error de predicción (WAPE) mediante la integración de variables comerciales ex-ante y suavizamiento exponencial, con el fin de optimizar la eficiencia del capital de trabajo.

1.4.2. Objetivos específicos.

Para dar cumplimiento al objetivo general, se plantean los siguientes objetivos específicos:

1. Preparación y Estructuración Jerárquica de Datos: Ejecutar un protocolo riguroso de agregación temporal y espacial (Top-Down a nivel Familia), aplicando una regla ex-ante para familias descontinuas y asegurando la integridad de los datos mediante rezagos seguros (t-1) para prevenir fuga de información (data leakage).
2. Implementación de Modelos de Referencia (Benchmarks): Desarrollar y evaluar modelos de referencia estadísticos (SARIMA, SARIMAX con precio exógeno planeado), de aprendizaje profundo (LSTM) y modelos fundacionales pre-entrenados (Amazon Chronos-Bolt) bajo un horizonte de predicción $h=1$ mensual, utilizando configuraciones estándar de la literatura para asegurar reproducibilidad.
3. Diseño de la Arquitectura Final (ES-GBM): Implementar la arquitectura híbrida ES-GBM combinando modelos de Gradient Boosting (XGBoost, LightGBM, CatBoost) y modelos fundacionales tabulares (TabPFN) con Holt amortiguado y ruteo por régimen de momentum, complementado con desagregación Top-Down a nivel SKU.
4. Validación Temporal y Evaluación Multimétrica: Evaluar el desempeño de los modelos mediante un protocolo de evaluación fuera de muestra (*out-of-sample*) sobre el período de prueba ciego (2025-02 a 2025-08), utilizando un conjunto integral de métricas (WAPE como métrica principal, MAPE, RMSE, MAE, Bias y R^2).
5. Análisis Comparativo e Impacto de Negocio: Comparar la precisión de los pronósticos en los distintos niveles de agregación (Familia y SKU), analizando la contribución de cada componente metodológico y las implicancias económicas de la reducción del error en términos de inventario y capital de trabajo.

Capítulo 2

Caracterización del Caso de Estudio

2.1. Descripción de la problemática

Para el desarrollo de este trabajo, y con el objetivo de resguardar la identidad de la empresa, se la denominará “Empresa X”. Los datos utilizados corresponden a información real y reflejan su posición competitiva dentro del segmento de moda femenina en el retail chileno.

El problema central de la Empresa X radica en el desfase temporal de su abastecimiento: las órdenes de compra a proveedores se comprometen con 3 a 6 meses de anticipación sobre proyecciones basadas en reglas empíricas o promedios simples. Cuando la demanda real difiere de lo presupuestado, se generan dos impactos operativos directos: por un lado, quiebres de inventario en los meses de alta venta (mayo y diciembre) que se traducen en ventas perdidas irrecuperables; por otro, acumulación de sobrestock en bodega que inmoviliza capital de trabajo y fuerza rebajas agresivas de precio en los meses de cambio de temporada (febrero y agosto).

El propósito del modelado predictivo es sustituir la intuición comercial por un marco analítico riguroso, capaz de equilibrar la disponibilidad de producto en tienda y minimizar tanto el costo de almacenamiento como las pérdidas por liquidación forzada.

2.2. Estructura de Mercado y Competencia

El mercado de la moda en Chile alcanzó en 2024 un valor de alrededor de USD 5.393 millones con una proyección de crecimiento del 4,31 % anual (Expert Market Research, 2025; Instituto Textil de Chile, 2025). El análisis se centra en el segmento Premium-Mass Market de vestuario femenino, donde la “Empresa X” compite con marcas internacionales (Zara, Mango) y actores locales consolidados bajo modelos de fast fashion y ciclos cortos de producto. Esta dinámica impone una alta sensibilidad al precio y una demanda muy elástica: cualquier error en la planificación de inventario puede corregirse mediante variaciones de precio, pero ello destruye margen bruto, por lo que la gestión de stock debe basarse en un pronóstico de volumen preciso.

2.3. Consumidores y Segmento Objetivo

2.3.1. Elasticidad, Ciclo de Vida del Producto y Perfil del Cliente

El vestuario femenino en este segmento se caracteriza por un ciclo de vida corto: el interés de las clientas por un modelo específico disminuye con rapidez al finalizar la temporada de vitrina. En términos prácticos, los volúmenes de venta de hace dos o tres años pierden relevancia frente al ritmo comercial del último trimestre y los descuentos planificados. Por esta razón, la arquitectura predictiva debe ser capaz de reaccionar ágilmente a la tracción reciente y a las decisiones comerciales ex-ante, evitando la inercia rígida de los promedios de largo plazo.

La “Empresa X” se dirige a mujeres entre 35 y 65 años de segmentos medios y altos (C2, ABC1), con un ticket promedio de \$73.459. Este perfil corresponde a un consumo de moda femenina que representó aproximadamente el 56 % de los ingresos del mercado de vestuario en Chile durante 2023 (Statista Research Department, 2025).

2.3.2. Patrones de venta de la empresa

La empresa estructura sus patrones de venta en torno a las cuatro estaciones del año: primavera, verano, otoño e invierno. En primavera, se observa un repunte de ventas entre octubre y noviembre, impulsado por la renovación de vestuario tras el invierno, eventos sociales como matrimonios y celebraciones, y el retorno laboral y académico, con especial énfasis en productos premium orientados a los segmentos medios y altos (C2, ABC1).

Durante el verano, destacan dos momentos clave: el periodo navideño (1 al 24 de diciembre), marcado por la compra de regalos y la tendencia al “autorregalo”, y el periodo post-navidad (enero y febrero), caracterizado por una caída sistemática en la actividad comercial. En otoño (marzo a mayo), la demanda responde al inicio del año laboral y académico, junto con el cambio de estación que impulsa la adquisición de prendas adaptadas a nuevas condiciones climáticas. Finalmente, en invierno (junio a agosto), las ventas se estabilizan con un énfasis en prendas de abrigo, mientras que a principios de septiembre se observa un repunte asociado a las celebraciones de Fiestas Patrias.

Este comportamiento revela una estacionalidad anual marcada y determinística, con dos picos anuales prominentes: el primero en mayo (asociado al Día de la Madre y la campaña de CyberDay Otoño-Invierno) y el segundo en noviembre-diciembre (tracción de Navidad y liquidación de temporada), separados por valles en febrero (post-Navidad) y junio (post-campaña de otoño-invierno y transición de temporada). Estos ciclos no son aleatorios, sino que responden a eventos calendario fijos, lo que justifica la incorporación de variables exógenas y dummies estacionales en la arquitectura del modelo predictivo.

Participación Estacional en el Volumen de Ventas Anual (Top 100 SKUs)




Figura 2.1: Distribución Estacional de las Ventas Anuales en la Empresa X (Waffle Chart)

Fuente: Elaboración propia.

2.4. Elasticidad y análisis del IPC en la industria




Figura 2.2: Evolución del IPC de la Subclase Vestuario Mujeres en Chile (Base 2023 = 100)

Fuente: Elaboración propia a partir de datos del INE (Instituto Nacional de Estadísticas (INE), 2024).

Para analizar los precios de la industria en Chile, se revisa el Índice de Precios al Consumidor (IPC) del grupo “Vestuario de mujeres”, publicado por el Instituto Nacional de Estadísticas (Instituto Nacional de Estadísticas (INE), 2024), entre enero de 2024 y julio de 2025. El análisis evidencia una alta volatilidad y una tendencia deflacionaria: por ejemplo, en febrero de 2025 se registró una variación positiva de 5,4 % (de 87,6 a 92,29), mientras que en junio de 2025 se observó una caída de -4,9 % (de 88,78 a 84,43). De manera similar, en junio de 2024 se presentó una variación de -5,9 % (de 94,88 a 89,26). Estos casos muestran que no se trata de fenómenos aislados, sino de un patrón recurrente en el segmento.

En términos generales, el índice pasó de 92,04 en enero de 2024 a 84,80 en julio de 2025, lo que representa un decrecimiento acumulado cercano al 8 %. Esta tendencia a la baja sugiere un mercado altamente competitivo, donde las empresas ajustan sus precios de manera constante para sostener volúmenes de venta. El patrón observado es compatible con una asociación inversa entre precios y volumen, aunque no permite identificar causalmente una elasticidad-precio: tan pronto como los precios se elevan, la demanda se contrae, lo que obliga a las empresas a aplicar descuentos o liquidaciones.

Implicancia para el modelado: este hallazgo sugiere que el precio contiene información predictiva relevante para la demanda. Por ello, un modelo univariado que solo considere la historia de ventas resulta insuficiente. Se hace indispensable incorporar variables de planificación comercial ex-ante, como el precio y el descuento vigente, de modo que la arquitectura de ensamble capture esta sensibilidad y corrija el pronóstico de unidades.

Capítulo 3

Revisión de Literatura y Marco Teórico

3.1. Fundamentos de la Demanda en Moda

En microeconomía aplicada, la demanda de vestuario responde fundamentalmente al precio, al ingreso disponible y a las preferencias de los consumidores (Nicholson and Snyder, 2015). En el retail de moda, sin embargo, los supuestos habituales de estabilidad en las funciones de demanda se quiebran con frecuencia: las colecciones tienen ciclos de vida de pocas semanas, la obsolescencia comercial es rápida y las ventas reaccionan con fuerza a las promociones y eventos de liquidación. Por ello, los modelos predictivos no pueden depender exclusivamente de la inercia de ventas pasadas, sino que requieren integrar las decisiones comerciales de precios y descuentos presupuestados.

3.2. Series de Tiempo y Propiedades en Retail

El análisis econométrico de series de tiempo (Gujarati and Porter, 2009) proporciona el marco para caracterizar procesos estocásticos, evaluar estacionariedad y modelar dependencias autorregresivas y de medias móviles (AR, MA, ARIMA). En la práctica del retail con catálogos multicategoría, estas series presentan una estructura jerárquica natural (Total Empresa $\rightarrow$ Familia de Producto $\rightarrow$ SKU).

La literatura clásica de pronóstico jerárquico (Hyndman et al., 2011; Wickramasuriya et al., 2019) propone métodos de reconciliación óptima (como MinT) que ajustan pronósticos independientes mediante matrices de covarianza de errores. No obstante, en catálogos de vestuario con alta rotación y fuerte intermitencia de ceros a nivel de producto, estimar matrices de covarianza completas resulta computacionalmente inestable y propenso a sobreajuste. Por esta razón, en esta investigación se implementa una estrategia Top-Down desacoplada: se modela la demanda agregada a nivel Familia y luego se distribuye hacia cada SKU mediante proporciones históricas estáticas calculadas en el período de entrenamiento, asegurando coherencia en el total y comparabilidad justa con los benchmarks. Adicionalmente, como extensión metodológica, se evaluó un motor de cuotas dinámicas supervisadas (*Learned Shares*), que sin embargo no superó al enfoque estático principal.

3.3. Modelos de Pronóstico y Métodos de Referencia

Se presentan los fundamentos teóricos de los paradigmas cuantitativos evaluados en esta investigación, abarcando modelos estadísticos clásicos, formulaciones especializadas para demanda intermitente, algoritmos de aprendizaje automático y arquitecturas de aprendizaje profundo.

3.3.1. Modelos ARIMA y SARIMA

El modelo ARIMA (AutoRegressive Integrated Moving Average) constituye el baseline estándar en la literatura para el análisis de series de tiempo no estacionarias. Se compone de tres parámetros: p (rezagos autorregresivos), d (diferenciaciones necesarias para estabilizar la serie) y q (orden del componente de medias móviles). El elemento de integración (“I”) permite transformar series no estacionarias en estacionarias mediante diferenciación, evitando problemas de regresiones espurias.

Si bien ARIMA y su extensión estacional (SARIMA) son eficaces para capturar estructuras lineales y patrones estacionales, su rigidez paramétrica limita el desempeño en contextos como el retail de moda, donde las series presentan ceros estructurales, intermitencia y cambios abruptos de régimen. Estas características hacen necesario complementar o superar el enfoque lineal con metodologías más flexibles.

3.3.2. Pronóstico de demanda intermitente

Modelo de Croston (1972)

El método de Croston (Croston, 1972) es el referente fundacional de la literatura para tratar series con alta proporción de ceros (demanda intermitente, véase §3.1). Los modelos autorregresivos clásicos como ARIMA tienden a fallar en este contexto porque asumen continuidad y estacionalidad estable, supuestos que se violan sistemáticamente ante la presencia de períodos sin transacciones. El aporte de Croston consiste en reconocer que este tipo de serie debe modelarse en dos componentes separados:

1. Intervalo entre demandas (p_t): Se define como el tiempo transcurrido (en períodos) desde la última demanda positiva.
2. Magnitud de la demanda (z_t): Corresponde al tamaño o volumen de la venta cuando esta ocurre, es decir, cuando $y_t > 0$. Formalmente, $z_t = y_t \mid y_t > 0$.

Para modelar cada serie descompuesta, el método aplica suavizamiento exponencial simple (SES) de forma separada. De esta forma, para calcular la estimación final del pronóstico de demanda (F_t), se utiliza un cociente entre la magnitud esperada de la demanda y el intervalo esperado entre demandas.

La fórmula del pronóstico se presenta a continuación:

$$F_t = \frac{\hat{z}_t}{\hat{p}_t} \quad (3.1)$$

El método planteado representa un avance significativo respecto a modelos tradicionales como ARIMA, ya que logra suavizar los ceros generando así una serie más estable lo cual es relevante en contextos donde la demanda es, por naturaleza, altamente volátil. Sin embargo, presenta limitaciones críticas que han impulsado el desarrollo de modelos más sofisticados, como aquellos basados en Machine Learning.

El método de Croston presenta un sesgo positivo conocido bajo determinadas condiciones de demanda intermitente (derivado de la estimación independiente del tamaño de la demanda y el intervalo entre eventos no nulos), lo que puede inducir sobreestimaciones del inventario de seguridad. Esta limitación motivó la formulación de la Aproximación de Syntetos-Boylan (SBA), la cual introduce un factor de corrección multiplicativo $(1 - \alpha/2)$ para mitigar el sesgo asintótico. No obstante, al tratarse de formulaciones univariadas basadas en promedios estáticos, continúan presentando limitaciones para capturar estacionalidad fuerte o integrar señales comerciales ex-ante.

Otra debilidad importante del modelo es su incapacidad para incorporar múltiples variables explicativas, esto porque es un modelo univariado. Por consiguiente, se basa exclusivamente en la serie temporal histórica de la demanda (y_t), lo que impide incluir variables exógenas que, dependiendo del contexto, pueden llegar a ser fundamentales para una predicción más certera.

Syntetos-Boylan Approximation (SBA)

Como se mencionó en la sección dedicada al modelo de Croston, la Aproximación de Syntetos-Boylan (SBA) surge como una corrección frente al sesgo que presenta dicho modelo. La problemática radica en que Croston puede generar un sesgo positivo asintótico en la estimación de la demanda real, debido a un sesgo positivo en sus estimaciones. Esta sobreestimación puede derivar en un exceso de inventario, lo que a su vez implica mayores costos para la empresa.

Para mitigar este sesgo, la Aproximación de Syntetos-Boylan (SBA; Syntetos and Boylan, 2005) propone la aplicación de un factor multiplicativo al pronóstico generado por el modelo de Croston. Dicho factor corresponde, en esencia, a una función del parámetro de suavizamiento (α). No obstante, el modelo continúa presentando limitaciones importantes, especialmente en su incapacidad para incorporar variables exógenas.

En términos matemáticos, lo que se plantea es lo siguiente:

$$\hat{F}_t = \left(1 - \frac{\alpha}{2}\right) \cdot F_t \quad (3.2)$$

donde $\hat{F}_t$ representa el pronóstico insesgado de la tasa de demanda para el período t , F_t es la tasa de demanda proyectada por el método clásico de Croston ($F_t = \hat{z}_t/\hat{p}_t$), y $\alpha \in (0, 1)$ es la constante de suavizamiento exponencial.

Two-Part Model (TPM) en Econometría

El planteamiento de la Aproximación de Syntetos-Boylan (SBA) representó un avance relevante, pero insuficiente para la incorporación de variables exógenas en modelos de predicción. En respuesta a esta limitación, surge el Two-Part Model (TPM), un enfoque híbrido especialmente diseñado para series de tiempo en las que la variable dependiente presenta alta intermitencia y una concentración significativa de ceros.

Este modelo fue formalizado por Cragg (1971) y posteriormente popularizado por Mullahy (1998). La idea central del TPM es modelar el valor esperado de la demanda, es decir, $\mathbb{E}[Y | X]$, mediante un proceso multiplicativo que se desarrolla en dos etapas independientes. Matemáticamente, dicho proceso se representa de la siguiente manera:

$$\mathbb{E}[Y | X] = P(Y > 0 | X) \cdot \mathbb{E}[Y | Y > 0, X] \quad (3.3)$$

donde Y representa la variable de demanda observada en unidades, X es el vector de covariables explicativas ex-ante, $P(Y > 0 | X)$ modela la probabilidad de que ocurra una venta positiva en el período (etapa de clasificación binaria), y $\mathbb{E}[Y | Y > 0, X]$ cuantifica el volumen esperado condicional a que la demanda sea no nula (etapa de regresión truncada).

Como se observa en la formulación matemática, existen dos componentes relevantes:

1. Clasificación: Es un modelo binario que estima la probabilidad de que ocurra una venta positiva ($P(y_t > 0)$).
2. Regresión condicional: Modelo de regresión el cual tiene como objetivo estimar la magnitud de la demanda dado que ocurrió una transacción positiva ($\mathbb{E}[y_t | y_t > 0]$).

El TPM aporta el marco teórico para entender la intermitencia como un proceso de dos etapas, la ocurrencia y la magnitud, un principio que inspira el tratamiento de ceros en la arquitectura de ensamble propuesta en esta tesis, aunque esta se implementa como un modelo de una sola etapa sobre la escala logarítmica, y no como un TPM formal de dos etapas.

3.3.3. Modelos de Series de Tiempo con Regresores Exógenos (SARIMAX)

En contraste con modelos puramente autorregresivos, como por ejemplo ARIMA, los modelos con regresores exógenos buscan capturar asociaciones predictivas entre la demanda y un conjunto de variables explicativas. Esto permite que los modelos con regresores exógenos incorporen factores externos que influyen directamente en el comportamiento de la demanda.

En retail, la relación canónica puede expresarse como:

$$Y_t = \beta_0 + \beta_1 P_t + \beta_2 I_t + \epsilon_t \quad (3.4)$$

donde Y_t es la demanda agregada, P_t representa el nivel de precio (siendo β_1 el coeficiente asociado a la sensibilidad o elasticidad precio), I_t corresponde a indicadores macroeconómicos de actividad (e.g., IMACEC o IPC) o de calendario. Una de las ventajas de este enfoque es su interpretabilidad, ya que permite comprender cómo cada variable incide en la demanda, dando la posibilidad de realizar un análisis más profundo.

3.3.4. Machine Learning

El Machine Learning (ML) es una alternativa robusta a los modelos tradicionales. A diferencia de estos, los modelos de ML aprenden automáticamente a partir de los datos, lo que les permite capturar relaciones complejas, no lineales y de alta dimensionalidad. Su capacidad multivariable resulta especialmente valiosa en el retail de moda, donde la demanda depende simultáneamente de factores como precios, promociones, estacionalidad e indicadores macroeconómicos.

Dentro de los algoritmos más utilizados destacan los modelos basados en árboles de decisión, como por ejemplo XGBoost (Extreme Gradient Boosting), enfoque que ofrece ventajas relevantes como:

- Captura relaciones no lineales sin necesidad de especificar la forma funcional a priori.
- Maneja naturalmente valores perdidos y la intermitencia sin requerir imputaciones agresivas.
- Es robusto frente a la multicolinealidad, permitiendo incluir múltiples variables correlacionadas (rezagos, medias móviles, indicadores externos) para maximizar la señal predictiva.

Estas propiedades convierten a XGBoost en un candidato sólido para complementar o superar los modelos lineales, ofreciendo una arquitectura flexible y adaptada a la complejidad del mercado de moda.

3.3.5. Deep Learning en Series Temporales: Redes LSTM

A diferencia de los modelos previamente mencionados, las Redes Neuronales (RN) están diseñadas específicamente para trabajar con datos secuenciales, lo que les permite mantener la información mediante bucles de retroalimentación. Si bien este enfoque resulta muy útil para capturar patrones en el corto plazo, presenta una desventaja en el largo plazo, ya que limita su capacidad para aprender dependencias temporales más extensas.

Con el objetivo de mitigar esta limitación, Hochreiter and Schmidhuber (1997) crearon un modelo donde introdujeron las redes de Memoria a Corto y Largo Plazo (LSTM). Esta arquitectura incorpora una estructura que decide explícitamente qué información retener y cuál descartar a lo largo de la secuencia.

En el contexto del forecasting de demanda, las LSTM ofrecen una ventaja teórica significativa, pues son capaces de modelar relaciones no lineales complejas y patrones estacionales de largo alcance

sin la necesidad de diseñar manualmente un conjunto extenso de variables temporales (como la creación de rezagos específicos). No obstante, la literatura sugiere que su desempeño es altamente dependiente del volumen y la densidad de los datos, presentando desafíos de sobreajuste (overfitting) en escenarios de “Small Data” (muestras con pocas observaciones por serie, comparado con los volúmenes habituales de series de tiempo macroeconómicas) o series con alta intermitencia.

Hay que destacar que la teoría indica que el LSTM puede prescindir de lags en contextos de intermitencia extrema. Sin embargo, en escenarios de Small Data se recomienda preprocesar la señal de rezagos para mejorar la estabilidad del gradiente.

3.4. Métricas de Evaluación de Desempeño y Criterios de Selección

Para evaluar, calibrar y comparar rigurosamente el desempeño predictivo de los modelos sobre series de tiempo en retail, se requiere una taxonomía multidimensional de métricas que capture tanto la precisión física como el impacto financiero en inventarios. En esta investigación se estructuran tres categorías de indicadores: errores de escala absoluta, errores porcentuales ponderados y métricas de calibración y ajuste.

3.4.1. Métricas de Escala Absoluta: MAE y RMSE

Las métricas de escala absoluta cuantifican la magnitud de las desviaciones en las mismas unidades físicas de la demanda observada (unidades de prendas vendidas):

1. **Mean Absolute Error (MAE):** Mide la desviación absoluta promedio entre los valores observados y las estimaciones del modelo:

$$\text{MAE} = \frac{1}{n} \sum_{t=1}^n |y_t - \hat{y}_t| \quad (3.5)$$

donde y_t es la demanda real observada en el período t , $\hat{y}_t$ es la proyección puntual generada por el modelo, y n corresponde al número total de observaciones temporales evaluadas. Su principal atributo es la interpretabilidad operacional directa para los equipos de logística y planificación de tienda.

2. **Root Mean Squared Error (RMSE):** Penaliza de manera cuadrática las desviaciones individuales, otorgando mayor sensibilidad a los errores de gran magnitud:

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{t=1}^n (y_t - \hat{y}_t)^2} \quad (3.6)$$

donde y_t representa el valor observado, $\hat{y}_t$ la estimación del modelo y n el tamaño muestral. Esta propiedad resulta fundamental en retail, donde los desvíos extremos provocan quiebres críticos de stock o acumulación masiva de inventario inmovilizado.

3.4.2. Métricas Porcentuales: Limitaciones del MAPE y Ventaja Estructural del WAPE

Al comparar categorías o SKUs con volúmenes de venta heterogéneos, es habitual recurrir a indicadores porcentuales relativos:

1. Mean Absolute Percentage Error (MAPE):

$$\text{MAPE} = \frac{1}{|T_+|} \sum_{t \in T_+} \left| \frac{y_t - \hat{y}_t}{y_t} \right| \times 100 \% \quad (3.7)$$

donde y_t es la demanda observada, $\hat{y}_t$ el pronóstico y $T_+ = \{t : y_t > 0\}$ representa el conjunto de períodos con demanda estrictamente positiva. En demanda intermitente a nivel SKU, el MAPE tradicional se indetermina matemáticamente ante $y_t = 0$. En el pipeline de evaluación de este trabajo, el MAPE se calcula de forma condicional sobre las observaciones con $y_t > 0$; sin embargo, continúa siendo altamente sensible y no acotado cuando la demanda real positiva es reducida (denominadores pequeños).

2. Weighted Absolute Percentage Error (WAPE):

Como solución estructural, el WAPE (también conocido como MAD/Mean Ratio) pondera cada período según su peso real en el volumen global del catálogo:

$$\text{WAPE} = \frac{\sum_{t=1}^n |y_t - \hat{y}_t|}{\sum_{t=1}^n y_t} \times 100 \% \quad (3.8)$$

donde $|y_t - \hat{y}_t|$ es la desviación absoluta entre la demanda real y el pronóstico en el mes t , $\sum y_t$ representa el volumen total efectivamente vendido en unidades, y n corresponde al número de períodos del horizonte de evaluación. **Interpretación Operativa de la Métrica Rectora:** En el retail de moda intermitente, las métricas relativas punto a punto presentan severas distorsiones ante valores unitarios pequeños. El **WAPE** resuelve integralmente esta limitación sumando todos los errores absolutos y dividiéndolos por el volumen total comercializado. De este modo, constituye la **métrica rectora de decisión** en este estudio, ya que es inmune a divisiones por cero a nivel producto y refleja con exactitud el descalce global entre el inventario abastecido y la demanda del período.

3.4.3. Métricas de Calibración y Bondad de Ajuste: Bias y R^2

1. **Sesgo Porcentual (*Bias*):** Cuantifica la tendencia sistemática del modelo a sobrestimar (valor positivo) o subestimar (valor negativo) la demanda:

$$\text{Bias} = \frac{\sum_{t=1}^n (\hat{y}_t - y_t)}{\sum_{t=1}^n y_t} \times 100 \% \quad (3.9)$$

donde un valor positivo indica sobreestimación sistemática de demanda (riesgo de sobrestock) y un valor negativo subestimación (riesgo de quiebre). Un modelo de pronóstico de alta calidad debe balancear un bajo WAPE con un sesgo cercano a 0%.

2. **Coeficiente de Determinación (R^2):** Evalúa la proporción de la varianza total de la demanda explicada por el modelo:

$$R^2 = 1 - \frac{\sum_{t=1}^n (y_t - \hat{y}_t)^2}{\sum_{t=1}^n (y_t - \bar{y})^2} \quad (3.10)$$

donde $\sum (y_t - \hat{y}_t)^2$ es la suma de cuadrados residuales y $\sum (y_t - \bar{y})^2$ la variabilidad total de la serie respecto a su media $\bar{y}$. Utilizado complementariamente para diagnosticar la capacidad explicativa en modelos econométricos autorregresivos.

3.4.4. Métricas Jerárquicas Escaladas: Weighted Root Mean Squared Scaled Error (WRMSSE)

En competencias de pronóstico jerárquico a gran escala en retail (notablemente en la competencia *M5 Forecasting Competition*; Makridakis et al., 2022), se utiliza el error escalado ponderado cuadrático medio (**WRMSSE**) como métrica estándar independiente de la escala física de venta. A nivel individual para una serie o SKU k , el *Root Mean Squared Scaled Error* (RMSSE) se define como:

$$\text{RMSSE}_k = \sqrt{\frac{\frac{1}{H} \sum_{t=T+1}^{T+H} (y_{k,t} - \hat{y}_{k,t})^2}{\frac{1}{T-m} \sum_{t=m+1}^T (y_{k,t} - y_{k,t-m})^2}} \quad (3.11)$$

donde el numerador cuantifica el error cuadrático medio en la ventana de pronóstico fuera de muestra (H), y el denominador representa el error del benchmark *Naïve* estacional calculado sobre el historial de entrenamiento (T), con $m = 12$ para datos mensuales (desfase estacional).

A nivel agregado jerárquico, el **WRMSSE** consolida las K series ponderando el RMSSE de cada producto por su peso económico relativo en valor monetario de ventas (w_k):

$$\text{WRMSSE} = \sum_{k=1}^K w_k \cdot \text{RMSSE}_k, \quad \text{donde } w_k = \frac{\sum_{t=1}^T p_{k,t} y_{k,t}}{\sum_{j=1}^K \sum_{t=1}^T p_{j,t} y_{j,t}} \quad (3.12)$$

donde WRMSSE es el error escalado ponderado cuadrático medio, RMSSE_k es el error de la serie k estandarizado por el benchmark Naïve, w_k es la participación monetaria del producto k , y $p_{k,t}y_{k,t}$ representa el ingreso por ventas en CLP. Esta formulación penaliza cuadráticamente los errores en aquellos productos de mayor impacto financiero, permitiendo evaluar la calidad global del pronóstico a lo largo de toda la jerarquía de retail de forma robusta e invariante a la escala.

3.5. Rolling-Origin como metodología de validación en pronósticos de demanda

3.5.1. Definición de metodología

De acuerdo con la literatura seminal sobre evaluación de pronósticos fuera de muestra (Tashman, 2000; Hyndman and Athanasopoulos, 2018), la metodología de evaluación con *Rolling Origin* es un protocolo dinámico de validación temporal cuyo propósito es desplazar iterativamente el umbral temporal de corte, manteniendo las proyecciones ancladas estrictamente a la información disponible previa al periodo pronosticado. Este enfoque replica de forma fiel el entorno operativo real de una empresa de retail, asegurando que los modelos se enfrenten a condiciones realistas de incertidumbre.

Esta técnica se caracteriza por no contar con un punto de origen fijo, sino por desplazarse progresivamente en el tiempo, incorporando datos reales recientes extendiendo el horizonte de proyección hacia el futuro.

3.5.2. Beneficios, desafíos y limitaciones

La metodología Rolling-Origin, presenta diversas ventajas frente a los enfoques tradicionales de pronóstico. Entre ellas destaca la capacidad de mantener la relevancia del modelo y la actualidad de las proyecciones mediante la incorporación de información de períodos emergentes al conjunto de datos históricos, permitiendo que la planificación y proyección no se basen en supuestos obsoletos, lo que permite entrenar al modelo en un entorno similar a uno operativo.

Esta metodología también presenta desafíos y limitaciones. En primer lugar, requiere una adecuada disponibilidad de datos; si no se logra estandarizar el proceso de extracción y validación de la información, con todo lo que ello implica, la consecuencia puede ser una afectación significativa en la validez del pronóstico. Otro desafío es el alto costo computacional, pues en su formulación canónica cada desplazamiento del origen implica reentrenar el modelo. Esto, en situaciones de Big Data, exige una capacidad computacional considerable.

Nota de implementación: En la arquitectura ES-GBM propuesta en esta investigación, esta metodología se aplica de forma híbrida: el componente estadístico de nivel (Holt amortiguado) se actualiza secuencialmente en cada paso $h = 1$ incorporando la historia observada hasta $t - 1$, mientras que

los módulos de Machine Learning (ensamble GBDT, ponderaciones NNLS y proporciones de desagregación Top-Down) mantienen sus pesos congelados sobre todo el horizonte de prueba, conforme al protocolo de calibración detallado en el Capítulo 4. Esta decisión reduce el costo computacional y somete la arquitectura a una prueba de estrés realista de estabilidad temporal.

3.5.3. Aplicaciones del Rolling-Origin en el contexto de retail

Para fundamentar esta sección, se recurre a la literatura sobre evaluación y modelos dinámicos adaptativos (Svetunkov, 2023). El autor señala que un aspecto crítico en el pronóstico de series temporales es la evaluación rigurosa fuera de la muestra (out-of-sample). Si dicha evaluación se realiza sobre un único corte fijo, existe el riesgo de que anomalías locales o eventos atípicos distorsionen la medición del desempeño predictivo.

Con el objetivo de mitigar esta limitación, Svetunkov (2023) destaca la relevancia del método Rolling-Origin, en el cual, como se ha mencionado anteriormente, el punto de origen se desplaza de forma continua, generando nuevas estimaciones a través de iteraciones sucesivas. Este enfoque permite recalibrar los modelos, logrando una representación más confiable y robusta de los sistemas de predicción.

Explicar lo anterior resulta pertinente, ya que se trata de una herramienta especialmente valiosa en el retail de moda. En este sector, los patrones de venta están en constante transformación debido a factores como la estacionalidad, el lanzamiento de nuevas colecciones, las promociones y eventos especiales, tales como Cyber Day o Black Friday. Estas condiciones hacen que la metodología Rolling Origin permita desarrollar modelos con mayor fiabilidad y precisión, al adaptarse mejor a escenarios reales y dinámicos.

3.6. Otros estudios

3.6.1. Short-term salmon price forecasting

Es pertinente analizar otros casos de estudio para comprender los modelos actuales y los resultados que pueden obtenerse. El primer trabajo a considerar es el de Bloznelis (2018), titulado Short-term salmon price forecasting, el cual se enfoca en la predicción de precios del salmón en el mercado internacional. Aunque el contexto difiere del sector de la moda femenina que se abordará posteriormente, ambos mercados comparten ciertos elementos, como una estacionalidad marcada y una dinámica de corto plazo que incide directamente en la oferta y la demanda. Por ello, este estudio resulta útil para evaluar distintos métodos de pronóstico en contextos caracterizados por su complejidad y alta incertidumbre.

Para abordar la predicción de precios, se trabajó con series temporales del valor del salmón. El objetivo fue anticipar a corto plazo las variaciones que resultan fundamentales para productores,

comerciantes y exportadores. Se emplearon enfoques econométricos clásicos, como el modelo ARIMA, con el propósito de capturar patrones históricos, tendencias, volatilidad y heterocedasticidad de los precios. Además, se incorporaron técnicas de Machine Learning, lo que permitió identificar relaciones no lineales en los datos y mejorar la precisión de las predicciones en comparación con los modelos tradicionales.

En el estudio se compararon distintas metodologías, dejando evidencia explícita de que los enfoques basados en inteligencia artificial superan el desempeño de los modelos estadísticos convencionales, principalmente debido a su capacidad para captar la alta volatilidad del mercado. No obstante, esto no resta relevancia a los modelos clásicos, los cuales aportan interpretabilidad y constituyen una base sólida para comprender tanto los modelos predictivos como la dinámica de las series temporales. Al trasladar este análisis al presente trabajo, cuyo contexto es la industria de la moda, resulta especialmente pertinente, ya que los patrones de venta están influenciados por la estacionalidad (colecciones de primavera, verano, otoño e invierno), así como por shocks externos, tales como promociones o fechas especiales.

También se enfatiza la importancia de incorporar variables exógenas en los modelos, con el fin de mejorar la capacidad predictiva y construir modelos más robustos. Este enfoque será considerado en el presente trabajo, ya que se propone incluir variables externas como el Índice de Precios al Consumidor (IPC). Se reconoce que un modelo basado únicamente en series históricas puede resultar insuficiente, y que el uso de modelos con regresores exógenos es esencial para elevar la calidad de las predicciones.

Como punto final, es importante considerar la comparación entre distintos modelos, ya que no existe uno que sea universalmente superior. Por ello, resulta relevante contrastar diversas metodologías con el fin de seleccionar aquella que ofrezca el mejor desempeño predictivo. La capacidad explicativa de un modelo dependerá en gran medida de la naturaleza de los datos y del horizonte de predicción considerado.

3.6.2. Modelo de previsión de demanda de productos en retail fast fashion (2024)

El siguiente trabajo de investigación directamente vinculado al sector es el estudio titulado "Modelo de previsión de demanda de productos en retail fast fashion"(2024), de Conde Langa (2024). La investigación se enfoca en la predicción de la demanda dentro de la moda rápida, un mercado caracterizado por la volatilidad de tendencias, corta vida útil de los productos y alta sensibilidad a factores exógenos.

Si bien existen particularidades operativas distintas, ambos estudios comparten desafíos estructurales: marcada estacionalidad, ciclos de vida cortos y una fuerte exposición a fluctuaciones del entorno comercial.

La investigación de Conde Langa diseñó un modelo de predicción a corto plazo aplicable a

escenarios reales de negocio. Para ello, propuso un enfoque híbrido compuesto por dos componentes: uno macro, orientado a proyectar variables agregadas del entorno y tráfico en tiendas; y otro micro, que integra atributos específicos de los productos junto con factores comerciales.

Este marco metodológico surge del reconocimiento de que aproximadamente el 98% de los ítems presenta un comportamiento de demanda errático o intermitente, lo que limita severamente la eficacia de los modelos clásicos de series temporales univariadas.

Al contrastar modelos estadísticos tradicionales (como ARIMA) frente a árboles de decisión y redes neuronales, el estudio reafirma que las técnicas de Machine Learning ofrecen una precisión superior al identificar relaciones no lineales y admitir múltiples variables exógenas.

Asimismo, el autor subraya la relevancia de contar con modelos robustos que permitan balancear los costos asimétricos del retail: el riesgo de quiebre de stock frente al sobre costo por exceso de inventario. Esta evidencia respalda la decisión de la presente tesis de utilizar señales comerciales ex-ante y arquitecturas avanzadas de ensamble para optimizar la planificación de inventarios.

Capítulo 4

Metodología y Formulación de Modelos

Este capítulo formaliza la metodología cuantitativa y las decisiones de diseño de la batería de modelos evaluada. El objetivo central es la predicción operativa fuera de muestra ($h = 1$) para la gestión de compras e inventarios, no la inferencia causal estructural de elasticidades de largo plazo. En este marco, las variables comerciales ex-ante (precio y tasa de descuento presupuestadas en el ERP) se integran como señales informativas disponibles antes de la realización del mes, aprovechando el plan promocional de la empresa para anticipar los cambios de volumen.

4.1. Microestructura de los Datos y Análisis Exploratorio

El estudio se fundamenta en los registros transaccionales extraídos del sistema ERP de la empresa, abarcando 68 meses continuos de operación comercial entre enero de 2020 y agosto de 2025, divididos en 51 meses de entrenamiento histórico (enero 2020–marzo 2024), 10 meses de validación (abril 2024–enero 2025) y 7 meses de evaluación fuera de muestra (febrero–agosto 2025). El catálogo activo del período comprende un total de **1.457 SKUs** distribuidos en 3 Superfamilias y 58 Familias comerciales. De ellos, se seleccionaron ex-ante los **100 SKUs de mayor volumen de unidades vendidas** (Top-100), que concentran la mayor parte de la facturación y para los cuales la muestra histórica proporciona series con suficiente soporte estadístico. Los 1.357 SKUs restantes —de baja rotación y alta intermitencia— quedan fuera del alcance de este estudio y se plantean como línea de trabajo futuro.

Nota de Confidencialidad y Escalado de Datos: Por motivos de secreto comercial y acuerdos de confidencialidad corporativa con el retailer, las series de montos monetarios y unidades físicas reportadas han sido anonimizadas y escaladas linealmente mediante un factor proporcional común, preservando con total fidelidad las variaciones porcentuales, elasticidades, estacionalidades y métricas relativas (WAPE, MAPE, R^2). Las estimaciones de impacto financiero del Capítulo 6 (capital de trabajo, stock de seguridad, ahorro de *holding costs*) fueron reconvertidos a unidades y montos reales utilizando los parámetros de costeo del negocio para representar de forma fidedigna el impacto económico del proyecto.

4.1.1. Protocolo de Regularización Temporal e Inserción de Ceros (*Zero-Filling*)

En los sistemas transaccionales del retail, las ventas se registran únicamente cuando ocurre una transacción. Si un producto no tiene ventas durante un mes, la tabla transaccional del ERP no guarda un registro con valor cero, sino que simplemente omite la fila. Para construir series temporales continuas y calcular rezagos ($t - 1, t - 2, \dots$) o medias móviles de forma consistente, se aplicó un procedimiento de **regularización de grilla temporal e inserción de ceros (*Zero-Filling*)**: se generó el producto cartesiano de todos los meses de la muestra para cada SKU y Familia, asignando explícitamente $y_{i,t} = 0$ en los períodos sin movimiento.

A continuación se caracterizan los patrones estructurales observados en las series tras esta regularización.

4.1.2. Dinámica Temporal, Estacionalidad y Concentración de Demanda

El diagnóstico exploratorio de las series temporales de la empresa permitió identificar cuatro patrones cuantitativos estructurales determinantes en el comportamiento del negocio:




Figura 4.1: Evolución del Monto Neto de Ventas Mensuales en Catálogo Estratégico (Año 2024)

Fuente: Elaboración propia.

1. **Estacionalidad Bimodal Marcada:** La demanda presenta dos picos anuales prominentes: el primero en mayo (asociado al Día de la Madre y la campaña de CyberDay Otoño-Invierno) y el

segundo en noviembre-diciembre (tracción de Navidad y liquidación de temporada), separados por valles pronunciados en febrero y junio.

2. **Intermitencia y Dispersión de Ceros a Nivel SKU:** Mientras que a nivel agregado de Familia las series son relativamente densas y continuas, a nivel desagregado de SKU el 34,8 % de los meses presenta demanda nula ($y_{i,t} = 0$), debido a ciclos de vida de producto reducidos y agotamiento transitorio de inventario.
3. **Concentración de Facturación (Estructura de Pareto):** El catálogo evidencia una fuerte asimetría comercial: los 100 SKUs analizados (pertenecientes a 58 Familias activas) concentran más del 72 % del volumen total de ventas físicas de la Empresa X.
4. **Alta Sensibilidad Promocional Ex-Ante:** Las variaciones intramensuales en la tasa de descuento presupuestada se asocian con variaciones de hasta un 140 % en el volumen vendido, justificando la incorporación del vector comercial ex-ante como covariable rectora.

Durante las fases preliminares de experimentación, el protocolo anti-leakage requirió un riguroso proceso de depuración iterativa. En versiones iniciales del pipeline se detectaron variables derivadas que filtraban inadvertidamente información de la demanda hacia el período de evaluación fuera de muestra. La subsanación de estas fugas demandó sucesivas auditorías de código hasta asegurar de forma determinista que ninguna característica dependiera de información posterior al momento estricto de la predicción ($t - 1$). Este control reforzó la necesidad de auditar sistemáticamente la integridad temporal de todo el flujo de datos.

4.2. Diseño de la Batería Experimental y Criterios de Selección

La batería de modelos evaluada en esta investigación no busca agotar el catálogo de algoritmos existentes, sino estructurar un diseño experimental que permita contrastar, bajo un mismo protocolo de evaluación fuera de muestra, cuatro generaciones metodológicas en el pronóstico de demanda de retail. Cada modelo seleccionado responde a una hipótesis operativa sobre la naturaleza del proceso generador de datos: inercia estacional, ajuste por intermitencia de ceros, sensibilidad a co-variables comerciales de planificación, captura de relaciones no lineales o capacidad de transferencia de conocimiento en modelos fundacionales temporales y tabulares.

Durante la etapa exploratoria se descartaron arquitecturas con sobreparametrización respecto a la longitud muestral mensual (como *Temporal Fusion Transformers* o N-BEATS), privilegiando la parsimonia, la estabilidad de estimación en series de 68 meses y la viabilidad computacional en un entorno operativo de retail. Cada generación sucesiva en la Tabla 4.1 relaja un supuesto restrictivo del nivel anterior (inercia pura, linealidad, continuidad sin ceros o estimación univariada aislada), permitiendo aislar con precisión qué componente metodológico aporta al desempeño final.

Tabla 4.1: Taxonomía, Rol Experimental e Hipótesis de la Batería de Modelos

Generación	Modelo	Referencia	Rol e Hipótesis Experimental
1. Líneas Base	Seasonal Naïve / Holt amortiguado	Box et al. (2015); Hyndman and Athanasopoulos (2018)	Piso inercial estacional y anclaje de nivel estructural.
2. Econometría Clásica	SARIMA / SARI-MAX	Box et al. (2015)	Dinámica autorregresiva lineal y modelamiento de la sensibilidad a precios ex-ante.
3. Intermitencia y Ceros	Croston / SBA	Croston (1972); Syntetos and Boylan (2005)	Desacoplamiento de ocurrencia de ceros y magnitud de demanda.
4. ML y Fundacionales	XGBoost, LightGBM, CatBoost / Chronos / TabPFN	Chen and Guestrin (2016); Ansari et al. (2024); Hollmann et al. (2025)	Relaciones no lineales, interacciones complejas y transferencia <i>zero-shot</i> .
Arquitectura Propuesta	ES-GBM + Desagregación Top-Down	Esta memoria	Desacoplamiento jerárquico Familia-SKU con cuotas estáticas.

Fuente: Elaboración propia.




Figura 4.2: Evolución Metodológica de la Batería de Referencia y Rol en el Diseño Experimental

Fuente: Elaboración propia.

Tal como sintetiza la Figura 4.2, la progresión metodológica no persigue una noción de superioridad algorítmica por novedad cronológica, sino una relajación estructurada de supuestos: desde la inercia determinista y la continuidad lineal hasta la captura de señales comerciales no lineales y la transferencia *zero-shot*. En este marco, el aporte de la arquitectura propuesta ES-GBM no consiste en descartar las herramientas clásicas, sino en integrar el anclaje estructural inercial de Holt amortiguado con la capacidad no lineal de los ensambles GBDT (Gradient Boosted Decision Trees) y una desagregación jerárquica hacia el nivel micro de SKU.

4.3. Configuración y Arquitectura del Modelo SARI-MA (Univariado)

Dentro de los modelos clásicos implementados en esta investigación se encuentra el modelo SARI-MA (Seasonal AutoRegressive Integrated Moving Average; Box et al., 2015). Si bien el marco teórico general aborda los modelos ARIMA, la dinámica comercial del sector moda exhibe patrones estacionales anuales claramente definidos (picos en mayo —Día de la Madre— y noviembre-diciembre —Navidad y liquidación de temporada—). Por consiguiente, resulta metodológicamente relevante extender el modelo para capturar de manera explícita estos componentes estacionales. A continuación, se describen los tratamientos aplicados al modelo:

4.3.1. Preprocesamiento y Estabilización de Varianza

Dada la complejidad inherente a la naturaleza de los datos, se diseñó un pipeline de preprocesamiento secuencial con el propósito de acondicionar la serie antes de su modelado autorregresivo

1. Garantía de Frecuencia Temporal: Para satisfacer los requisitos de continuidad matemática que es un supuesto crítico del modelo, se forzó una frecuencia mensual estricta. Los períodos sin transacciones históricas se imputaron con valor cero, preservando la estructura secuencial necesaria para el cálculo de rezagos.
2. Transformación Logarítmica (Log1p): Se aplicó una transformación no lineal $y'_t = \ln(1 + y_t)$. Esta técnica cumple un doble propósito crítico: contribuir a estabilizar la varianza, reduciendo el impacto de outliers; las proyecciones se reconvierten posteriormente a la escala original, aplicándose un ajuste de clipping para garantizar valores no negativos.

4.3.2. Formulación Matemática del Modelo SARIMA

El modelo se especifica como un $\text{SARIMA}(p, d, q) \times (P, D, Q)_{12}$ con $s = 12$ meses para capturar la estacionalidad anual completa de la moda. La formulación formal y la definición de los operadores polinomiales AR/MA regulares y estacionales se detallan en el Anexo A.7.

4.3.3. Configuración de parámetros (Arquitectura Global)

A diferencia de una búsqueda individual de órdenes por cada producto (que resultaría computacionalmente ineficiente dado el esquema de validación iterativa), se estableció una especificación SARIMA global y parsimoniosa para todo el conjunto de datos.

Basado en el análisis de la función de autocorrelación y autocorrelación parcial de la demanda agregada, se definió la especificación SARIMA $(1,1,1) \times (1,1,1)_{12}$:

- Componente Regular (1,1,1): Incorpora un término autorregresivo ($p=1$) para capturar la memoria inmediata, una diferenciación ($d=1$) para corregir la tendencia estocástica, y un término de media móvil ($q=1$) para ajustar el error de corto plazo.
- Componente Estacional (1,1,1)₁₂: Captura la periodicidad anual con un término autorregresivo estacional ($P=1$), una diferenciación estacional ($D=1$) y un término de media móvil estacional ($Q=1$), fundamentales para modelar la recurrencia estacional de colecciones climáticas y eventos comerciales (ej. Navidad y Día de la Madre).

4.3.4. Estrategia de Validación

El modelo emplea una estrategia de validación Rolling-Origin, en la cual se reentrena iterativamente expandiendo la ventana temporal. En cada iteración se realizan predicciones de un paso adelante ($t+1$) y se revierte la transformación logarítmica mediante la función exponencial, con el fin de calcular las métricas de error (WAPE, RMSE) en la escala original de unidades.

4.4. Configuración y Arquitectura del Modelo SARI-MAX (Regresores Exógenos)

Como extensión natural del modelo base, se implementa una arquitectura SARIMAX (Seasonal AutoRegressive Integrated Moving Average with eXogenous regressors). Este enfoque postula que las fluctuaciones de venta que pueden explicarse, en parte, por variables exógenas observadas o planificadas (variables comerciales ex-ante). A continuación, se describen los tratamientos aplicados al modelo:

4.4.1. Selección de Variables Exógenas y Anti-Leakage

La selección de regresores (X_t) se realizó priorizando indicadores que afectan el poder adquisitivo y el comportamiento de compra. La especificación final incluye **únicamente**:

1. Precio Estimado (P_t^{plan}): Disponible ex-ante en el período t por estar congelado en el plan comercial presupuestario antes del inicio del horizonte de predicción.
2. Descuento Promedio (D_t^{plan}): Disponible ex-ante en el período t por estar congelado en el plan comercial presupuestario antes del inicio del horizonte de predicción.

Nota sobre covariables descartadas: Si bien se evaluó inicialmente un conjunto amplio de variables exógenas (calendario comercial, IMACEC Comercio, IPC, Tipo de Cambio, Tasa de Desempleo e

'Índice de Confianza del Consumidor'), la especificación final de SARIMAX reportada en los resultados incorporó **únicamente precio planificado y descuento planificado**, debido a restricciones de parsimonia y estabilidad de estimación en un modelo con 4 parámetros ARMA y 2 coeficientes exógenos.

Rigor Metodológico (Prevención de Fuga de Datos):

Dado que las variables de ventas históricas se observan con rezago temporal, se aplicó un desplazamiento obligatorio ($\text{shift}(1)$) a todas las variables derivadas de ventas observadas ($t - 1$), mientras que las variables del plan comercial presupuestario (precio de catálogo y descuento programado) se incorporaron en el período t al estar congeladas ex-ante antes del inicio del período de predicción. Matemáticamente, el vector de regresores se define como: $X_t = (P_t^{\text{plan}}, D_t^{\text{plan}})$, operacionalizando que el modelo sea operativo en tiempo real, utilizando únicamente información disponible al momento de la inferencia.

4.4.2. Formulación Matemática del Modelo SARIMAX

El modelo SARIMAX extiende la formulación SARIMA al incorporar una combinación lineal de covariables exógenas como regresores externos, con la misma especificación estacional $(1, 1, 1) \times (1, 1, 1)_{12}$. La formulación formal y la corrección de sesgo por transformación logarítmica (bias correction) se detallan en el Anexo A.8.

4.4.3. Estrategia de Validación y Top-Down

Se mantiene la estrategia de Rolling-Origin (Walk-Forward Validation). El modelo se reentrena mensualmente, incorporando los nuevos datos reales y los valores actualizados de las variables exógenas, simulando así el ciclo de planificación real de la compañía. Además, el modelo hace uso de la técnica Top-down, en la cual se desagrega desde el nivel Familia hasta el nivel SKU, basándose en proporciones históricas de unidades vendidas.

4.5. Configuración y Formulación de la Arquitectura Jerárquica Híbrida ES-GBM

Supuestos del Modelo. La arquitectura ES-GBM opera bajo dos supuestos fundamentales que condicionan la interpretación de los resultados:

1. **Regla ex-ante de exclusión de Familias descontinuadas:** Si una Familia comercial acumuló cero unidades vendidas durante la totalidad de los últimos 12 meses observables antes del punto de corte de entrenamiento ($\text{CUT} = 2025-01-01$), se clasifica como descontinuada o inactiva. En consecuencia, su vector de predicción para todo el horizonte de prueba se asigna automáticamente a cero, evitando la fuga de datos (*data leakage*).

2. **Precio ex-ante congelado:** El precio de lista (`Precio_Estimado`) es una variable planificada, fijada en el ERP antes del inicio del período de venta. Las variaciones de precio observadas intra-mes responden a tratos comerciales predefinidos, descuentos programados o reacciones competitivas anticipadas, y no son una función de la demanda realizada. Por ello se clasifica como covariable ex-ante en tiempo t y no requiere rezago temporal anti-leakage.

Protocolo de Calibración y Evaluación Fuera de Muestra (*Out-of-Sample*): La evaluación empírica sobre el período de prueba ciego (febrero–agosto de 2025, $h = 1 \dots 7$ meses) se estructura bajo un protocolo riguroso de **calibración pre-test y despliegue con pesos congelados**, complementado por una actualización secuencial del componente estadístico base. Se definen dos fechas de corte fundamentales: CUT = 1-ene-2025 (corte principal que separa entrenamiento de prueba) y $C_1 = 1\text{-mar-}2024$ (corte de validación que delimita la ventana de calibración de ensamble, NNLS y ruteo).

- **Actualización Secuencial del Nivel Base (Holt amortiguado):** El nivel inercial de demanda familiar se recalcula iterativamente mes a mes ($h = 1$) incorporando la historia observada hasta $t - 1$, anclando la trayectoria predictiva en la tendencia de corto plazo más reciente.
- **Modelos de Machine Learning y Ponderaciones Fijas:** Los algoritmos de Gradient Boosting (XGBoost, LightGBM, CatBoost), las ponderaciones NNLS (W_n), el umbral de momentum de ruteo (τ^*, w_{hi}, w_{lo}) y las proporciones de desagregación Top-Down se entrenan y calibran **una única vez** utilizando exclusivamente los datos disponibles antes de la fecha de corte (CUT = 2025-01-01) y la ventana de validación previa ($C_1 \rightarrow \text{CUT}$). Estos pesos se mantienen fijos durante todo el horizonte de prueba de 7 meses.

Justificación Operativa y Robustez frente a *Concept Drift*: En la operación real de empresas del retail, el reentrenamiento mensual de arquitecturas complejas de Machine Learning conlleva una alta fricción computacional y el riesgo de sobre-reaccionar a anomalías transitorias de corto plazo. Evaluar el modelo con pesos congelados durante un horizonte de 7 meses somete a la arquitectura a una prueba de estrés realista, mostrando su capacidad para retener valor predictivo y estabilidad sin depender de costosos ciclos continuos de reajuste.

Interpretación Operativa de la Arquitectura: La demanda de cada familia comercial se descompone en dos fuerzas complementarias: primero, un método estadístico clásico (Holt amortiguado; Holt, 2004) estima el **comportamiento base estructural** (nivel y tendencia amortiguada); segundo, modelos de árboles de decisión potenciados (GBDT) estiman la **desviación respecto a esa base** cuando intervienen variables de planificación comercial, tales como precios de lista ex-ante, descuentos y calendario promocional. De esta forma, los algoritmos de Machine Learning no aprenden el volumen desde cero, sino las modulaciones comerciales sobre la trayectoria esperada.

La arquitectura propuesta **ES-GBM** resuelve el problema de pronóstico mediante este esquema de desacoplamiento de señal en dos niveles (Figura 4.3):




Figura 4.3: Diagrama de Flujo de la Arquitectura Jerárquica Híbrida ES-GBM (Descomposición Inercial, Ensamble GBDT + TabPFN y Desagregación Top-Down).

Componente Metodológico	Instancia de Calibración	Recalibración en Test
Nivel Base Inercial (Holt amortiguado)	Secuencial mensual ($t - 1$)	Sí (actualización nivel $h = 1$)
Ensamble GBDT (XGB, LGB, CAT)	Todo el Train ($t \leq \text{CUT}$)	No (árboles y pesos fijos)
Ponderaciones NNLS (W_n)	4 ventanas OOS históricas (2023)	No (vector fijo de ensamble)
Umbral Momentum (τ^*) y Ruteo	Validación previa ($C_1 \rightarrow \text{CUT}$)	No (parámetros congelados)
Motor Desagregación (Proporciones Estáticas Top-Down)	Todo el Train ($t \leq \text{CUT}$)	No (proporciones fijas)

Tabla 4.2: Protocolo de Calibración y Evaluación Fuera de Muestra de la Arquitectura ES-GBM.

Fuente: Elaboración propia.

Esta sección detalla la metodología de la arquitectura de ensamble ES-GBM, la propuesta central de esta tesis. Para facilitar su comprensión antes de abordar el detalle algorítmico, el modelo resuelve el desafío del pronóstico retail a través de cuatro etapas lógicas encadenadas:

- Paso 1 — Extraer la inercia base estructural (Holt amortiguado): En lugar de exigirle a los algoritmos de Machine Learning que estimen desde cero el volumen físico de una categoría, el modelo estadístico Holt amortiguado calcula su nivel base suavizado de largo plazo (lv_l). Esto aporta un anclaje estable y evita que el pronóstico sobreerreaccione a shocks temporales.
- Paso 2 — Capturar el impacto de las palancas comerciales (Ensamble GBDT): Sobre ese nivel base, tres algoritmos de Gradient Boosting (Chen and Guestrin, 2016; Ke et al., 2017; Prokhorenkova et al., 2018) aprenden cómo el precio, los descuentos, el calendario y los eventos promocionales modulan la demanda por encima o por debajo de su tendencia natural. Para que modas antiguas no contaminen el presente, las observaciones históricas pierden peso gradualmente mediante un decaimiento temporal de 24 meses.
- Paso 3 — Conmutación de régimen según aceleración comercial (Ruteo por Momentum): El sistema monitorea si una familia de productos está en una fase de rápida aceleración (momentum trimestral superior al promedio anual). Si detecta una tendencia en auge, asigna mayor peso a la predicción dinámica; si la categoría es madura o estable, prioriza la señal conservadora.
- Paso 4 — Desagregación Jerárquica Top-Down a nivel SKU: Tras proyectar la demanda agregada continua a nivel Familia (donde la serie exhibe mayor densidad temporal y menor volatilidad), el modelo desagrega el volumen total hacia cada SKU utilizando proporciones históricas estáticas calculadas sobre el período de entrenamiento, asegurando que la suma de los productos cuadre exactamente con el total de la categoría.




Figura 4.4: Diagrama del Módulo de Ensamble Híbrido, Blending Global y Ruteo por Régimen.

Fuente: Elaboración propia.

4.5.1. Arquitectura de Ensamble con Nivel Suavizado

- Etapa de Nivel Base (Holt Amortiguado): Para cada Familia se ajusta un modelo de suavizamiento exponencial con tendencia amortiguada (Holt damped trend, sin componente estacional), el cual extrae el nivel base estructural de la demanda (lv_l_t) proyectado a un paso adelante ($h = 1$) a lo largo de la historia.
 - Familia “Combo GBDT”: Tres modelos de árboles de decisión con Gradient Boosting (XGBoost, LightGBM y CatBoost) entrenados sobre la transformación continua $\text{arcsinh}(\text{Unidades})$ con ponderación de muestras por antigüedad (decay exponencial con vida media de 24 meses) para priorizar el comportamiento reciente del mercado.
 - Familia “ES-GBM” (Ratio sobre Nivel): Dos modelos avanzados (LightGBM y CatBoost) entrenados sobre la escala relativa $\log(1 + \text{Unidades} / (lv_l + 1))$, aprendiendo los residuos y multiplicadores estacionales alrededor del nivel base extraído por Holt amortiguado.

Optimización del Ensamble

La combinación de los pronósticos individuales en el ensamble no se realiza mediante un promedio simple, sino mediante la optimización de ponderaciones por **mínimos cuadrados no negativos** (*Non-Negative Least Squares*, NNLS) sujeta a que los pesos sumen 1 ($\sum w_m = 1, w_m \geq 0$). NNLS minimiza la suma de errores cuadráticos ($\|Y - P\mathbf{w}\|_2^2$), no el WAPE; la selección final del factor de blend (w) y los umbrales de ruteo sí se realizó minimizando el WAPE sobre el conjunto de validación. Adicionalmente, el ensamble integra el modelo fundacional tabular **TabPFN Regresor** (*TabPFN v2 for Regression*; Hollmann et al., 2025), adaptado específicamente para problemas de regresión continua en datos tabulares mediante aproximación bayesiana no paramétrica evaluada en inferencia *in-context* zero-shot.

4.5.2. Formulación del Blend y Ruteo por Régimen

La predicción final combina las familias “combo” y “ES-GBM” en dos etapas, ambas calibradas exclusivamente sobre el conjunto de validación:

Blend global: Se determina el vector de pesos (w_c, w_e, w_t) que minimiza el WAPE en el conjunto de validación, balanceando la predicción directa en arcsinh (combo), la predicción modulada por nivel (ES-GBM) y la inferencia tabular de TabPFN.

Ruteo por régimen de momentum: En lugar de un peso estático para todas las familias, se calcula un indicador dinámico de momentum temporal ($\text{mom_3_12} = \text{rolling_mean_3} / (\text{rolling_mean_12} + 1)$). Se evaluó una grilla de umbrales $\tau \in [1,05; 1,50]$ y, para cada valor, se optimizaron los pesos del ruteo (w_{hi}, w_{lo}) sobre el conjunto de validación. El valor seleccionado (τ^*) y los pesos óptimos se determinaron minimizando el WAPE en validación. Si el momentum supera τ^* , el ensamble rutea

mayor ponderación a la componente de nivel dinámico (w_{hi}); en caso contrario, prioriza la señal conservadora del combo (w_{lo}).

Este mecanismo de ruteo dinámico por régimen permite que una única arquitectura continua se adapte tanto a familias en fase de aceleración comercial como a familias maduras o de baja rotación.



Figura 4.5: Pipeline de Entrenamiento Secuencial y Protocolo de Validación Anti-Leakage en Tres Fases.

Fuente: Elaboración propia, arquitectura del pipeline de ejecución.

4.5.3. Segmentación por Volumen de Demanda (Adaptación ABC)

- Como parte del análisis exploratorio y diagnóstico, cada Familia se clasifica en segmentos ABC (High, Medium, Low) según sus cuartiles de volumen de demanda en entrenamiento (Q1 y Q3). Sin embargo, a nivel de modelado, el ES-GBM entrena un estimador unificado sobre todo el catálogo: el decay temporal de muestras y el ruteo por momentum gestionan

naturalmente la heterogeneidad de volumen sin necesidad de truncar o aislar artificialmente el segmento bajo.

4.5.4. Ingeniería de Características y Anti-Leakage

La construcción de las variables explicativas se llevó a cabo bajo un estricto control metodológico con el fin de evitar la fuga de datos (data leakage). Antes de detallar las transformaciones realizadas, es relevante señalar que, para los modelos, las variables precio y descuento se consideran determinísticas. En el contexto de la empresa y del sector retail, el precio se establece antes del inicio del periodo t , mientras que el descuento corresponde al resultado de una planificación previa (por ejemplo, promociones asociadas al uso de determinadas tarjetas). Sobre esta base, se implementaron las siguientes transformaciones:

4.5.5. Creación de features

- Variables Autorregresivas (Lags): Desfases seguros de 1, 2, 3, 6 y 12 meses sobre la demanda, más un desfase adicional de 24 meses incorporado exclusivamente en la etapa de ensamble.
- Estadísticas Móviles Agrupadas: Media, desviación estándar y máximo móvil (ventanas de 3, 6 y 12 meses) calculadas estrictamente dentro de cada familia para prevenir contaminación entre series.

Dinámicas y Señales Financieras: Medias móviles exponenciales (`ewm3`, `ewm6`), tendencias polinómicas locales (`trend6`), ratios interanuales (`yoy_12_24`), ratios de inercia (`l1_l12`, `rm3_perfil`, `std_rel`), momentum de precio (`precio_mom`), profundidad de descuento (`desc_depth`), perfil relativo de familia (`perfil_fam_mes`, `perfil_rel`), precio relativo histórico (`px_rel_hist`) y variables macroeconómicas con lag $t-1$.

Codificación: Transformación armónica para estacionalidad (`sin_m`, `cos_m`).

Rigor Metodológico:

- Shift Temporal: Se aplicó un desplazamiento obligatorio a todas las variables derivadas de ventas históricas e indicadores macroeconómicos, asegurando que para predecir el mes t solo se utilicen datos disponibles hasta $t - 1$. Las variables de planificación comercial ex ante (precio y descuento programado) se incorporan directamente en t , dado que están disponibles antes del inicio del período de predicción.
- Validación Rolling Origin: Se utilizó la función `TimeSeriesSplit` para la validación cruzada, asegurando que el conjunto de entrenamiento siempre sea cronológicamente anterior al de prueba.

4.5.6. Selección de Pesos y Umbrales en Validación

A diferencia de una búsqueda bayesiana de hiperparámetros por modelo, la arquitectura propuesta fija los hiperparámetros de cada modelo base del ensamble (profundidad máxima, tasa de aprendizaje, número de estimadores y fracción de submuestreo) en valores calibrados previamente, y concentra el esfuerzo de optimización en las decisiones de ensamble: los pesos NNLS de la familia combo, el peso del blend global, y el umbral y los pesos del ruteo por régimen. Todas estas decisiones se seleccionan por búsqueda en grilla sobre el conjunto de validación, nunca sobre el conjunto de prueba, y se promedian sobre múltiples semillas aleatorias para reducir la varianza asociada a la inicialización de cada modelo.

Batería de Pruebas Automatizadas de Integridad Temporal Anti-Leakage: Para verificar rigurosamente la ausencia de fugas residuales de información antes del entrenamiento, el pipeline implementa un protocolo computacional automatizado de tres pruebas unitarias independientes:

1. **Test de Causalidad Temporal Estricta:** Verificación lógica booleana sobre el índice de rezago de todas las características de panel, asegurando que ninguna variable observada del entorno o transaccional posea marcas temporales contemporáneas o futuras ($t' \geq t$).
2. **Test de Correlación Cruzada Límite:** Evaluación sistemática del coeficiente de correlación lineal de Pearson entre cada covariable $X_{j,t-1}$ y el vector objetivo y_t . Se define una regla de parada y exclusión automática ante correlaciones anómalas ($|\rho| > 0,95$) calculadas exclusivamente sobre el período de entrenamiento, permitiendo detectar y descartar posibles señales circulares encubiertas (tales como ingresos netos contemporáneos o agregados acumulados post-evento).
3. **Test de Aislamiento de Transformadores (*Blind Split*):** Comprobación de que los estimadores de normalización (escaladores Min-Max, cálculos de medias móviles y descomposiciones de nivel) se ajusten exclusivamente sobre la ventana histórica de entrenamiento (T_{train}), evitando cualquier transferencia o fuga de parámetros hacia los conjuntos de validación y prueba.

4.5.7. Curación de Variables mediante Auditoría Anti-Leakage

1. En lugar de una selección automática de variables por eliminación recursiva, el conjunto final de predictores se depuró mediante el proceso de auditoría descrito en la auditoría metodológica de integridad temporal anti-leakage: las variables identificadas como fuente de fuga de datos, o como transformaciones que reconstruían parcialmente la variable objetivo, se excluyeron explícitamente del conjunto de entrada a los modelos. Este criterio, aplicado de forma manual y verificado mediante análisis de correlación, resultó más conservador que una selección puramente estadística, priorizando la validez temporal y operacional de cada variable por sobre su aporte marginal a la métrica de entrenamiento.

4.6. Arquitectura de Deep Learning: Redes LSTM (Enfoque Top-Down)

Como aproximación de aprendizaje profundo, se implementó una red neuronal recurrente LSTM (Long Short-Term Memory) bajo una estrategia jerárquica Top-Down a nivel de Familia.

Sin embargo, la aplicación directa de Deep Learning a nivel de SKU en retail presenta un desafío estructural: la alta dispersión de datos y la intermitencia impiden la convergencia del descenso de gradiente. Para superar esto, se diseñó una estrategia jerárquica Top-Down.

4.6.1. Estrategia Jerárquica de Modelado (Top-Down Approach)

La justificación conceptual del enfoque jerárquico Top-Down radica en la ley de los grandes números: a nivel de SKU individual, las ventas son sumamente erráticas e intermitentes (con días o semanas de cero ventas), lo que confunde a los algoritmos de optimización. Al agregar las ventas a nivel de Familia, el 'ruido' individual se cancela y emerge una curva de demanda densa, suave y con estacionalidad clara. De este modo, el sistema primero predice con alta precisión el volumen total de la categoría (el 'bosque') y posteriormente utiliza el motor de participaciones para distribuir las unidades entre los productos específicos (las 'ramas'), superando la inestabilidad del modelado directo desde abajo (Bottom-Up).

4.6.2. Preprocesamiento de Tensores y Escalado

Con el objetivo de capturar la estacionalidad anual, se definió una ventana temporal (sequence length) de 12 meses; es decir, se consideran los 12 meses previos para predecir el periodo siguiente. Con ello, los datos históricos se transforman en un formato que la red pueda procesar (tensores tridimensionales). El vector de entrada en cada paso temporal incluye la demanda histórica de la Familia y componentes armónicos de estacionalidad (seno y coseno del mes); en la variante con precio ex-ante, se añade además el precio estimado del mismo período, disponible de antemano por tratarse de una variable de planificación comercial.

4.6.3. Arquitectura de la Red (Celdas de Memoria)

La arquitectura fue implementada en PyTorch (torch.nn) y comprende dos capas LSTM apiladas, capa de salida densa y optimizador Adam con early stopping. La configuración completa de hiperparámetros (número de celdas, dropout, semillas) se detalla en el Anexo A.9.

Entrenamiento Multi-Semilla y Protocolo de Evaluación: Se aplica Early Stopping con paciencia de 15 épocas sobre el conjunto de validación. Para mitigar la variabilidad inherente al Deep Learning en Small Data, el modelo se entrena sobre un ensamble de 5 semillas aleatorias (42, 1, 7, 2025,

99), promediando sus inferencias. Los pesos de la red LSTM se calibraron exclusivamente sobre el conjunto de entrenamiento y validación previa (hasta la fecha de corte CUT = enero 2025) y permanecieron congelados durante todo el horizonte de prueba de 7 meses (febrero–agosto de 2025), sin reentrenamiento secuencial, preservando estricta paridad con el esquema de evaluación de la arquitectura propuesta.

4.6.4. Modelo Fundacional de Series de Tiempo (Amazon Chronos-Bolt)

Como cuarto benchmark de frontera, se incorporó Amazon Chronos-Bolt (Ansari et al., 2024), un modelo fundacional pre-entrenado sobre miles de millones de observaciones temporales. Chronos cuantiza las series de tiempo continuas como secuencias de tokens discretos, adaptando una arquitectura Transformer para realizar inferencia probabilística zero-shot. En esta tesis se evalúa bajo horizonte $h=1$ mensual sobre la historia de cada Familia, extrayendo la mediana (cuantil 0.50) de la distribución predictiva y desagregando posteriormente a SKU.

$$\hat{y}_{i,t} = \hat{Y}_{\text{Fam},t} \times w_i \quad (4.1)$$

donde $\hat{y}_{i,t}$ representa la predicción desagregada para el SKU i en el mes t , $\hat{Y}_{\text{Fam},t}$ es la proyección de la Familia respectiva, y w_i corresponde a la proporción histórica estática del SKU dentro de su familia calculada exclusivamente sobre el período de entrenamiento ($w_i = \text{Venta_Train}_i / \text{Venta_Train}_{\text{Fam}}$) y congelada durante todo el horizonte de prueba. Este procedimiento de desagregación Top-Down asegura estricta comparabilidad experimental con los demás modelos benchmark.

4.6.5. Desagregación Dinámica a Nivel SKU: Cuotas Supervisadas (*Learned Shares*)

La etapa final del pipeline metodológico consiste en la desagregación de la demanda agregada proyectada a nivel de Familia hacia cada uno de los SKU individuales. Para los resultados principales de esta tesis, se utilizó un esquema de **proporciones estáticas históricas** (*Static Shares*): la participación de cada SKU dentro de su familia se calcula como la proporción de unidades vendidas en el período de entrenamiento ($w_i = y_i / \sum_{j \in \mathcal{F}} y_j$), y se aplica de forma fija durante todo el horizonte de prueba. Este enfoque es el mismo utilizado por todos los modelos benchmark, asegurando comparabilidad justa.

Como extensión metodológica, se implementó adicionalmente un motor de **Machine Learning supervisado** (LightGBM, XGBoost y CatBoost) para predecir de forma adaptativa la participación dinámica (*share*) de cada artículo, denominado *Learned Shares* (detallado en el Anexo A.5). La desagregación se restringe al catálogo estratégico (Top 100 SKUs): la demanda familiar proyectada $\hat{Y}_{\text{Fam},t}$ corresponde al agregado de los SKUs Top 100 de esa familia, y las cuotas se normalizan al

simplex exclusivamente sobre ese subconjunto, asegurando coherencia jerárquica $\sum_{i \in \text{Top100} \cap \mathcal{F}} \hat{y}_{i,t} = \hat{Y}_{\text{Fam},t}$.

El vector de características explicativas a nivel SKU (X_{share}) se compone de señales autorregresivas, tendenciales y de precio relativo:

- **Rezagos de cuota histórica:** Participación del SKU en los meses $t-1$ y $t-12$ ($\text{share}_{t-1}, \text{share}_{t-12}$), capturando la inercia reciente y la estacionalidad interanual del producto.
- **Medias móviles de participación:** Promedios móviles suavizados de 3 y 12 meses ($\overline{\text{share}}_3, \overline{\text{share}}_{12}$), aislando la tendencia subyacente de rotación frente a la volatilidad mensual.
- **Indicador de inactividad comercial (MSLS):** Meses transcurridos desde la última venta positiva (*Months Since Last Sale*), penalizando productos en proceso de obsolescencia o discontinuación.
- **Posicionamiento y precio relativo:** Ratio de precio unitario del producto frente al precio promedio ponderado de su familia comercial ($P_{\text{SKU}}/\bar{P}_{\text{Fam}}$).

Las participaciones proyectadas ($\hat{s}_{i,t}$) para los M artículos pertenecientes a la familia $\mathcal{F}$ se proyectan al simplex y normalizan de forma determinista para asegurar no negatividad y que la suma de participaciones sea exactamente igual al 100 %:

$$\hat{w}_{i,t} = \frac{\max(0, \hat{s}_{i,t})}{\sum_{j \in \mathcal{F}} \max(0, \hat{s}_{j,t})} \quad (4.2)$$

donde $\hat{w}_{i,t}$ representa la cuota normalizada al simplex para el SKU i en el mes t , $\hat{s}_{i,t}$ es la participación bruta estimada por el modelo de Gradient Boosting, y $\mathcal{F}$ denota el conjunto de todos los SKUs que pertenecen a la misma Familia comercial. En caso de que todas las predicciones brutas sean no positivas ($\sum_{j \in \mathcal{F}} \max(0, \hat{s}_{j,t}) = 0$), se asigna un reparto uniforme entre los SKUs de la familia como mecanismo de fallback. La proyección física final en unidades para el SKU i en el mes t se obtiene multiplicando la demanda familiar agregada proyectada ($\hat{Y}_{\text{Fam},t}$) por su respectiva cuota supervisada:

$$\hat{y}_{i,t} = \hat{Y}_{\text{Fam},t} \times \hat{w}_{i,t} \quad (4.3)$$

donde $\hat{y}_{i,t}$ es la demanda física final pronosticada para el producto i en el mes t , $\hat{Y}_{\text{Fam},t}$ es la proyección agregada generada para la Familia respectiva, y $\hat{w}_{i,t}$ es la cuota dinámica asignada por el motor de desagregación, lo que asegura la coherencia jerárquica estricta sin requerir reconciliaciones posteriores.

4.7. Descripción de variables

Se especifican las variables del conjunto de datos maestro depurado, las cuales constituyen la base analítica común para todos los modelos evaluados en esta investigación:

4.7.1. Variables de Identificación de Catálogo y Target

- **Año y Mes:** Variables temporales enteras que registran el período mensual (enero 2020 a agosto 2025).
- **Jerarquía de Catálogo:** SKU_Personalizado, Familia, Superfamilia, Subfamilia y Temporada.
- **Target Transaccional:** Venta_Neta_Unidades (demanda física y) y Venta_Neta_Monto (CLP).

4.7.2. Variables Exógenas y de Planificación Comercial Ex-Ante

- **Plan Comercial Ex-Ante (Tiempo t):** Precio_Estimado (catálogo ERP) y Descuento_promedio_estimado (pauta comercial).
- **Calendario y Festivos (Tiempo t):** Hitos determinísticos (Navidad, *CyberDay*, *Black Friday*, Día de la Madre).
- **Entorno Macroeconómico (Rezago $t - 1$ Anti-Leakage):** IMACEC_Comercio, IPC_Vestuario, tipo de cambio USD/CLP, tasa de desempleo e Índice de Confianza del Consumidor.

Capítulo 5

Resultados y Análisis Comparativo

En este capítulo se presentan y discuten los resultados empíricos obtenidos tras evaluar las diversas familias de modelos sobre la ventana de evaluación fuera de muestra (*out-of-sample*), correspondiente al período de febrero a agosto de 2025. La evaluación cuantitativa se efectúa a través de métricas estandarizadas de la literatura: Error Absoluto Ponderado (*Weighted Absolute Percentage Error*, WAPE), Error Porcentual Absoluto Medio condicional (*Mean Absolute Percentage Error*, MAPE), Raíz del Error Cuadrático Medio (RMSE), Error Absoluto Medio (MAE), Sesgo Relativo (*Bias*) y Coeficiente de Determinación (R^2), evaluadas tanto a nivel macro (58 Familias agregadas del catálogo núcleo) como a nivel micro (Top 100 SKUs desagregados).

5.1. Comparativa Consolidada de Desempeño Global

La Tabla 5.1 presenta la síntesis general del desempeño comparativo de todas las arquitecturas evaluadas frente a la demanda real observada durante los 7 meses de prueba.

La investigación adoptó una estrategia metodológica de **screening industrial en dos etapas**: en una primera fase de tamizaje comparativo, se evaluaron implementaciones estándar y parsimoniosas de referencia representativas de los principales paradigmas del estado del arte (econométricos univariados y multivariados, modelos para demanda intermitente con ceros, redes neuronales recurrentes y modelos fundacionales *zero-shot*); en la segunda fase, tras constatar las limitaciones estructurales de los enfoques lineales e individuales, se concentró el desarrollo e ingeniería avanzada sobre la arquitectura jerárquica híbrida ganadora (**ES-GBM con Desagregación Top-Down**).

Tal como se ilustra en la Tabla 5.1 y en la Figura 5.1, la progresión de los modelos evidencia una reducción sustancial del error a medida que se incorporan no linealidades, señales comerciales exógenas y desacoplamiento jerárquico: el WAPE desciende desde un **84,87 %** en el baseline Croston clásico y **83,42 %** en SBA hasta un **16,10 %** en la arquitectura propuesta. Cabe destacar que el Seasonal Naïve (WAPE 69,89 %) supera a SARIMAX (73,24 %) y SARIMA (76,74 %) a nivel SKU, validando la fortaleza de los patrones estacionales puros en retail de moda.

Evaluación Comparativa con Métrica Ponderada de Escala (WRMSSE): Para conectar formalmente los resultados con el marco teórico de la competencia M5 (§3.4.4), se calculó el

Tabla 5.1: Comparativa Consolidada de Desempeño en el Período de Evaluación Fuera de Muestra (Feb–Ago 2025)

Modelo / Arquitectura	Nivel	WAPE	sMAPE	RMSE	MAE	Bias (%)	R ²	Ranking
<i>Panel A: Modelos Desagregados a Nivel SKU (Top 100 Productos)</i>								
ES-GBM (Static Top-Down)	SKU	16,10 %	20,47 %	26,7	11,4	-4,8 %	0,95	1°
ES-GBM (Learned Dynamic Share)	SKU	24,35 %	28,90 %	41,2	17,2	-5,2 %	0,79	2°
LSTM Recurrente (con precio ex-ante)	SKU	45,75 %	52,10 %	64,1	32,3	+8,4 %	0,55	3°
Chronos-Bolt Desagregado (Static Share)	SKU	48,44 %	70,69 %	65,1	34,2	+5,6 %	0,72	4°
LSTM Recurrente (sin precio ex-ante)	SKU	53,76 %	61,40 %	68,1	38,1	+11,2 %	0,38	5°
Seasonal Naïve (Benchmark y_{t-12})	SKU	69,89 %	88,17 %	107,2	49,4	+6,3 %	0,23	6°
SARIMAX (con precio y descuento)	SKU	73,24 %	170,87 %	122,9	51,7	+11,6 %	-0,01	7°
SARIMA Univariado (Línea Base)	SKU	76,74 %	309,88 %	139,6	54,2	+14,3 %	-0,31	8°
SBA (Syntetos-Boylan Approx.)	SKU	83,42 %	95,19 %	108,1	58,9	-4,2 %	0,22	9°
Croston Clásico	SKU	84,87 %	95,35 %	108,6	59,9	+0,9 %	0,21	10°
<i>Panel B: Modelos Agregados a Nivel Familia (58 Familias del Catálogo Top 100)</i>								
ES-GBM Ensamble Agregado	Familia	12,89 %	14,67 %	35,9	15,7	-4,8 %	0,96	1°
Chronos-Bolt Agregado (Zero-Shot)	Familia	36,35 %	61,38 %	81,9	44,3	+5,6 %	0,79	2°
LSTM Recurrente Agregado (Familia)	Familia	40,51 %	69,36 %	88,1	49,3	+7,9 %	0,76	3°
SARIMAX Agregado	Familia	59,64 %	268,31 %	165,3	72,6	+11,6 %	0,16	4°
Seasonal Naïve Agregado (Y_{t-12})	Familia	59,78 %	84,80 %	148,9	72,8	+6,3 %	0,32	5°
SARIMA Agregado	Familia	64,84 %	450,19 %	183,3	79,0	+14,3 %	-0,03	6°

Fuente: Elaboración propia a partir de datos del caso de estudio. La columna sMAPE (*symmetric Mean Absolute Percentage Error*) se reporta en lugar del MAPE clásico porque este último es indefinido o diverge cuando la demanda real $y_t = 0$, condición frecuente en series intermitentes del retail. El sMAPE (Chen and Yang, 2017) acota el error relativo en el rango [0 %, 200 %] y se calcula de forma condicional sobre meses con demanda positiva. El WAPE opera como métrica rectora robusta de volumen.




Figura 5.1: Comparativa Consolidada de Pronóstico Fuera de Muestra vs Demanda Real para Modelos Representativos

Fuente: Elaboración propia.

WRMSSE para los modelos evaluados¹, normalizando el error cuadrático por la escala del Seasonal Naïve (y_{t-12}) y ponderando por el valor de ventas de cada producto. La arquitectura propuesta **ES-GBM alcanza un WRMSSE de 0,2017** (reduciendo el error escalado en casi 5 veces frente a la escala unitaria de referencia), superando de forma clara a Chronos-Bolt (0,3980), LSTM Recurrente (0,5420), SARIMAX (0,8950), SARIMA (0,9620) y Seasonal Naïve (1,0000 como referencia de escala).

Diagnóstico de la Sensibilidad del sMAPE en SARIMAX: En la Tabla 5.1 se observa un valor elevado en el sMAPE de SARIMAX (170,87%) a pesar de exhibir un WAPE de 73,24%. Esta discrepancia obedece a una propiedad analítica ampliamente documentada en la econometría de series temporales (Hyndman and Koehler, 2006): cuando un producto presenta ventas reales positivas reducidas ($y_{i,t} \in \{1, 2\}$) y la regresión dinámica proyecta valores positivos moderados inducidos por el vector de precios, el ratio $|y - \hat{y}|/y$ diverge sustancialmente, afectando el promedio aritmético no ponderado. En contraste, el WAPE pondera las desviaciones por el volumen físico total del catálogo, reflejando con exactitud la precisión global de inventario.

A continuación, se desglosa el análisis detallado por cada familia de modelos evaluada.

¹El cálculo del WRMSSE se realizó de forma externa al pipeline principal de Python, utilizando una implementación independiente de la métrica sobre los archivos de predicciones generados por cada modelo.

5.2. Evaluación de Líneas Base Econométricas (SARIMA y SARIMAX)

Como punto de partida, se evaluaron los modelos econométricos estacionales tradicionales:

- **SARIMA $(1, 1, 1) \times (1, 1, 1)_{12}$ Univariado:** Asume que la demanda futura depende exclusivamente de la estructura lineal de rezagos autorregresivos y medias móviles de la propia serie histórica.
- **SARIMAX $(1, 1, 1) \times (1, 1, 1)_{12}$ con Regresores Exógenos:** Extiende la formulación anterior incorporando precio planificado y descuento promedio como covariables ex-ante.




Figura 5.2: Desempeño Predictivo de la Línea Base SARIMA vs. Demanda Real Fuera de Muestra (Suma Top 100 SKUs)

Fuente: Elaboración propia.

El análisis de las trayectorias de SARIMA (Figura 5.2) y SARIMAX permite identificar tres fallas estructurales intrínsecas en entornos de retail de moda:

1. **Efecto de Retardo Sistemático (*Lag Effect*):** Al basarse en diferencias autorregresivas sin memoria no lineal, el modelo proyecta picos de demanda con un desfase de un mes ($t - 1$). En la práctica comercial, esto ocasiona que el abastecimiento llegue cuando el evento promocional ya ha concluido, generando sobrestock crítico y pérdidas por liquidación forzada.
2. **Inercia y Amortiguamiento de Extremos:** Frente a la bimodalidad del retail de vestuario femenino (temporadas de otoño-invierno y primavera-verano), la estructura lineal suaviza excesivamente las proyecciones hacia la media histórica, subestimando la demanda en temporada alta (mayo) y sobreestimándola en meses valle (febrero y marzo).

3. **Limitación de Elasticidad Constante en SARIMAX:** Aunque SARIMAX logra reducir el WAPE a nivel Familia de 64,84 % a 59,64 % gracias a la información de precios, la hipótesis de linealidad rígida $\beta \cdot P_t$ impide capturar umbrales psicológicos de precios, saturación de demanda o interacciones promocionales específicas por categoría.

5.3. Modelos para Demanda Intermitente y Ceros (Croston y SBA)

Dada la alta presencia de meses con demanda nula a nivel SKU (originada por quiebres transitorios de stock y ciclos de vida cortos), se evaluaron las formulaciones clásicas para demanda intermitente:

Tabla 5.2: Desempeño Comparativo de Modelos para Demanda Intermitente a Nivel SKU

Modelo / Algoritmo	WAPE	MAPE	RMSE	MAE	Bias (%)	R ²
SBA (Syntetos-Boylan Approx.)	83,42 %	95,19 %	108,1	58,9	-4,2 %	0,22
Croston Clásico	84,87 %	95,35 %	108,6	59,9	+0,9 %	0,21

Fuente: Elaboración propia a partir de datos del caso de estudio.

Los resultados de la Tabla 5.2 revelan hallazgos clave:

- **Falla de Estacionalidad en Croston y SBA:** El método de Croston (WAPE **84,87 %**) y la corrección de Syntetos-Boylan (WAPE **83,42 %**) separan la serie en dos procesos de suavizado exponencial simple: el tamaño de la demanda no nula y el intervalo temporal entre demandas. Al no poseer un mecanismo nativo para capturar factores de ciclo estacional ni tendencias no estacionarias, proyectan tasas de demanda casi constantes a lo largo del año. A diferencia de los modelos econométricos que sí incorporan estacionalidad (SARIMA, SARIMAX) o arquitecturas jerárquicas con ruteo no lineal (ES-GBM), Croston y SBA obtienen los peores desempeños del ranking a nivel SKU (WAPE 84,87 % y 83,42 % respectivamente), incluso por debajo del Seasonal Naïve (69,89 %).
- **Rendimiento Inferior al Seasonal Naïve:** A nivel SKU, tanto Croston (84,87 %) como SBA (83,42 %) resultan superados por el Seasonal Naïve simple (69,89 %), cuyo enfoque de proyectar y_{t-12} y desagregar vía proporciones estáticas captura de forma más efectiva la estacionalidad fuerte del retail de moda. Este resultado refuerza que, en catálogos con ciclos estacionales marcados y alta proporción de ceros, los modelos de demanda intermitente carecen del mecanismo para aprovechar la señal estacional, lo que explica por qué ES-GBM lo supera con un WAPE de **16,10 %**.

- **Limitación de la Intermitencia Pura vs. Señales Exógenas:** A nivel SKU, Croston (WAPE **84,87 %**) y SBA (WAPE **83,42 %**) obtienen los peores resultados de todos los modelos evaluados, quedando por debajo incluso del Seasonal Naïve (69,89 %). Aunque Croston modela explícitamente la intermitencia separando el tamaño de la demanda no nula del intervalo entre demandas, su incapacidad para incorporar factores exógenos (precio, descuento) ni capturar la estacionalidad fuerte del retail de moda lo condena a un desempeño deficiente. SARIMAX (73,24 %) supera a Croston por 11,6 puntos porcentuales gracias a la información de precios, y ES-GBM (16,10 %) presenta una mejora de 68,8 puntos porcentuales de WAPE respecto de Croston bajo el protocolo experimental definido. La contribución individual de cada componente metodológico forma parte de la estructura global del ensamble y no fue aislada mediante una ablación factorial completa.

5.4. Deep Learning Recurrente y Modelos Fundacionales (LSTM y Chronos-Bolt)

Para examinar la capacidad de arquitecturas conexionistas complejas, se entrenaron redes neuronales recurrentes LSTM y se testeó el modelo fundacional preentrenado *Amazon Chronos-Bolt*:

Tabla 5.3: Evaluación de Deep Learning Recurrente y Modelos Fundacionales

Modelo	Nivel	WAPE	MAPE	RMSE	MAE	R ²
LSTM Recurrente (con precio ex-ante)	SKU	45,75 %	52,10 %	64,1	32,3	0,55
LSTM Recurrente (sin precio ex-ante)	SKU	53,76 %	61,40 %	68,1	38,1	0,38
Chronos-Bolt (Zero-Shot Foundation)	Familia	36,35 %	61,38 %	81,9	44,3	0,79

Fuente: Elaboración propia a partir de datos del caso de estudio.

- **Impacto Decisivo del Vector de Precios Ex-Ante en LSTM:** La inclusión del precio planificado permitió a la red LSTM reducir el WAPE a nivel SKU de **53,76 % a 45,75 %** (una reducción de 8,0 puntos porcentuales), mostrando que las redes recurrentes sí logran capturar la relación predictiva precio-demanda intertemporal cuando disponen de señales exógenas alineadas.
- **Desempeño Zero-Shot de Amazon Chronos-Bolt:** A nivel Familia, el modelo fundacional Chronos-Bolt (basado en arquitectura T5 preentrenada sobre miles de millones de puntos temporales sintéticos y públicos) alcanzó un WAPE de **36,35 %** en modalidad *zero-shot* pura (sin reentrenamiento). Para obtener el pronóstico a nivel SKU reportado en la Tabla 5.1 (WAPE 48,44 %), la predicción agregada de Chronos-Bolt a nivel Familia se desagregó mediante las mismas cuotas históricas estáticas del experimento de ablación Top-Down (proporciones

fijas por SKU calculadas sobre el período de entrenamiento), sin ningún componente de aprendizaje dinámico. Esta configuración sirve de referencia comparativa directa frente al enfoque de desagregación estática del ensamble propuesto. Chronos-Bolt superó con holgura a las referencias econométricas tradicionales (SARIMAX 59,64%), pero quedó aún distante del ensamble híbrido especializado ES-GBM (12,89 % Familia / 16,10 % SKU).

5.5. Desempeño de la Arquitectura Propuesta (ES-GBM con Desagregación Top-Down)

La arquitectura jerárquica propuesta (**ES-GBM con Desagregación Top-Down**) combina la descomposición del nivel estructural mediante Holt amortiguado con un ensamble de árboles de decisión gradiente (*XGBoost*, *LightGBM*, *CatBoost*) y modelos fundacionales tabulares (*TabPFN*), integrando un módulo de ruteo dinámico por momentum y desagregación jerárquica hacia nivel SKU mediante proporciones estáticas históricas calculadas sobre el período de entrenamiento.

Tabla 5.4: Métricas de Desempeño del Ensamble Jerárquico ES-GBM

Nivel de Agregación	WAPE	MAPE	RMSE	MAE	Bias (%)	R^2
Familia (Agregado Top 100 SKUs)	12,89 %	14,67 %	35,9	15,7	-4,84 %	0,96
SKU (Static Top-Down)	16,10 %	20,47 %	26,7	11,4	-4,84 %	0,95
<i>Extensión: SKU (Learned Dynamic Share)</i>	24,35 %	28,90 %	41,2	17,2	-5,20 %	0,79

Fuente: Elaboración propia a partir de datos del caso de estudio.




Figura 5.3: Evolución Temporal del Pronóstico ES-GBM vs. Demanda Real Fuera de Muestra (Suma Top 100 SKUs)

Fuente: Elaboración propia.

Tal como ilustran la Tabla 5.4 y la Figura 5.3, la metodología desarrollada exhibe un desempeño consistente fuera de muestra:

- **Precisión Macro y Micro:** Alcanza un R^2 de **0,96** a nivel Familia (WAPE 12,89%) y de **0,95** a nivel SKU (WAPE 16,10%), con un WRMSSE de **0,2017**.

- **Ablación de Cuotas (*Static Top-Down* vs. *Learned Dynamic Share*):** La desagregación supervisada dinámica (Learned Shares) obtuvo un WAPE de 24,35 %, superior al enfoque estático principal (16,10 %), lo que sugiere que en catálogos con alta proporción de SKUs intermitentes las proporciones fijas del período de entrenamiento ofrecen mayor estabilidad predictiva que un modelo de cuotas supervisado con ventanas de entrenamiento limitadas.

5.5.1. Estudio de Ablación del Vector de Precios y Señales Ex-Ante

Para cuantificar con exactitud la contribución de la información de precios y evaluar la robustez del ensamble frente a posibles desviaciones en el plan comercial, se realizó un experimento de ablación controlada sobre la ventana de evaluación fuera de muestra, cuyos resultados se resumen en la Tabla 5.5.²

Tabla 5.5: Estudio de Ablación del Vector de Precios en el Ensamble ES-GBM (Nivel SKU)

Configuración de Precios	WAPE	MAPE	RMSE	R ²
1. Sin información de precios (solo señal temporal)	38,25 %	44,10 %	58,3	0,69
2. Con precio rezagado $t - 1$ (estrictamente histórico)	26,42 %	31,50 %	41,2	0,78
3. Con plan comercial ex-ante mes t (modelo propuesto)	16,10 %	20,47 %	26,7	0,95

Fuente: Elaboración propia a partir de datos del caso de estudio.

Los resultados de la Tabla 5.5 ponen de manifiesto dos aspectos metodológicos cruciales:

1. Incluso sin información de precios (Configuración 1, WAPE 38,25 %), la arquitectura ES-GBM alcanza un error sustancialmente inferior al observado en SARIMA (76,74 %) y en SBA (83,42 %), lo que evidencia que su desempeño no depende exclusivamente de la señal de precios, sino que cuenta con una base sólida provista por el desacoplamiento inercial y el modelado no lineal de panel.
2. La incorporación del precio rezagado $t - 1$ (Configuración 2) reduce el error a 26,42 %, mientras que el plan ex-ante (Configuración 3) alcanza el 16,10 %, mostrando que el modelo aprovecha eficazmente la señal predictiva de precio intertemporal planificada sin depender de ella de forma frágil.

²Nota metodológica: este experimento de ablación requiere reentrenar el ensamble ES-GBM excluyendo o rezagando las variables de precio. Debido a la complejidad computacional del pipeline completo (8 semillas $\times$ 3 modelos GBDT $\times$ NNLS $\times$ ruteo), estos resultados se obtuvieron mediante ejecuciones experimentales separadas del pipeline y no están disponibles como scripts reproducibles en el repositorio.

5.6. Interpretabilidad y Diagnóstico de Residuos

Para satisfacer las exigencias de gobernanza y transparencia requeridas por la gerencia de planificación del retail, se evaluó la explicabilidad del modelo mediante el análisis de importancia por ganancia total de división (*Total Gain Importance*) del módulo directo GBDT del ensamble:




Figura 5.4: Importancia Relativa de Variables por Ganancia Total del Módulo GBDT (*Total Gain Importance*)

Fuente: Elaboración propia.

El análisis de ganancia total (*total gain*) del módulo GBDT (Figura 5.4), utilizado como proxy interpretativo del ensamble, revela que la variable con mayor importancia relativa es el **precio estimado ex-ante** (67,0 % de la ganancia total del submodelo), seguido por la demanda del mes anterior (*lag 1*, 11,1 %). Este resultado indica que el precio constituye una fuente importante de información predictiva para este componente del ensamble. No obstante, esta importancia relativa por ganancia total del submodelo no debe interpretarse como una estimación causal directa de la sensibilidad precio sobre la mejora total de WAPE del ensamble, dado que el diagnóstico se limita al submodelo GBDT y puede estar influido por correlaciones entre variables.

5.6.1. Diagnóstico y Evaluación de Residuos

El diagnóstico de los residuos fuera de muestra permite corroborar la estabilidad estadística de la arquitectura propuesta y evaluar posibles patrones de heterocedasticidad o autocorrelación no capturados:




Figura 5.5: Análisis de Residuos y Heterocedasticidad del Modelo Propuesto

Fuente: Elaboración propia.

Tal como ilustra la Figura 5.5, el diagnóstico de los residuos muestra evidencia visual compatible con un comportamiento aproximadamente simétrico, centrado en cero y sin patrones de autocorrelación temporal remanente. La prueba de Ljung–Box no rechaza la hipótesis de ausencia de autocorrelación hasta el rezago evaluado ($p = 0,751$). Si bien estos resultados aportan evidencia favorable, no constituyen una confirmación definitiva de normalidad ni de homocedasticidad; no obstante, son consistentes con un comportamiento residual adecuado para la validación de la arquitectura en condiciones reales de operación.

Capítulo 6

Conclusiones e Impacto Financiero

La evaluación empírica fuera de muestra sobre los 7 meses de prueba (febrero a agosto de 2025) indica que la arquitectura jerárquica híbrida ES-GBM es la alternativa de mejor desempeño para el catálogo de la Empresa X. Al evaluar mediante el WAPE —métrica rectora que pondera los errores por el volumen físico comercializado y evita distorsiones por divisiones por cero en meses de demanda nula—, el modelo propuesto alcanza un 16,10 % a nivel SKU y un 12,89 % a nivel Familia, superando de forma consistente a las referencias econométricas, a los modelos para demanda intermitente y a las redes neuronales recurrentes.

6.1. Limitaciones Estructurales de los Modelos Clásicos Univariados

Como se mostró en la Sección 5.2, los modelos SARIMA (WAPE 64,84 % Familia / 76,74 % SKU) y SARIMAX (59,64 % / 73,24 %) presentan errores estructuralmente elevados. Las causas identificadas en el capítulo anterior pueden sintetizarse en tres fallas clave: (i) **inercia y retardo**: la dependencia exclusiva de la autocorrelación genera un desfase sistemático en la detección de cambios de tendencia; (ii) **sesgo hacia la media**: frente a la presencia de ceros estructurales, los modelos lineales suavizan el pronóstico, subestimando la magnitud de los eventos de venta reales; y (iii) **imputación de ceros**: la imputación artificial introduce ruido que deteriora la estacionalidad real. Además, si bien SARIMAX logró una reducción marginal de 3,5 puntos porcentuales sobre SARIMA a nivel SKU (76,74 % $\rightarrow$ 73,24 %), su estructura paramétrica lineal resultó insuficiente para explotar la riqueza de la señal de precios, la cual, al ser procesada mediante ensambles no lineales de árboles, permite reducir el error en más de 20 puntos adicionales.

6.2. Eficacia de la arquitectura de ensamble y principales aportes metodológicos

El desempeño documentado en el párrafo anterior no se explica por la elección de un único algoritmo, sino por cinco pilares metodológicos encadenados que abordan cada uno un problema

concreto de la demanda en retail de moda:

1. **Arquitectura Híbrida Semi-Paramétrica (Nivel + Residuo Comercial):** En lugar de forzar a los árboles de decisión a predecir el volumen total desde cero, el modelo descompone la señal en dos capas. Primero, el modelo estadístico Holt amortiguado extrae la inercia estructural de largo plazo (el nivel base de la categoría). Luego, los modelos de Gradient Boosting (XGBoost, LightGBM, CatBoost) y el modelo fundacional TabPFN aprenden cómo las palancas comerciales (precios, descuentos y campañas) modulan la demanda sobre ese nivel base utilizando una escala continua arcsinh y ponderación temporal decreciente (decay de 24 meses).
2. **Algoritmo de Ruteo Dinámico por Momentum:** Frente a los ensambles tradicionales que aplican pesos fijos a todos los productos, el sistema incorpora un mecanismo adaptativo dependiente del estado. Evalúa en tiempo real si una categoría viene acelerando sus ventas (momentum trimestral superior al promedio anual); si detecta un auge de demanda, conmuta hacia una ponderación de nivel dinámico, mientras que si la categoría es madura o estable, prioriza una combinación conservadora.
3. **Desagregación Jerárquica Top-Down:** La demanda familiar proyectada se descompone hacia SKUs individuales mediante proporciones históricas calculadas en el período de entrenamiento. Este enfoque, idéntico al utilizado por los benchmarks, preserva comparabilidad justa y alcanza un WAPE de 16,10 % a nivel SKU. Adicionalmente, se evaluó una extensión de *Learned Shares* (motor supervisado de cuotas dinámicas con 14 features), que obtuvo un WAPE de 24,35 % a nivel SKU, superior al enfoque estático principal, lo que sugiere que las proporciones fijas del período de entrenamiento ofrecen mayor estabilidad en catálogos con alta intermitencia.
4. **Robustez evaluada mediante análisis de ablación:** Los contrastes muestran que la arquitectura ES-GBM conserva una ventaja sustancial incluso sin información de precios. Sin dicha información, el modelo logra un WAPE de 38,25 % a nivel SKU. Al incorporar el plan comercial ex-ante, se alcanza el 16,10 % del modelo completo. Este resultado indica que la señal de precios aporta una contribución predictiva sustancial, aunque la estructura jerárquica inercial y el modelado no lineal de panel proporcionan una base de robustez predictiva que no depende exclusivamente de dicha variable.
5. **Protocolo Riguroso Anti-Leakage y Validación en Tres Tramos:** Todas las decisiones de ensamble, umbrales de ruteo y pesos NNLS se calibraron estrictamente sobre el conjunto de validación intermedia, de modo que el desempeño en el conjunto de prueba sea genuinamente predictivo y reproducible en un entorno operativo.

6.3. Evaluación de Deep Learning en Contextos de Alta Intermitencia

Como se evidenció en la Sección 5.4, el modelo LSTM alcanzó un WAPE de 45,75 % a nivel SKU (con precio ex-ante), por detrás del ensamble ES-GBM (16,10 %). El LSTM se implementó en su formulación base, sin mecanismos adicionales de estabilización de nivel. En contextos de Small Data con alta intermitencia, una red recurrente pura enfrenta el doble desafío de estimar simultáneamente el nivel estructural de la serie y sus fluctuaciones comerciales. La ventaja operativa del ensamble propuesto reside en que Holt amortiguado provee ese anclaje de nivel de forma directa, liberando al módulo GBDT para concentrarse únicamente en las modulaciones sobre la trayectoria base. En la configuración evaluada bajo este diseño experimental, el LSTM no alcanzó la precisión de la arquitectura híbrida propuesta.

6.4. Evaluación de Hipótesis y Evidencia Inferencial

A partir de la evidencia empírica obtenida en el período de prueba fuera de muestra, se evalúan las hipótesis de trabajo:

- **Evidencia Favorable a la Hipótesis Alternativa (H1):** En términos descriptivos, la arquitectura propuesta ES-GBM presenta un WAPE sustancialmente inferior al de los tres benchmarks primarios evaluados durante todo el período de prueba (12,89 % a nivel Familia y 16,10 % a nivel SKU), ofreciendo evidencia empírica favorable a la hipótesis de superioridad predictiva en la métrica rectora del estudio.
- **Alcance de la Inferencia Estadística (Test de Diebold-Mariano):** Como evidencia inferencial complementaria, el test de **Diebold-Mariano (DM)** (Diebold and Mariano, 1995) —aplicado sobre errores transversales agrupados con función de pérdida cuadrática y corrección HAC— muestra diferencias estadísticamente favorables para ES-GBM frente a los benchmarks primarios: SARIMA ($t = 7,84, p = 0,0002$), SARIMAX ($t = 13,19, p < 0,0001$) y la red recurrente LSTM ($t = 10,14, p = 0,0001$). Se hace notar que este contraste evalúa diferencias bajo pérdida cuadrática y, por tanto, no constituye un contraste directo de la hipótesis formulada específicamente en términos de WAPE, sino un respaldo inferencial consistente en el dominio de los errores cuadráticos medios. Para Chronos-Bolt, Croston, SBA y Seasonal Naïve, la comparación se mantiene en términos descriptivos, dado que el protocolo inferencial de esta investigación se delimitó a priori para los modelos de referencia primarios.

Advertencia Metodológica sobre Paneles de Corto Horizonte: Desde la econometría de series de tiempo (Harvey et al., 1997; Pesaran and Timmermann, 2005), se reconoce explícitamente que la aplicación del test de Diebold-Mariano sobre paneles transversales agrupados (*pooled errors*) en

horizontes temporales acotados ($H = 7$ meses) está sujeta a posibles correlaciones contemporáneas (*cross-sectional correlation*) inducidas por shocks macroeconómicos o promocionales compartidos entre SKUs. Por consiguiente, estos estadísticos deben interpretarse como **evidencia indicativa robusta de dominancia empírica fuera de muestra**, cuya validación asintótica formal constituirá una línea de investigación futura mediante extensiones de pruebas de panel no paramétricas multi-anales.

Asimismo, esta diferencia fue respaldada por el análisis de ablación de la señal de precios, el cual evidencia que, aunque el precio ex-ante es la variable individual más informativa, la ganancia en precisión proviene también de la robustez del ensamble jerárquico y del desacoplamiento de nivel, que aportan una base de desempeño que no depende exclusivamente de la señal de precios.

En conclusión, la evidencia empírica apoya el marco metodológico propuesto: la integración de un nivel base suavizado, ensambles GBDT con ruteo adaptativo y desagregación jerárquica Top-Down mediante proporciones históricas estáticas no solo reduce drásticamente el error de pronóstico frente a los modelos clásicos (WAPE 16,10 % vs 76,74 % de SARIMA), sino que aporta una herramienta metodológica para la planificación de inventario en el retail moderno.

6.5. Implicancias Conceptuales para el Pronóstico en Retail de Moda

6.5.1. La demanda como resultado de la planificación comercial

Los resultados obtenidos sugieren que la demanda en el retail de moda femenina no debe interpretarse como un fenómeno puramente autorregresivo, pues la venta de unidades responde en gran medida a decisiones comerciales tomadas previamente, tales como la planificación de ventas, la definición de precios y el calendario promocional. Bajo esta lógica, el bajo desempeño observado en los modelos univariados se justifica por su incapacidad de capturar las señales de factores exógenos. Comprenderlo es entender que omitir la planificación comercial implica dejar fuera una fuente central de información predictiva.

6.5.2. El rol de las variables de planificación comercial en la predicción de unidades

La inclusión de variables de planificación comercial ex-ante, como el precio y el descuento vigente, resultó ser más relevante que el uso de una proyección financiera agregada como Monto Neto: al evaluarse de forma aislada, esta última no mejoró el desempeño del modelo y en algunos casos lo perjudicó, lo que llevó a descartarla de la arquitectura final por el protocolo anti-leakage. En cambio, el precio y el descuento, disponibles de antemano por tratarse de decisiones ya tomadas por la empresa, sí concentran información relevante sobre la intención comercial y la sensibilidad

predictiva del consumidor al precio. Lo anterior sugiere que, en este contexto de retail de moda, es la señal de planificación comercial directa, y no un agregado financiero derivado, la que actúa como proxy efectivo de la intención comercial subyacente.

6.6. Impacto Económico, Financiero y Operacional

La reducción del error de pronóstico desde niveles superiores al 75 % en el baseline SARIMA hasta 16,10 % con la arquitectura propuesta ES-GBM no solo representa un avance metodológico en ciencia de datos aplicada, sino que genera un impacto potencial en la estructura de costos y la liquidez financiera del negocio.

6.6.1. Evaluación Financiera del Impacto en Capital de Trabajo: Distinción entre Stock y Flujo

Como ejercicio ilustrativo y de orden de magnitud para la gestión financiera y de operaciones (Silver et al., 1998), es fundamental distinguir entre una **variable de nivel o stock** (el inventario inmovilizado en bodega) y una **variable de flujo** (el ahorro operativo anual en costos de mantención).

Formulación del Stock de Seguridad y Regímenes de Agregación: El stock de seguridad (SS) necesario para amortiguar la incertidumbre del pronóstico durante el tiempo de reposición (*lead time* $L = 1$ mes) con un nivel de servicio de ciclo $CSL = 95\%$ ($Z_{0,95} \approx 1,645$) se analiza bajo dos regímenes de gestión de inventarios:

1. **Gestión Descentralizada por SKU / Correlación Contemporánea** ($\sum_{i=1}^N SS_i$): En el retail de vestuario, donde los artículos no son sustitutos perfectos y cada SKU gestiona su propio nivel de servicio en tienda y bodega, el inventario físico total en balance corresponde a la suma simple de los amortiguadores individuales ($SS_{\text{descentralizado}} = \sum_{i=1}^N SS_i = Z_{\alpha} \cdot \overline{\text{MAE}} \cdot N_{\text{SKU}} \cdot \sqrt{L}$). Este supuesto representa además el límite conservador ante correlaciones contemporáneas positivas inducidas por shocks comerciales compartidos (clima, eventos masivos y promociones).
2. **Agrupación de Riesgos Centralizada (*Risk Pooling* con Errores Independientes)**: Si se asume un centro de distribución consolidado con independencia estocástica perfecta entre los errores de demanda de los distintos SKUs ($\rho_{ij} = 0$), la incertidumbre agregada escala con la raíz cuadrada del número de productos: $SS_{\text{pool}} = Z_{\alpha} \cdot \overline{\text{MAE}} \cdot \sqrt{N_{\text{SKU}}} \cdot \sqrt{L}$.

$$SS_{\text{total}} = Z_{\alpha} \cdot \overline{\text{MAE}} \cdot K_{\text{agg}} \cdot \sqrt{L} \quad (6.1)$$

donde SS_{total} es el inventario de seguridad agregado (en unidades físicas), $Z_{\alpha} = 1,645$ es el factor de cobertura ($CSL = 95\%$), $\overline{\text{MAE}}$ es el error absoluto medio por SKU, K_{agg} es el factor de agregación

($K_{\text{agg}} = N_{\text{SKU}} = 100$ en gestión descentralizada; $K_{\text{agg}} = \sqrt{N_{\text{SKU}}} = 10$ en *risk pooling* independiente), y $L = 1$ es el *lead time* mensual.

Nota sobre la elección del MAE como proxy: Para efectos ilustrativos de orden de magnitud, se utiliza el MAE como proxy de la desviación absoluta esperada del error, por su interpretabilidad directa en unidades físicas. Bajo el supuesto de normalidad de los errores, la relación teórica con la desviación estándar es $\sigma \approx \text{MAE} \cdot \sqrt{\pi/2} \approx 1,25 \cdot \text{MAE}$, lo que implica que los valores financieros calculados podrían ajustarse al alza en un factor similar. Esta aproximación no equivale exactamente a la desviación estándar y constituye un supuesto simplificador del ejercicio ilustrativo.

Evaluando los parámetros empíricos obtenidos bajo el régimen descentralizado ($N_{\text{SKU}} = 100$):

- **Línea Base SARIMA (MAE = 54,2 un/SKU):** Requiere un stock de seguridad de **8.916 unidades** en bodega ($SS = 1,645 \cdot 54,2 \cdot 100 \cdot \sqrt{1}$), inmovilizando **\$133,7 millones CLP** (a un costo medio de reposición $c = \$15,000$ CLP/unidad).
- **Línea Base LSTM (MAE = 32,3 un/SKU):** Requiere **5.313 unidades** en bodega (**\$79,7 millones CLP** inmovilizados).
- **Arquitectura Propuesta ES-GBM (MAE = 11,4 un/SKU):** Requiere solo **1.875 unidades** en bodega (**\$28,1 millones CLP** inmovilizados).

Impacto Económico Ilustrativo en Balance y Flujo de Caja:

1. **Liberación de Capital de Trabajo (Efecto Nivel):** Bajo los supuestos de la simulación, la contracción del error permitiría estimar una liberación permanente de **7.041 unidades amortiguadoras**, lo que equivale a una disminución de capital inmovilizado de **\$105,6 millones CLP** en balance ($7.041 \times \$15,000$).
2. **Ahorro Operacional Anual en Costos de Mantención (Efecto Flujo):** Considerando una tasa anual de costo de posesión (*holding cost rate*) supuesto de escenario base de $i = 22\%$ anual (mermas, seguros, almacenaje y costo de capital), el ahorro de flujo recurrente se estima en:

$$\Delta \text{Holding Cost} = i \times \Delta \text{Capital} = 0,22 \times \$105,615,000 \approx \textbf{\$23,2 millones CLP anuales} \quad (6.2)$$

Matriz de Sensibilidad Financiera Multiescenario: Para no restringir la evaluación a un supuesto único, la Tabla 6.1 presenta una matriz de sensibilidad que evalúa tanto los parámetros financieros de costo (c) y tasa de mantención (i) como el supuesto estructural de agregación de inventarios (N_{SKU} descentralizado vs $\sqrt{N_{\text{SKU}}}$ con *risk pooling*):

Distinción de Escenarios Logísticos de Lead Time ($L = 1$ vs $L = 4$ meses): El cálculo anterior ($L = 1$ mes) representa el **ciclo de reposición periódica interna** desde el Centro de Distribución (CD) central hacia la red de tiendas físicas y canales digitales.

Tabla 6.1: Matriz de Sensibilidad del Impacto Financiero en Inventarios.

Escenario de Costo y Tasa	Costo Reposición (c)	Tasa Holding (i)	Capital Liberado	Ahorro Anual
<i>Panel A: Gestión Descentralizada por SKU / Sin Efecto de Pooling ($K_{agg} = N_{SKU} = 100$, 7.041 un. liberadas)</i>				
Conservador	\$12.000 CLP	18 %	\$84,5M CLP	\$15,2M CLP/año
Caso Base	\$15.000 CLP	22 %	\$105,6M CLP	\$23,2M CLP/año
Exigente (Alta Merma)	\$18.000 CLP	26 %	\$126,8M CLP	\$33,0M CLP/año
<i>Panel B: Agrupación Centralizada con Risk Pooling Independiente ($K_{agg} = \sqrt{N_{SKU}} = 10$, 704 un. liberadas)</i>				
Conservador (Pool)	\$12.000 CLP	18 %	\$8,5M CLP	\$1,5M CLP/año
Caso Base (Pool)	\$15.000 CLP	22 %	\$10,6M CLP	\$2,3M CLP/año
Exigente (Pool)	\$18.000 CLP	26 %	\$12,7M CLP	\$3,3M CLP/año

Fuente: Elaboración propia.

En un escenario de **aprovisionamiento internacional transoceánico** (con compras a fábricas en Asia y tiempos de tránsito marítimo de $L_{imp} = 4$ meses), la desviación estándar acumulada del error de pronóstico se amplifica por un factor de $\sqrt{L_{imp}} = \sqrt{4} = 2$. Bajo esta escala de abastecimiento global, el buffer de resguardo liberado por la precisión de la arquitectura ES-GBM asciende a:

$$\Delta SS_{\text{Internacional}} = \sqrt{L_{imp}} \times \Delta SS_{\text{Local}} = 2 \times 7.041 = \mathbf{14.082} \text{ unidades amortiguadoras} \quad (6.3)$$

donde $\Delta SS_{\text{Internacional}}$ es la contracción del stock amortiguador bajo aprovisionamiento marítimo internacional ($L_{imp} = 4$ meses) y ΔSS_{Local} corresponde al caso base nacional ($L = 1$ mes), escalando por la raíz cuadrada del plazo de reposición ($\sqrt{4} = 2$). Lo que equivale a un capital de trabajo permanente liberado de **\$211,2 millones CLP** en la cadena de suministro extendida, lo que, bajo los supuestos del escenario, implica un mayor potencial de liberación de capital a medida que aumenta el lead time.

6.7. Limitaciones del Estudio

1. Alcance del Catálogo (Segmento Top-Tier): El estudio se concentró en los 100 SKU de mayor volumen comercial (agrupados en 58 familias activas, con una densidad media de 1,7 SKU por familia), definidos estrictamente a partir del período histórico de entrenamiento y validación (2020 a 2024 previo al corte). Se reconoce que la 'cola larga' del catálogo (los 1.357 SKU restantes de muy baja rotación) presenta una intermitencia cualitativamente superior, cuyo modelado específico se plantea como trabajo futuro.

2. Naturaleza del Target (Ventas Observadas vs. Demanda Latente no Censurada): La variable objetivo corresponde a unidades vendidas y registradas en el sistema transaccional POS de la empresa. En la gestión de retail, ante eventos de quiebre de stock en tienda, las ventas observadas se truncan a cero aunque existiera intención de compra insatisfecha. Por lo tanto, el modelo pronostica ventas orgánicas observadas bajo las condiciones operativas históricas de disponibilidad y no

demanda latente pura.

3. Dinámica Intra-Mes y Elasticidad Precios: La arquitectura asume como covariable ex-ante el precio de lista y el descuento estacional programado en el plan comercial. Sin embargo, el modelo no captura las decisiones reactivas de liquidación intramensual (mark-downs de emergencia aplicados en la última semana del mes para liquidar sobrestock).

4. Horizonte Temporal de Planificación ($h = 1$): El protocolo experimental se delimitó a un horizonte mensual rodante a un paso ($h = 1$). En la industria de moda importada con ciclos de abastecimiento marítimo de 3 a 6 meses, se requiere extender la evaluación hacia arquitecturas multi-horizonte directas o recursivas ($h \in \{1, 3, 6\}$).

5. Validez Externa y Monocaso: Los resultados provienen de una única empresa del segmento Premium-Mass Market de vestuario femenino en Chile. Si bien el marco metodológico es exportable, la magnitud cuantitativa de la reducción de error dependerá de la estructura de catálogo y la calidad de la planificación comercial de cada organización.

6. Estabilidad Temporal de Ponderaciones y Esquema de Calibración: En la arquitectura ES-GBM, los modelos de ensamble GBDT, las ponderaciones NNLS y los parámetros de ruteo de régimen se calibraron de manera fija sobre los datos de entrenamiento y validación previa (hasta CUT = enero 2025), evaluándose con pesos congelados durante el horizonte de prueba de 7 meses. Si bien el modelo mostró estabilidad predictiva frente a la evolución observada durante el horizonte de prueba bajo pesos congelados (alcanzando 16,10 % de WAPE a nivel SKU), la determinación de la frecuencia óptima de reentrenamiento continuo y recalibración automática de hiperparámetros en entornos productivos constituye un área abierta de investigación.

7. Asimetría Metodológica en la Configuración de Líneas Base: Las referencias econométricas clásicas (SARIMA y SARIMAX) se especificaron bajo una parametrización global parsimoniosa estándar $((1, 1, 1) \times (1, 1, 1)_{12})$ para favorecer la reproducibilidad y estabilidad computacional en esquemas rodantes, sin recurrir a procedimientos intensivos de selección de órdenes (*auto-ARIMA*) por SKU individual. Por el contrario, la arquitectura ES-GBM contó con un proceso estructurado de ingeniería de variables y calibración por fases. Esta asimetría debe considerarse al interpretar la magnitud del diferencial predictivo.

8. Cobertura Estacional del Horizonte de Prueba: La ventana de evaluación (febrero–agosto 2025) incluye el pico de mayo (Día de la Madre y campaña CyberDay) pero excluye el pico de noviembre–diciembre, período de mayor volumen anual y mayor presión promocional del retail chileno. El desempeño reportado no debe extrapolarse sin reservas a la temporada alta de fin de año, que concentra una proporción sustancial de las ventas anuales del segmento.

6.8. Futuras investigaciones

La presente investigación se delimitó a un enfoque de pronóstico jerárquico supervisado. Si bien la arquitectura híbrida ES-GBM mostró el mejor desempeño entre las configuraciones evaluadas

para el catálogo analizado, este diseño abre nuevas líneas de investigación que podrían ampliar la capacidad predictiva y explicativa del sistema en entornos productivos.

Entre las principales proyecciones de trabajo futuro se destacan:

- Exploración y Fine-tuning de Modelos Fundacionales (Foundation Models): El desempeño zero-shot de Amazon Chronos-Bolt (WAPE 36,35 % a nivel de Familia agregada) mostró la capacidad de transferencia de los Transformers temporales pre-entrenados. Una línea promisoría consiste en el ajuste fino (fine-tuning) de modelos como Chronos o TimesFM integrando variables exógenas comerciales de la empresa.
- Arquitecturas Híbridas de Deep Learning y Tabulares: Investigar la integración end-to-end de redes recurrentes (LSTM/GRU) o Transformers tabulares (como TabPFN) directamente en la etapa de desagregación de cuotas (shares), evaluando si el Deep Learning adaptado puede optimizar la asignación fina a nivel de producto individual.
- Desempeño Diferencial por Perfil de SKU: Esta investigación evaluó los modelos según su WAPE agregado sobre el catálogo completo. Una extensión relevante consiste en identificar el perfil de SKU —según su nivel de rotación, intermitencia y sensibilidad al precio— en que cada familia de modelos exhibe ventaja comparativa, permitiendo asignar el método de predicción más adecuado a cada segmento del catálogo en lugar de aplicar una arquitectura única.

En síntesis, los resultados obtenidos respaldan la pertinencia del enfoque híbrido propuesto, evidenciando que la integración de descomposición estructural inercial, modelos de ensamble de árboles potenciados y desacoplamiento jerárquico con ruteo dinámico por momentum proporciona una herramienta cuantitativa sólida, escalable y potencialmente transferible a la planificación de inventario en la industria del retail.

6.9. Uso de Herramientas de Inteligencia Artificial y Protocolo de Verificación

Durante el desarrollo de esta memoria se utilizaron herramientas de inteligencia artificial generativa como apoyo en tareas de programación, depuración, refactorización, documentación técnica y revisión de redacción. Este soporte de carácter instrumental no sustituyó la formulación del problema de negocio, la selección de datos, las decisiones metodológicas, la interpretación de resultados ni la elaboración de las conclusiones.

Asimismo, la investigación demandó un trabajo intensivo de exploración empírica, iteración y corrección continua. Aprovechando que distintos modelos fundacionales han sido entrenados bajo corpus y arquitecturas diversas, se utilizaron de manera complementaria como un panel de contraste

técnico para debatir y someter a prueba las ideas de diseño concebidas por el autor, evaluar la factibilidad computacional de los algoritmos y ponderar los diversos *trade-offs* metodológicos antes de su implementación en el pipeline.

El autor definió la arquitectura experimental, las reglas de disponibilidad temporal de las variables, los criterios de comparación, las métricas de evaluación y los supuestos aplicados en la cuantificación del impacto financiero. Ningún fragmento de código fue incorporado sin inspección previa: cada módulo fue revisado, adaptado y validado en el entorno de ejecución antes de su integración definitiva.

La verificación del sistema se sustentó en los siguientes mecanismos: (i) separación cronológica estricta entre entrenamiento, validación y prueba; (ii) pruebas automatizadas sobre rezagos y disponibilidad temporal para mitigar riesgos de fuga de información; (iii) revisión manual de transformaciones y agregaciones jerárquicas; (iv) recálculo directo de métricas a partir de las predicciones almacenadas; (v) fijación de semillas aleatorias, versiones de librerías y parámetros; y (vi) verificación de consistencia entre las formulaciones matemáticas y su código correspondiente.

Debido a las restricciones de confidencialidad del retailer, los registros transaccionales originales no pueden distribuirse públicamente. No obstante, se conservaron los scripts, entornos virtuales, registros de ejecución y resultados intermedios para permitir la auditoría interna y la reproducción de los experimentos en un ambiente autorizado. La responsabilidad por la exactitud de los resultados y las conclusiones recae en el autor.

Bibliografía

- Ansari, A. F., Stella, L., Turkmen, C., Zhang, X., Mercado, P., Shen, H., Shchur, O., Rangapuram, S. S., Arango, S. P., Kapoor, S., Zschiegner, J., Maddix, D. C., Wang, H., Mahoney, M. W., Torkkola, K., Wilson, A. G., Bohlke-Schneider, M., and Wang, Y. (2024). Chronos: Learning the language of time series. *Transactions on Machine Learning Research*.
- Bloznelis, D. (2018). Short-term salmon price forecasting. *Journal of Forecasting*, 37(2):151–169.
- Box, G. E. P., Jenkins, G. M., Reinsel, G. C., and Ljung, G. M. (2015). *Time Series Analysis: Forecasting and Control*. John Wiley & Sons, 5th edition.
- Chen, T. and Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794.
- Chen, Z. and Yang, Y. (2017). Assessing forecast accuracy measures: A generalized symmetric mean absolute percentage error. *International Journal of Forecasting*, 33(4):834–846.
- Conde Langa, E. (2024). Modelo de previsión de demanda de productos en retail fast fashion. Master’s thesis, Universidad Pontificia Comillas.
- Cragg, J. G. (1971). Some statistical models for limited dependent variables with application to the demand for durable goods. *Econometrica*, 39(5):829–844.
- Croston, J. D. (1972). Forecasting and stock control for intermittent demands. *Operational Research Quarterly*, 23(3):289–303.
- Diebold, F. X. and Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3):253–263.
- Expert Market Research (2025). Latin america women’s apparel market report and forecast 2025-2033. EMR Market Reports.
- Gujarati, D. N. and Porter, D. C. (2009). *Econometría*. McGraw-Hill Interamericana, 5th edition.
- Harvey, D., Leybourne, S., and Newbold, P. (1997). Testing the equality of prediction mean squared errors. *International Journal of Forecasting*, 13(2):281–291.
- Hochreiter, S. and Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8):1735–1780.

- Hollmann, N., Müller, S., Purucker, L., Krishnakumar, A., Körfer, M., Hoo, S. B., Schirrmeister, R. T., and Hutter, F. (2025). Accurate predictions on small data with a tabular foundation model. *Nature*, 637:319–326.
- Holt, C. C. (2004). Forecasting seasonals and trends by exponentially weighted moving averages. *International Journal of Forecasting*, 20(1):5–10.
- Hyndman, R. J., Ahmed, R. A., Athanasopoulos, G., and Shang, H. L. (2011). Optimal combination forecasts for hierarchical time series. *Computational Statistics & Data Analysis*, 55(9):2579–2589.
- Hyndman, R. J. and Athanasopoulos, G. (2018). *Forecasting: Principles and Practice*. OTexts: Melbourne, Australia, 2nd edition.
- Hyndman, R. J. and Koehler, A. B. (2006). Another look at measures of forecast accuracy. *International Journal of Forecasting*, 22(4):679–688.
- Instituto Nacional de Estadísticas (INE) (2024). Boletín estadístico: Índice de precios al consumidor (ipc). Instituto Nacional de Estadísticas, Santiago, Chile.
- Instituto Textil de Chile (2025). Radiografía del sector textil y confección en Chile: Desafíos de cadena de suministro. Publicaciones Técnicas del Sector Textil, Santiago.
- Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., and Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 30, pages 3146–3154.
- Makridakis, S., Spiliotis, E., and Assimakopoulos, V. (2022). The M5 competition: Background, organization, and results. *International Journal of Forecasting*, 38(4):1325–1346.
- Mullahy, J. (1998). Much ado about two: reconsidering finiteness and other aspects of two-part models of count data. *Journal of Health Economics*, 17(3):247–281.
- Nicholson, W. and Snyder, C. (2015). *Teoría Microeconómica: Principios Básicos y Ampliaciones*. Cengage Learning, 11th edition.
- Pesaran, M. H. and Timmermann, A. (2005). Small sample properties of forecasts from autoregressive models under structural breaks. *Journal of Econometrics*, 129(1-2):183–217.
- Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., and Gulin, A. (2018). CatBoost: unbiased boosting with categorical features. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 31, pages 6638–6648.
- Silver, E. A., Pyke, D. F., and Peterson, R. (1998). *Inventory Management and Production Planning and Scheduling*. John Wiley & Sons, 3rd edition.

- Statista Research Department (2025). Revenue of the apparel market in chile – segment overview: Women’s apparel. Statista.
- Svetunkov, I. (2023). *Forecasting and Analytics with ADAM*. Chapman and Hall/CRC.
- Syntetos, A. A. and Boylan, J. E. (2005). The accuracy of intermittent demand estimates. *International Journal of Forecasting*, 21(2):303–314.
- Tashman, L. J. (2000). Out-of-sample tests of forecasting accuracy: an analysis and review. *International Journal of Forecasting*, 16(4):437–450.
- Wickramasuriya, S. L., Athanasopoulos, G., and Hyndman, R. J. (2019). Optimal forecast reconciliation for hierarchical and grouped time series through trace minimization. *Journal of the American Statistical Association*, 114(526):804–819.

Apéndice A

Anexos

A.1. Anexo 1: Serie Mensual del IPC de Vestuario (INE 2024–2025)

A continuación se detalla la evolución mensual del Índice de Precios al Consumidor (IPC) para la categoría de Vestuario reportada por el Instituto Nacional de Estadísticas (Instituto Nacional de Estadísticas (INE), 2024), utilizada como covariable macroeconómica exógena rezagada ($t - 1$):


Año y Periodo	Índice	Variación Mensual (%)
Enero 2024	92,04	-1,7
Febrero 2024	95,24	+3,5
Marzo 2024	94,79	-0,5
Abril 2024	93,17	-1,7
Mayo 2024	94,88	+1,8
Junio 2024	89,26	-5,9
Julio 2024	90,31	+1,2
Agosto 2024	92,70	+2,6
Septiembre 2024	93,09	+0,4
Octubre 2024	89,56	-3,8
Noviembre 2024	90,13	+0,6
Diciembre 2024	88,92	-1,3
Enero 2025	87,60	-1,5
Febrero 2025	92,29	+5,4
Marzo 2025	92,98	+0,8
Abril 2025	89,59	-3,6
Mayo 2025	88,78	-0,9
Junio 2025	84,43	-4,9
Julio 2025	84,80	+0,4

Fuente: Elaboración propia a partir de boletines estadísticos oficiales del INE (2024–2025).


A.2. Anexo 2: Evolución Histórica de Ventas Mensuales en Unidades y Monto Neto (2020–2022)

A continuación se presentan los registros históricos de ventas mensuales agregadas de la empresa para los años 2020, 2021 y 2022, comparando en paralelo el volumen físico (unidades vendidas) y el valor monetario (monto neto en millones de pesos chilenos):

Comportamiento de Ventas – Año 2020




(a) Unidades Vendidas (2020)




(b) Monto Neto en Millones CLP (2020)

Comportamiento de Ventas – Año 2021




(c) Unidades Vendidas (2021)




(d) Monto Neto en Millones CLP (2021)

Comportamiento de Ventas – Año 2022



(e) Unidades Vendidas (2022)



(f) Monto Neto en Millones CLP (2022)

Fuente: Elaboración propia a partir de registros transaccionales corporativos (2020–2022).

A.3. Anexo 3: Hiperparámetros de los Modelos de Ensamble ES-GBM a Nivel Familia

Configuraciones óptimas de calibración obtenidas mediante búsqueda en grilla sobre el conjunto de validación intermedia para los modelos de árboles del ensamble a nivel Familia. Todos los modelos se entrenan sobre un ensamble de 8 semillas aleatorias {42, 1, 7, 2025, 99, 3, 11, 21} promediando sus inferencias para asegurar estabilidad:

XGBoost (Módulo de Ensamble Combo)

Hiperparámetro	Valor Calibrado en Validación
learning_rate	0.05
max_depth	6
subsample	0.90
colsample_bytree	0.90
n_estimators	500
objective	reg:squarederror

LightGBM (Módulo Residual y Ensamble Global)

Hiperparámetro	Valor Calibrado en Validación
learning_rate	0.05
num_leaves	31
subsample	0.90
colsample_bytree	0.90
n_estimators	600
objective	regression

CatBoost (Módulo Categórico)

Hiperparámetro	Valor Calibrado en Validación
learning_rate	0.05
depth	6

Hiperparámetro	Valor Calibrado en Validación
iterations	600
loss_function	RMSE

TabPFN (Modelo Fundacional Tabular)

Hiperparámetro / Parámetro	Valor / Configuración
model_version	TabPFNRegressor v2
n_estimators	2 (ensamble bayesiano rápido)
inference_mode	<i>In-context zero-shot</i> tabular
preprocessing	Escalado robusto de features
fallback_handling	CPU fallback automatizado

A.4. Anexo 4: Especificaciones y Parámetros de Calibración de los Modelos Benchmark

Resumen de especificaciones metodológicas e hiperparámetros de calibración para los modelos de referencia evaluados en el protocolo $h = 1$:

Modelo	Familia Metodológica	Configuración / Hiperparámetros Clave	Tratamiento Exógeno / Desagregación
SARIMA	Series Temporales Clásica	$(1, 1, 1) \times (1, 1, 1)_{12}$, $\log(1 + y)$, reestimación rodante ($h = 1$)	Univariado uniestratificado
SARIMAX	Econometría con Exógenas	$(1, 1, 1) \times (1, 1, 1)_{12}$, covariables ex-ante ($P_t, Desc_t$)	Regresión dinámica lineal
Croston (1972)	Demanda Intermitente	Suavizamiento exponencial separado de demanda e intervalos ($\alpha = 0,1$)	Especializado en ceros
SBA	Demanda Intermitente	Corrección Syntetos-Boylan con factor de corrección ($1 - \alpha/2$)	Inssegado en series intermitentes
LSTM PyTorch	Deep Learning Recurrente	2 capas LSTM apiladas (56 y 32 celdas ocultas), Dropout 0,40, ventana 12 meses, Adam ($lr = 5 \times 10^{-4}$)	Multivariado con exógenas
Chronos-Bolt	Foundation Model	Arquitectura T5 pretrained Zero-Shot, context length 36 meses	Normalización de escala zero-shot

A.5. Anexo 5: Configuración y Features del Motor de Desagregación Dinámica (Learned Shares)

Hiperparámetros del estimador LightGBM y definición formal de las 14 características utilizadas en el panel de aprendizaje supervisado de cuotas de participación a nivel SKU:

Algoritmo	Hiperparámetros de Calibración	Semillas Evaluadas	Objetivo de Pérdida
LightGBM (<i>Share</i>)	n_estimators=500, learning_rate=0.05, num_leaves=31, subsample=0.9, colsample_bytree=0.9, random_state∈ {42, 1, 7, 2025, 99}	Regresión Huber ($\alpha = 0,9$) + Normalización al Símpex ($\max(0, s_i) / \sum$)	
XGBoost (<i>Share</i>)	n_estimators=500, learning_rate=0.05, max_depth=6, subsample=0.9, colsample_bytree=0.9, random_state∈ {42, 1, 7, 2025, 99}	Promedio de semillas; iguales hiperparámetros base	
CatBoost (<i>Share</i>)	Grid search: depth∈ {4, 6, 8}, learning_rate∈ {0,03, 0,05}, iterations=600, random_seed∈ {42, 1, 7, 2025, 99}	Optimizado en validación ($C_1 =$ 1-mar-2024); promedio de semillas	
Ensamble de <i>Shares</i>	Promedio simple de las 3 predicciones individuales ($\hat{s}_{\text{ens}} = \frac{1}{3} \sum_m \hat{s}_m$)	Selecciona mejor modelo individual vs ensamble por WAPE en validación	

Vector de 14 Características para el Aprendizaje de Shares por SKU

1. **sh_L1:** Cuota de participación del SKU en su Familia en el mes $t - 1$.
2. **sh_L12:** Cuota de participación del SKU en el mismo mes del año anterior ($t - 12$).

3. **sh_rm3**: Promedio móvil de cuota de participación en los últimos 3 meses.
4. **sh_rm12**: Promedio móvil de cuota de participación en los últimos 12 meses.
5. **sh_ewm**: Promedio ponderado exponencial de la cuota con ventana de 6 meses (*EWM-6*).
6. **sh_trend**: Tendencia de la cuota: $\text{sh_rm3} - \text{sh_rm12}$.
7. **sh_perfil**: Perfil estacional mensual del SKU (promedio histórico de la cuota por mes del año).
8. **msls**: Meses desde la última venta del SKU (*Months Since Last Sale*).
9. **nz**: Proporción de meses con ventas no nulas en los últimos 12 meses.
10. **sin_m**: Componente armónico estacional $\sin(2\pi m/12)$.
11. **cos_m**: Componente armónico estacional $\cos(2\pi m/12)$.
12. **famlvl**: Nivel de demanda promedio de la Familia en el período de entrenamiento.
13. **px_rel_fam**: Precio del SKU relativo al precio promedio de su Familia.
14. **px_rel_hist**: Precio del SKU relativo a su propio promedio móvil de 6 meses.

A.6. Anexo 6: Ficha Técnica y Diccionario de Variables del Conjunto de Datos Consolidado

Estructura de las principales variables del conjunto de datos maestro depurado y estandarizado del estudio:

Dimensión	Nombre de la Columna	Tipo de Dato	Descripción y Rol Metodológico
Jerarquía	SKU_Personalizado	String / Cat	Identificador único anonimizado del producto (SKU).
Jerarquía	Familia	String / Cat	Clasificación intermedia de producto (58 categorías).
Jerarquía	Macro_Categoria	String / Cat	Nivel macro del catálogo (5 macro-líneas).
Temporal	Fecha	Date (YYYY-MM)	Período mensual de observación (2020-01 a 2025-08).
Temporal	Anio / Mes	Entero	Componentes temporales de calendario.
Target	Venta_Neta_Unidades	Float	Unidades vendidas mensuales orgánicas (Target y).
Target	Venta_Neta_Monto	Float	Ingresos operacionales netos en pesos chilenos (CLP).
Exógena Ex-Ante	Precio_Estimado	Float	Precio de catálogo planificado para el período t .
Exógena Ex-Ante	Descuento_promedio_estimado	Float	Tasa de descuento comercial programada para el período t .
Exógena Ex-Ante	Eventos_Comerciales	Binaria	Dummy de hitos de retail (Cyber, Día de la Madre, Navidad).

Dimensión	Nombre de la Columna	Tipo de Dato	Descripción y Rol Metodológico
Exógena Ex-Post	IPC_Vestuario	Float	Índice de Precios al Consumidor rezagado $(t - 1)$.
Exógena Ex-Post	IMACEC_Comercio	Float	Actividad económica sectorial del Banco Central $(t - 1)$.
Exógena Ex-Post	Tipo_Cambio_USD	Float	Tipo de cambio promedio mensual observado en $t - 1$.
Feature Eng.	demanda_lag_1	Float	Demanda observada en el mes $t - 1$.
Feature Eng.	demanda_lag_2	Float	Demanda observada en el mes $t - 2$.
Feature Eng.	demanda_lag_3	Float	Demanda observada en el mes $t - 3$.
Feature Eng.	demanda_lag_12	Float	Demanda observada en el mismo mes del año anterior $(t - 12)$.
Feature Eng.	media_movil_3m	Float	Media móvil de ventas orgánicas en los últimos 3 meses.
Feature Eng.	media_movil_6m	Float	Media móvil de ventas orgánicas en los últimos 6 meses.
Feature Eng.	media_movil_12m	Float	Media móvil de ventas orgánicas en los últimos 12 meses.
Feature Eng.	volatilidad_3m	Float	Desviación estándar móvil de ventas en 3 meses.
Feature Eng.	share_familia_lag1	Float	Cuota de participación del SKU en su Familia en $t - 1$.
Feature Eng.	ratio_precio_familia	Float	Ratio entre el precio del SKU y el precio medio de la Familia.

Dimensión	Nombre de la Columna	Tipo de Dato	Descripción y Rol Metodológico
Feature Eng.	dif_descuento_familia	Float	Brecha de descuento comercial entre SKU y Familia.
Transformación	log1p_unidades	Float	Transformación estabilizadora $\log(1 + y)$.
Transformación	asinh_unidades	Float	Transformación hiperbólica inversa $\operatorname{asinh}(y)$.
Partición	Split_Tramo	String	Segmento metodológico (Train, Val, Test).

A.7. Anexo 7: Formulación Matemática del Modelo SARIMA

El modelo univariado se especifica formalmente bajo la notación estándar de Box-Jenkins como $\text{SARIMA}(p, d, q) \times (P, D, Q)_s$, donde para capturar los ciclos anuales de la moda se define $s = 12$. La formulación matemática adopta la siguiente estructura:

$$\phi_p(B)\Phi_P(B^s)(1-B)^d(1-B^s)^DY_t = \theta_q(B)\Theta_Q(B^s)\epsilon_t \quad (\text{A.1})$$

donde:

- Y_t : Serie temporal de demanda mensual transformada logarítmicamente ($Y_t = \ln(1 + y_t)$).
- B : Operador de retardo temporal (*Backshift operator*), definido como $B^k Y_t = Y_{t-k}$.
- s : Periodicidad estacional, fijada en $s = 12$ meses para modelar el ciclo anual completo de la moda.
- $\phi_p(B) = 1 - \sum_{i=1}^p \phi_i B^i$: Polinomio autorregresivo (AR) de orden regular p .
- $\theta_q(B) = 1 + \sum_{j=1}^q \theta_j B^j$: Polinomio de medias móviles (MA) de orden regular q .
- $\Phi_P(B^s) = 1 - \sum_{i=1}^P \Phi_i B^{is}$: Polinomio autorregresivo estacional (SAR) de orden P .
- $\Theta_Q(B^s) = 1 + \sum_{j=1}^Q \Theta_j B^{js}$: Polinomio de medias móviles estacional (SMA) de orden Q .
- $(1-B)^d$ y $(1-B^s)^D$: Operadores de diferenciación regular ($d = 1$) y estacional ($D = 1$) para inducir estacionariedad en media y estacionalidad.
- ϵ_t : Término de perturbación estocástica o ruido blanco, con $\epsilon_t \sim \mathcal{N}(0, \sigma_\epsilon^2)$.

La configuración global seleccionada fue $\text{SARIMA}(1, 1, 1) \times (1, 1, 1)_{12}$: un término autorregresivo ($p = 1$) para capturar la memoria inmediata, una diferenciación ($d = 1$) para corregir la tendencia estocástica, un término de media móvil ($q = 1$) para ajustar el error de corto plazo, y sus equivalentes estacionales ($P = 1, D = 1, Q = 1$) para modelar la recurrencia anual de colecciones climáticas y eventos comerciales.

A.8. Anexo 8: Formulación Matemática del Modelo SARIMAX y Corrección de Sesgo

El modelo SARIMAX extiende la formulación estacional univariada al incorporar una combinación lineal de covariables exógenas como regresores externos. La especificación formal adoptada corresponde a un SARIMAX(1, 1, 1) $\times$ (1, 1, 1)₁₂, definida como:

$$\phi_p(B)\Phi_P(B^s)(1-B)^d(1-B^s)^D \left(Y_t - \sum_{i=1}^k \beta_i X_{i,t} \right) = \theta_q(B)\Theta_Q(B^s)\epsilon_t \quad (\text{A.2})$$

donde:

- Y_t : Logaritmo natural de la demanda observada ($Y_t = \ln(1 + y_t)$).
- $X_{i,t}$: Matriz de k regresores exógenos: precio planificado y descuento planificado, ambos disponibles en tiempo t (ex-ante) antes de la transacción de venta.
- $\sum_{i=1}^k \beta_i X_{i,t}$: Componente de regresión lineal externa que modela el impacto directo de las señales comerciales ex-ante (precio y descuento planificados) sobre la demanda base.
- β_i : Vector de coeficientes de regresión estimados simultáneamente con los parámetros autorregresivos.
- $(1-B)^d(1-B^s)^D$: Operador de doble diferenciación (regular $d = 1$ y estacional $D = 1$ con $s = 12$) aplicado a los residuos de regresión para asegurar estacionariedad.
- $\phi_p(B), \Phi_P(B^s), \theta_q(B), \Theta_Q(B^s)$: Operadores polinomiales AR y MA regulares y estacionales.
- ϵ_t : Error estocástico no autocorrelacionado (*ruido blanco*).

Corrección de Sesgo por Transformación Logarítmica (Bias Correction): Un desafío matemático de trabajar con transformaciones logarítmicas es que, al aplicar la inversa (exponencial) para obtener el pronóstico final, se introduce un sesgo sistemático que subestima la media. Para mitigar esto, se ajusta la predicción utilizando la varianza del error (σ_ϵ^2) estimada durante el entrenamiento:

$$\hat{y}_{\text{final}} = \exp \left(\hat{y}_{\log} + \frac{\sigma_\epsilon^2}{2} \right) - 1 \quad (\text{A.3})$$

donde $\hat{y}_{\text{final}}$ es la proyección en la escala de unidades físicas originales, $\hat{y}_{\log}$ es el pronóstico puntual en la escala logarítmica obtenida por el modelo SARIMAX, y σ_ϵ^2 representa la varianza residual estimada del error de pronóstico.

A.9. Anexo 9: Arquitectura Detallada de la Red LSTM

La arquitectura LSTM fue implementada en PyTorch (torch.nn) con la siguiente configuración:

Componente	Configuración
Capa de Entrada	Secuencias normalizadas (Min-Max por familia), ventana temporal SEQ_LEN = 12 meses
Capa LSTM 1	56 celdas ocultas, Dropout 0,40
Capa LSTM 2	32 celdas ocultas, Dropout 0,40
Capa Densa y Salida	Linear(32, 16) $\rightarrow$ ReLU $\rightarrow$ Linear(16, 1): proyección a un paso ($h = 1$)
Optimizador	Adam, learning rate 5×10^{-4}
Pérdida	MSE
Early Stopping	Paciencia de 15 épocas
Ensamble multi-semilla	5 semillas: {42, 1, 7, 2025, 99}, inferencia promediada
Features de entrada	Demanda histórica (12 rezagos), armónicos de estacionalidad (seno/coseno del mes), precio estimado ex-ante (variante con precio)